Deutsches Forschungszentrum
für Künstliche Intelligenz
German Research Center for Artificial Intelligence

DHBW CAS
Duale Hochschule
Baden-Württemberg
Center for Advanced Studies

Quantitative Analyse des Einflusses von Datenqualitätsproblemen auf die Robustheit unterschiedlicher NER-Modellarchitekturen

Masterarbeit

für die Prüfung zum

Master of Science (M.Sc.)

Im Studiengang

Informatik

am Center for Advanced Studies
der Dualen Hochschule Baden-Württemberg

Vorname und Nachname:	Denis Trautner
Matrikelnummer:	5474827
Bearbeitungszeitraum:	11.05.2025 – 10.11.2025
Dualer Partner:	Andreas STIHL AG & Co. KG
Betreuer*in/Prüfer*in:	Dr. Philippe Thomas
Prüfer*in:	Prof. Dr. Alexander Dück

Erklärung

Hiermit erkläre ich, dass ich die vorliegende Masterarbeit selbständig und ohne fremde Hilfe verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe. Aus fremden Quellen direkt oder indirekt übernommene Gedanken habe ich als solche kenntlich gemacht. Die Arbeit habe ich bisher keinem anderen Prüfungsamt in gleicher oder vergleichbarer Form vorgelegt. Sie wurde bisher auch nicht veröffentlicht.

Ich erkläre weiterhin, dass ich ein unverschlüsseltes digitales Textdokument der Arbeit (in einem der Formate .doc, .docx, .odt, .pdf, .rtf) in Moodle hochgeladen habe.

Schwaikheim, 10.11.2025 _____

(Ort, Datum) (Unterschrift)

Abstract (Deutsch)

Diese Arbeit untersucht den Einfluss von Datenqualitätsproblemen auf die Leistungsfähigkeit und Robustheit Transformer-basierter Modelle für die Named Entity Recognition. Im Zentrum steht die Frage, wie sich verschiedene Arten von Störungen auf die Modellleistung auswirken und in welchem Umfang architektonische Unterschiede zu einer höheren Stabilität beitragen. Ziel ist es, ein systematisches Verständnis der Zusammenhänge zwischen Datenqualität, Modellarchitektur und Robustheit zu entwickeln und damit einen Beitrag zur Bewertung der Zuverlässigkeit moderner NER-Systeme zu leisten.

Zur Beantwortung dieser Fragen wird ein hybrider Forschungsansatz gewählt, der ein systematisches Literaturreview mit einer experimentellen Analyse kombiniert. Das Literaturreview dient der Identifikation zentraler Arten von Datenstörungen und ihrer Einordnung in übergreifende Kategorien. Auf dieser Grundlage werden Experimente durchgeführt, in denen die identifizierten Störungstypen gezielt simuliert und ihre Auswirkungen auf sechs verbreitete Transformer Modelle untersucht werden: BERT, RoBERTa, DeBERTa, XLNet, DistilBERT und CANINE. Als Datengrundlage dient der CoNLL 2003 Datensatz.

Die Ergebnisse zeigen deutliche Unterschiede zwischen den Störungskategorien und verdeutlichen, dass die Robustheit stark von der Modellarchitektur abhängt. Besonders syntaktische Veränderungen führen zu spürbaren Leistungseinbußen, während eine gezielte Exposition gegenüber gestörten Trainingsdaten die Stabilität der Modelle deutlich erhöht. Darüber hinaus lassen sich charakteristische architekturspezifische Stärken identifizieren, die als Ansatzpunkte für zukünftige Modelloptimierungen dienen können.

Die Arbeit erweitert somit das Verständnis der Zusammenhänge zwischen Datenqualität, Modellarchitektur und Robustheit und bietet eine Grundlage für die gezielte Modellauswahl in der Praxis und die Entwicklung robusterer Modelle.

Abstract (English)

This thesis investigates the impact of data quality issues on the performance and robustness of transformer-based models for Named Entity Recognition (NER). It focuses on how different types of data perturbations affect model accuracy and to what extent architectural differences contribute to higher stability. The goal is to develop a systematic understanding of the relationships between data quality, model architecture, and robustness, thereby contributing to the assessment of reliability in modern NER systems.

To address these questions, a hybrid research approach is applied, combining a systematic literature review with an experimental analysis. The literature review identifies major types of data perturbations and groups them into broader categories. Based on these findings, a series of experiments is conducted in which the identified perturbation types are systematically simulated to analyze their effects on six widely used transformer models: BERT, RoBERTa, DeBERTa, XLNet, DistilBERT, and CANINE. The experiments are carried out using the CoNLL-2003 dataset as the evaluation basis.

The results reveal clear differences between perturbation categories and show that robustness strongly depends on model architecture. In particular, syntactic alterations lead to significant performance losses, whereas targeted exposure to perturbed training data considerably improves model stability. Furthermore, characteristic architecture-specific strengths are identified that can inform future model enhancements.

The study deepens the understanding of the relationships between data quality, model architecture, and robustness and provides a foundation for informed model selection in practice and the development of more resilient NER architectures.

Inhaltsverzeichnis

Abstract (Deutsch) III

Abstract (English) IV

Abkürzungsverzeichnis VII

Abbildungsverzeichnis VIII

Tabellenverzeichnis IX

1 Einleitung 1

1.1 Motivation und Problemstellung 1

1.2 Zielsetzung 2

1.3 Abgrenzung 3

1.4 Vorgehensweise 4

2 Grundlagen 5

2.1 Named Entity Recognition 5

2.2 Transformer-Architektur 8

2.3 Datenqualität und verwandte Konzepte 14

2.4 Evaluationsmetriken 17

3 Methodik 19

3.1 Systematic Literature Review 19

3.2 Laborexperiment 22

4 Systematic Literature Review 23

4.1 Vorbereitung 23

4.2 Durchführung 27

4.3 Ergebnisse 28

4.3.1 Identifizierte Datenstörungen 29

4.3.2 Methoden und Leistungseinfluss 33

4.3.3 Zusammenfassung 40

5 Experimente 42

5.1 Generelles Vorgehen 42

5.2 Auswahl Modelle 44

5.3 Auswahl Datensatz 47
5.4 Entwicklung Baseline Modell 47
5.5 Implementierung Qualitätsminderungsverfahren 50
6 Evaluation 59
6.1 Baseline 59
6.2 Störungen im Testdatensatz 60
6.3 Störungen im Test- und Trainingsdatensatz 66
6.4 Störungen im Trainingsdatensatz 72
6.5 Abgleich mit Literatur 75
7 Fazit 79
7.1 Kritische Reflexion 80
7.2 Ausblick 81
Literaturverzeichnis 82
Anhang 96

Abkürzungsverzeichnis

ACR	=	Automatic Speech Recognition
ASR	=	Attack Success Rate
BERT	=	Bidirectional encoder representations from transformers
CANINE	=	Character Architecture with No Tokenization in Encoding
CRFs	=	Conditional Random Fields
DeBERTa	=	Decoding-enhanced BERT with Disentangled Attention
GPU	=	Graphics Processing Unit
LLM	=	Large Language Model
LSTM	=	Long short-term memory
MLM	=	Masked Language Modeling
NLP	=	Natural Language Processing
NER	=	Named Entity Recognition
OCR	=	Optical Character Recognition
OOV	=	Out-of-Vocabulary
PLM	=	Pretrained Language Model
RoBERTa	=	Robustly Optimized BERT Approach

Abbildungsverzeichnis

Abbildung 1: Visualisierung Token-Annotation bei NER 6

Abbildung 2: Visualisierung Transformer-Architektur 9

Abbildung 3: Multi Head Self-Attention-Mechanismus 12

Abbildung 4: Zusammenspiel der Forschungsmethoden 21

Abbildung 5: Literatur-Selektionsprozess 28

Abbildung 6: Two-Stream Self-Attention-Mechanismus in XLNet 45

Abbildung 7: CANINE-Architektur 47

Abbildung 8: Mittlere F1-Score Veränderung auf Testdaten 60

Abbildung 9: Durchschnittliche Prozentuale Veränderung je Modell 64

Abbildung 10: Orthografische Leistung mit Entitätsschutz auf Testdatensatz 65

Abbildung 11: Semantische Leistung mit Entitätsschutz auf Testdatensatz 66

Abbildung 12: Modellleistung mit und ohne orthografische Störungen in Trainingsdaten 69

Abbildung 13: Modellleistung mit und ohne semantische Störungen in Trainingsdaten 70

Abbildung 14: Modellleistung mit und ohne syntaktische Störungen in Trainingsdaten 71

Abbildung 15: Leistungsverlust bei Label-bezogenen Störungen 74

Tabellenverzeichnis

Tabelle 1: Einschluss- und Ausschlusskriterien SRL 24

Tabelle 2: Relevanz Begriffe Pilotsuche 26

Tabelle 3: Identifizierte Datenstörungen 30

Tabelle 4: Übersicht implementierte orthografische Qualitätsminderungsmethoden 53

Tabelle 5: Übersicht implementierte syntaktische Qualitätsminderungsmethoden 55

Tabelle 6: Übersicht implementierte semantische Qualitätsminderungsmethoden 57

Tabelle 7: Übersicht implementierte Label-bezogene Qualitätsminderungsmethoden 58

Tabelle 8: Baseline Ergebnisse 59

Tabelle 9: Ergebnisse Datenqualitätsminderungen Testdatensatz 62

Tabelle 10: Ergebnisse Datenqualitätsminderungen Trainings- und Testdatensatz 67

Tabelle 11: Ergebnisse Datenqualitätsminderungen Trainingsdatensatz 73

1 Einleitung

Die automatische Erkennung benannter Entitäten, bekannt als Named Entity Recognition (NER), stellt eine zentrale Aufgabe im Bereich des Natural Language Processing (NLP) dar (J. Li et al., 2022). Ziel der NER ist es, Entitäten wie Personen, Organisationen, Orte oder Zeitangaben in unstrukturierten Texten zu identifizieren und zu kategorisieren. Diese Fähigkeit bildet die Grundlage zahlreicher Anwendungen wie der Informationsbeschaffung, der semantischen Suche oder der automatisierten Wissensextraktion (Rogers et al., 2020; Sajun et al., 2024; Yadav & Bethard, 2018).

Mit der zunehmenden Digitalisierung und der exponentiellen Zunahme unstrukturierter Textdaten in nahezu allen Branchen gewinnt die präzise Extraktion relevanter Information stetig an Bedeutung (Gartner, 2023). NER-Verfahren finden heute in einer Vielzahl praktischer Anwendungsfelder Verwendung, etwa in der biomedizinischen Forschung zur Erkennung medizinischer Fachbegriffe, in der juristischen Dokumentenanalyse zur Identifikation von Rechtsnormen oder in der Finanzbranche zur Extraktion von Unternehmensdaten (Rogers et al., 2020).

In den letzten Jahren haben insbesondere vortrainierte Sprachmodelle wie BERT (Devlin et al., 2019), RoBERTa (Y. Liu et al., 2019) oder XLNet (Z. Yang et al., 2019) zu erheblichen Fortschritten geführt. Durch ihr umfassendes Sprachverständnis und ihre Fähigkeit, kontextuelle Zusammenhänge zu erfassen, erreichen moderne NER-Systeme heute eine Genauigkeit, die in vielen Fällen mit der menschlichen Leistung vergleichbar ist (Akbik et al., 2018; Yadav & Bethard, 2018).

Der Lernprozess solcher Modelle erfolgt typischerweise in zwei Phasen. Zunächst werden sie auf umfangreichen allgemeinen Textsammlungen vortrainiert, um allgemeine Sprachstrukturen zu erfassen. Anschließend werden sie in einer Feinabstimmung (Fine-Tuning) auf kleinere, aufgabenspezifische oder domänenspezifische Datensätze angepasst. In dieser Phase lernen die Modelle, Entitäten in einem bestimmten Anwendungsgebiet wie der Medizinbranche, präzise zu erkennen (Devlin et al., 2019; Rogers et al., 2020).

1.1 Motivation und Problemstellung

Die Leistungsfähigkeit von NER-Modellen hängt dabei maßgeblich von der Qualität der Daten ab, mit denen sie trainiert und evaluiert werden (Belinkov & Bisk, 2017; J. Li et al., 2022). Insbesondere in der Phase des Fine Tunings, in der Modelle an spezifische Aufgaben oder Domänen angepasst werden, ist eine hohe Datenqualität entscheidend (Gururangan et al., 2020). Da NER-Modelle auf der Erfassung von sequenziellen und kontextuellen Zusammenhängen beruhen, wirken sich bereits geringfügige Abweichungen in der Datenqualität unmittelbar auf die Erkennung und Klassifikation von Entitäten aus (Bhadauria et al., 2024; Ebrahimi et al., 2018).

Fehlerhafte oder inkonsistente Daten wie Tippfehler, unvollständige Wörter, syntaktische Unregelmäßigkeiten oder fehlerhafte Annotationen können dazu führen, dass zuvor korrekt erkannte Entitäten nicht mehr identifiziert oder falsch zugeordnet werden (Náplava et al., 2021; Ribeiro et al., 2020).

In der praktischen Anwendung stammen die Daten für jedoch selten aus perfekt kuratierten, fehlerfreien Quellen. NER-Systeme werden häufig auf Texten eingesetzt, die aus fehleranfälligen Quellen wie automatischer Texterkennung (Optical Character Recognition), Spracherkennung (Automatic Speech Recognition) oder nutzergenerierten Inhalten, beispielsweise sozialen Medien oder Online-Foren, stammen (Derczynski et al., 2013; Hamdi et al., 2023; B. Wang et al., 2021). Solche Texte enthalten typischerweise Abweichungen in der Datenqualität, etwa durch Rechtschreibfehler, informelle Schreibweisen oder uneinheitliche Annotationen. Häufig wird hier auch von verrauschten Daten (englisch: noisy data) gesprochen (Belinkov & Bisk, 2017; Z. Ma et al., 2023).

Diese Unterschiede zwischen den realen und den in der Forschung häufig genutzten, bereinigten Datensätzen führen zu einer deutlichen Diskrepanz zwischen der Modellleistung unter Laborbedingungen und in realen Anwendungsszenarien. Studien zeigen, dass die Genauigkeit von NER-Modellen unter solchen Bedingungen um bis zu ein Drittel sinken kann (Bhadauria et al., 2024; Dirkson et al., 2021).

1.2 Zielsetzung

Trotz dieser Erkenntnisse besteht bislang ein begrenztes Verständnis darüber, welche Arten von Datenqualitätsproblemen die Robustheit von NER-Modellen in welchem Ausmaß beeinflussen. Vorhandene Studien verwenden häufig verrauschte Datensätze, ohne systematisch zu erfassen, welche Störungstypen existieren, wie sich diese im Einzelnen auf die Modellleistung auswirken (Bernier-Colborne & Langlais, 2020; Georg Heigold et al., 2018; Meng et al., 2021; Merdjanovska et al., 2024). Unklar ist zudem, ab welcher Intensität von Qualitätsminderungen ein signifikanter Leistungsabfall eintritt und ob sich dieser graduell oder sprunghaft vollzieht (Lin et al., 2021; Morris et al., 2020).

Darüber hinaus ist bislang nur unzureichend untersucht, ob sich die Auswirkungen einzelner Störungsarten über verschiedene Modellarchitekturen hinweg ähneln oder ob bestimmte Modelle empfindlicher auf bestimmte Qualitätsprobleme reagieren. Ebenso fehlt ein systematischer Vergleich, der untersucht, wie sich dieselben Störungen im Training und bei der Anwendung unterschiedlich auswirken und ob sich dabei wiederkehrende Muster erkennen lassen (Bhadauria et al., 2024; Náplava et al., 2021). Es gibt bereits verschiedene Ansätze, um Modelle robuster gegenüber verrauschten Daten zu machen, etwa durch die gezielte Integration künstlicher Störungen in das Training (Belinkov & Bisk, 2017; X. Jin et al., 2023).

Diese Arbeiten zeigen, dass eine gewisse Menge an Störungen positive Effekte auf die Stabilität haben kann. Jedoch bleibt offen, welche Arten von Störungen tatsächlich zur Robustheit beitragen, bis zu welchem Punkt diese Effekte anhalten, und ab wann zusätzliche Störungen die Modellleistung wieder verringern (X. Jin et al., 2023; Lin et al., 2021). Ein systematischer Vergleich zwischen Qualitätsminderungen in Trainings- und Testdaten, der diese Fragen empirisch beleuchtet, steht bislang aus (Lin et al., 2021; Moradi & Samwald, 2021).

Vor diesem Hintergrund untersucht die vorliegende Arbeit, wie sich verschiedene Arten und Intensitäten von Datenqualitätsproblemen auf die Robustheit von NER-Modellen auswirken, in welchen Bereichen kritische Kipppunkte erreicht werden und ob sich über verschiedene Modellarchitekturen hinweg wiederkehrende Muster in der Fehleranfälligkeit erkennen lassen. Daraus ergeben sich die zentralen Forschungsfragen:

- **FF1:** Welche Arten von Datenstörungen treten in Datensätzen für Named Entity Recognition auf?
- **FF2:** Wie wirken sich unterschiedliche Typen und Intensitäten von Datenqualitätsproblemen auf die Leistungsfähigkeit Transformer-basierter NER-Modelle aus?
- **FF3:** Welchen Einfluss haben identische Datenqualitätsprobleme in Trainings- und Testdaten auf die Leistung der Modelle?
- **FF4:** Wie unterscheiden sich verschiedene Transformer-basierte Modellarchitekturen in ihrer Robustheit gegenüber den definierten Störungen?

1.3 Abgrenzung

Um den Umfang der Arbeit klar zu begrenzen, werden bestimmte Aspekte ausgeschlossen. Die Untersuchung konzentriert sich ausschließlich auf monolinguale Szenarien, also Datensätze derselben Sprache. Mehrsprachige oder interlinguale Ansätze sowie die damit verbundenen zusätzlichen Herausforderungen, wie Unterschiede in Grammatik, Morphologie oder Schrift, werden nicht betrachtet (Jehangir et al., 2023). Ebenso erfolgt eine bewusste Abgrenzung von der Datenquantität: Die Arbeit fokussiert auf Aspekte der Datenqualität, weshalb Szenarien mit stark begrenzter Datenverfügbarkeit (Low-Resource) nicht gesondert evaluiert werden (Tang et al., 2024).

Darüber hinaus befasst sich die Arbeit nicht mit der Entwicklung neuer Modellarchitekturen oder Trainingsverfahren. Im Mittelpunkt steht die Analyse bestehender Transformer-basierter Modelle und deren Verhalten unter verschiedenen Bedingungen reduzierter Datenqualität. Die Untersuchung beschränkt sich bewusst auf diese Modellklasse, da Transformer derzeit den Stand der Technik in NER darstellen. Einzelne Arten von Datenqualitätsproblemen könnten bei früheren Modellarchitekturen abweichende Effekte hervorrufen, deren Analyse jedoch nicht Gegenstand dieser Arbeit ist.

1.4 Vorgehensweise

Die Arbeit gliedert sich in sieben Kapitel. Kapitel 2 stellt die theoretischen Grundlagen bereit und erläutert die wesentlichen Konzepte der Arbeit. Dazu gehören die Grundlagen der Named Entity Recognition, die Funktionsweise Transformer-basierter Sprachmodelle, Begriffliche Abgrenzungen im Bereich Dataqualität sowie die Evaluationsmetriken, die zur Beurteilung der Modellleistung verwendet werden. Darauf aufbauend skizziert Kapitel 3 das methodische Forschungsdesign der Arbeit.

Kapitel 4 widmet sich der ersten Forschungsfrage (FF1) und enthält ein systematisches Literaturreview, in dem relevante Arten von Datenstörungen sowie deren in der Forschung bislang beobachtete Effekte auf die Modellleistung identifiziert werden Auf Grundlage dieser Ergebnisse wird in Kapitel 5 ein experimentelles Untersuchungsdesign zur Beantwortung der Forschungsfragen FF2 bis FF4 entwickelt. Zunächst werden die genutzten Datensätze und deren Vorverarbeitung beschrieben. Anschließend erfolgt die Entwicklung eines Baseline-Modells und die Implementierung von Verfahren zur gezielten Simulation von Qualitätsminderungen.

Kapitel 6 befasst sich mit der Auswertung und Analyse der Ergebnisse. Hier werden die Auswirkungen der verschiedenen Störungsarten auf die Leistungsfähigkeit der Modelle untersucht, Schwellenwerte und kritische Kipppunkte identifiziert und Muster in der Fehleranfälligkeit der Modelle herausgearbeitet. Darüber hinaus werden Unterschiede zwischen den Modellarchitekturen und den jeweiligen Störungstypen diskutiert.

Kapitel 7 schließt die Arbeit mit einer Zusammenfassung der zentralen Ergebnisse, einer kritischen Einordnung in den bestehenden Forschungskontext sowie einem Ausblick auf zukünftige Forschungsperspektiven ab.

2 Grundlagen

Dieses Kapitel ordnet die für das Verständnis der Arbeit relevanten Konzepte ein und definiert zentrale Begriffe. Dazu werden die wesentlichen Prinzipien der Named Entity Recognition, die Funktionsweise Transformer-basierter Sprachmodelle sowie grundlegende Begriffe und Dimensionen der Datenqualität erläutert. Abschließend werden die Evaluationsmetriken vorgestellt, mit denen die Leistungsfähigkeit der Modelle im weiteren Verlauf der Arbeit bewertet wird.

2.1 Named Entity Recognition

Named Entity Recognition (NER) bezeichnet die automatische Erkennung und Klassifizierung benannter Entitäten in natürlichsprachlichen Texten. Dazu gehören in der Regel Eigennamen von Personen, Bezeichnungen von Organisationen, geographische Orte sowie Zeitangaben, Ereignisse oder fachspezifische Termini. Als zentrales Verfahren der Informationsextraktion bildet NER die Grundlage zahlreicher weiterführender Methoden der Sprachverarbeitung. Dazu zählen unter anderem die Extraktion von Beziehungen zur Identifikation semantischer Zusammenhänge zwischen Entitäten, die Erstellung von Wissensgraphen, die semantische Suche sowie Systeme zur automatischen Fragebeantwortung und Textzusammenfassung (Jurafsky & Martin, 2025; Yadav & Bethard, 2018).

Aus technischer Perspektive wird NER als Aufgabe der Sequenzklassifikation betrachtet. Ein Text wird dabei in kleinere Einheiten zerlegt, die als Tokens bezeichnet werden. Tokens stellen die kleinsten bedeutungstragenden Elemente eines Textes dar und können aus einzelnen Wörtern, Satzzeichen oder Wortbestandteilen bestehen (J. Li et al., 2022; Nadeau & Sekine, 2009). Das Ziel besteht darin, aufeinanderfolgende Tokens zu identifizieren, die gemeinsam eine Entität bilden, und diese einer sogenannten semantischen Kategorie zuzuordnen. Eine semantische Kategorie beschreibt die Bedeutungsklasse, der eine Entität zugeordnet wird, und gibt damit an, was die erkannte Einheit im inhaltlichen Kontext repräsentiert. So werden beispielsweise Namen von Personen der Kategorie PERSON, Bezeichnungen von Unternehmen oder Institutionen der Kategorie ORGANIZATION und Ortsnamen der Kategorie LOCATION zugeordnet (Yadav & Bethard, 2018). Abhängig von der jeweiligen Anwendungsdomäne können jedoch auch andere Kategorien relevant sein, etwa MUTATION oder GENE in medizinischen Texten. Solche Kategorien bilden die Grundlage für die maschinelle Interpretation von Textinhalten, da sie unstrukturierte sprachliche Daten in strukturierte, maschinenlesbare Information überführen.

Ein Beispielsatz könnte lauten: „Am 12. September 2025 traf sich Bundeskanzler Friedrich Merz in Berlin mit Vertretern der Europäischen Kommission.“. In diesem Satz sollte ein NER-

Modell die Entitäten Friedrich Merz (PERSON), Berlin (LOCATION) und Europäische Kommission (ORGANIZATION) erkennen.

Zur eindeutigen Kennzeichnung der Grenzen einer Entität wird häufig das BIO-Schema verwendet. Dabei steht das Label B für den Beginn einer Entität, I für ein weiteres Element innerhalb derselben und O für Tokens, die keiner Entität angehören (Ramshaw & Marcus, 1999). So würde etwa der Ausdruck „Technische Universität Berlin“ mit „Technische B-ORG“, „Universität I-ORG“ und „Berlin I-ORG“ markiert werden. Abbildung 1 zeigt exemplarisch, wie das BIO-Schema zur Annotation von Entitäten in einem Satz angewendet wird.

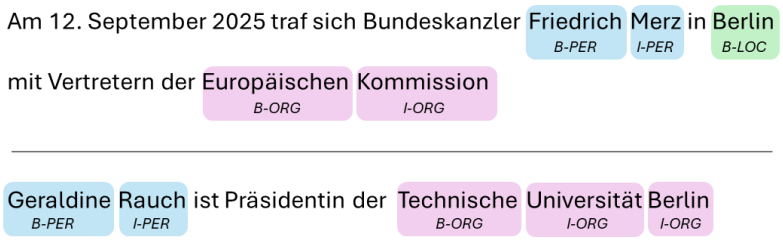


Abbildung 1: Visualisierung Token-Annotation bei NER- Die Abbildung zeigt, wie Tokens innerhalb eines Satzes entsprechend ihrer semantischen Kategorie (z. B. Person, Organisation, Ort) mit den Labels B (Beginn), I (innerhalb) und O (außerhalb) markiert werden (Eigene Darstellung).

Das Beispiel verdeutlicht zugleich, dass die korrekte Klassifizierung von Berlin kontextabhängig ist. Während es im ersten Satz als geografischer Ort (LOCATION) zu interpretieren ist, wird es im zweiten Beispiel als Teil einer Organisation (ORGANIZATION) verstanden. Damit zeigt sich, dass NER-Modelle nicht nur einzelne Wörter erkennen, sondern deren Bedeutung stets im Kontext des gesamten Satzes interpretieren müssen (J. Li et al., 2022).

Die Fähigkeit, sprachliche Kontexte angemessen zu berücksichtigen, war dabei eine der zentralen Herausforderungen in der historischen Entwicklung von NER-Systemen. Die methodischen Ansätze lassen sich im Wesentlichen in drei technologische Phasen unterteilen (Jehangir et al., 2023; Lample et al., 2016; Nadeau & Sekine, 2009).

Frühe NER-Systeme basierten auf regelbasierten Verfahren, bei denen linguistische Regeln, reguläre Ausdrücke und vordefinierte Listen bekannter Namen, sogenannte Gazetteers, verwendet wurden (Hobbs et al., 1993; Wacholder et al., 1997). Diese Systeme erzielten in begrenzten Anwendungsdomänen teilweise hohe Genauigkeit, waren jedoch kaum auf neue Textsorten übertragbar und reagierten sensitiv auf sprachliche Variationen. So konnte ein System etwa den Ausdruck „Deutscher Bundestag“ korrekt erkennen, während Varianten wie „im Deutschen Bundestag“ oder „Bundestag in Berlin“ häufig nicht identifiziert wurden.

Mit dem Aufkommen statistischer Lernverfahren in den 2000er Jahren verlagerte sich der Schwerpunkt auf datenbasierte Modelle wie Hidden Markov Models, Maximum Entropy Markov Models und insbesondere Conditional Random Fields (Lafferty et al., 2001; McCallum et al., 2000).

Diese Modelle nutzten Wahrscheinlichkeiten, um Abhängigkeiten zwischen benachbarten Tokens zu erfassen, und konnten dadurch konsistente Labelsequenzen erzeugen. Durch die Einbeziehung von Merkmalen wie Wortform, Groß- und Kleinschreibung oder Kontextfenstern stieg die Leistungsfähigkeit deutlich an (Lafferty et al., 2001). Der CoNLL-2003-Datensatz (Tjong Kim Sang & Meulder, 2003) etablierte sich in dieser Zeit als Standard zur Bewertung solcher Systeme.

Mit dem Einzug neuronaler Netze begann die dritte Entwicklungsphase (Bengio et al., 2003; Lample et al., 2016). Neuronale Netze sind Modelle des maschinellen Lernens, die aus mehreren Schichten künstlicher Neuronen bestehen und darauf ausgelegt sind, komplexe Muster und nichtlineare Zusammenhänge in Daten zu erkennen (I. Goodfellow et al., 2016). Rekurrente Architekturen wie Long Short Term Memory (LSTM) Netzwerke ermöglichten es, längere Abhängigkeiten in Texten zu erfassen und kontextuelle Informationen umfassender zu berücksichtigen. In Kombination mit Conditional Random Fields entstanden Modelle, die sowohl syntaktische als auch semantische Merkmale nutzen konnten (Hochreiter & Schmidhuber, 1997; Z. Huang et al., 2015).

Einen grundlegenden Wendepunkt in der Entwicklung der NER-Systeme markierte jedoch die Einführung der Transformer-Architektur (Vaswani et al., 2017). Im Gegensatz zu rekurrenten Modellen, die Texte sequenziell verarbeiten, beruhen Transformer auf dem Self-Attention-Mechanismus, der jedes Token in Beziehung zu allen anderen Tokens einer Eingabesequenz bewertet. Dadurch wird die Abhängigkeitserfassung über beliebige Distanzen hinweg möglich, ohne dass Informationen über viele Schritte hinweg weitergereicht werden müssen.

Neben der verbesserten Kontextmodellierung ermöglichte die parallele Verarbeitung von Sequenzen eine erhebliche Beschleunigung des Trainings. Die Transformer-Architektur bildete damit die methodische Grundlage für eine neue Generation leistungsfähiger Sprachmodelle (Rogers et al., 2020; Vaswani et al., 2017).

Auf dieser Basis wurde 2018 das Modell BERT entwickelt, das für „Bidirectional Encoder Representations from Transformers“ steht und einen Meilenstein für viele NLP-Aufgaben darstellt (Devlin et al., 2019). BERT wird auf großen Mengen unannotierter Texte vortrainiert, wobei einzelne Tokens maskiert und vom Modell anhand ihres Kontexts rekonstruiert werden. Durch die bidirektionale Kontextbetrachtung entstehen besonders tiefgehende semantische Repräsentationen der Wörter. Nach dem anschließenden Finetuning kann das Modell spezifische Aufgaben wie NER mit hoher Genauigkeit lösen (Devlin et al., 2019).

BERT entwickelte sich zu einem Quasi-Standard, auf dessen Grundlage zahlreiche Weiterentwicklungen wie ALBERT (Lan et al., 2020), BioBERT (Lee et al., 2020), DistilBERT (Sanh et al., 2019) oder RoBERTa (Y. Liu et al., 2019) entstanden. Diese optimierten meist verschiedene Aspekte der Architektur, des Trainingsprozesses oder spezialisierten sich auf einzelne Domänen.

Trotz dieser methodischen Fortschritte stellt die Robustheit von NER-Modellen weiterhin ein zentrales Forschungsfeld dar. In realen Anwendungsszenarien reagieren Modelle oft empfindlich auf verrauschte oder domänenspezifisch abweichende Daten, was ihre Übertragbarkeit und Zuverlässigkeit einschränkt (Dirkson et al., 2021; Náplava et al., 2021). Damit bleibt die Entwicklung robuster Modelle, die auch unter unterschiedlichen Datenqualitäten und Anwendungskontexten stabile Ergebnisse liefern, eine wesentliche Herausforderung der aktuellen Forschung.

2.2 Transformer-Architektur

Transformer-Modelle bilden derzeit das Fundament moderner Sprachverarbeitungssysteme. Sie haben sich aufgrund ihrer hohen Leistungsfähigkeit und Parallelisierbarkeit als Standardarchitektur im Bereich des Natural Language Processing (NLP) etabliert (J. Li et al., 2022). Die Architektur wurde erstmals von Vaswani et al. (2017) vorgestellt. Sie basiert auf neuronalen Netzwerken, die ausschließlich den sogenannten Attention-Mechanismus zur Modellierung von Abhängigkeiten zwischen Tokens verwenden. Im Gegensatz zu rekurrenten oder konvolutionalen Netzwerken verarbeitet der Transformer alle Positionen einer Eingabesequenz parallel und kann dadurch Informationen über beliebige Distanzen hinweg effizient integrieren.

Die Architektur folgt einer Encoder-Decoder-Struktur, die in Abbildung 2 auf der nächsten Seite dargestellt ist. Beide Komponenten bestehen aus mehreren identisch aufgebauten Schichten, die Self-Attention mit nachgeschalteten Feed-Forward-Netzwerken kombinieren, welche durch nichtlineare Aktivierungsfunktionen komplexe Muster in den Repräsentationen erfassen. Während der Encoder (linke Seite der Abbildung) eine Eingabesequenz in eine dichte, kontextuelle Repräsentation überführt, generiert der Decoder (rechte Seite) auf dieser Basis eine Ausgabesequenz (Vaswani et al., 2017).

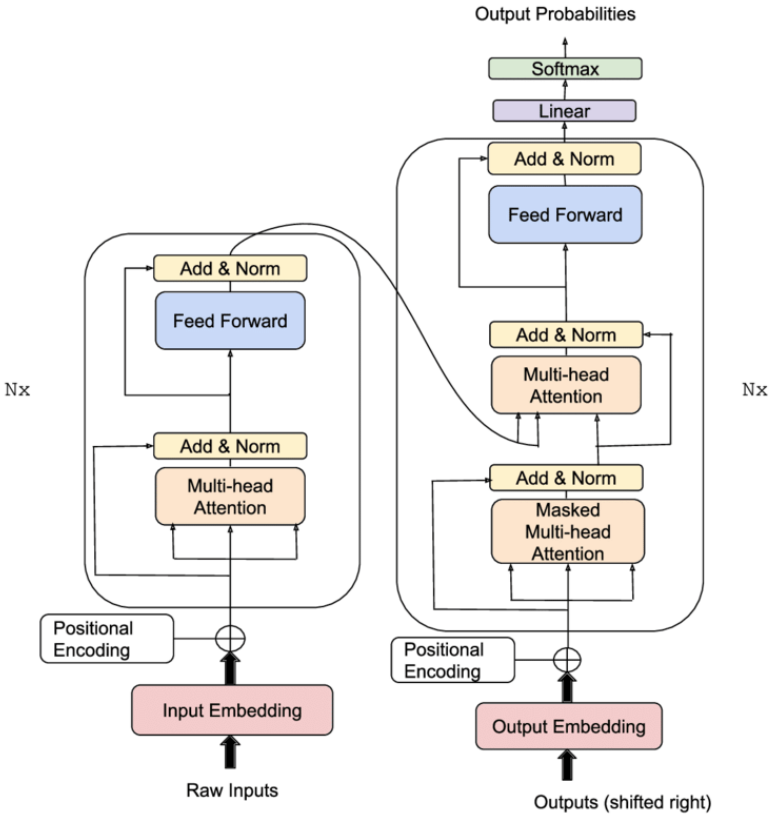


Abbildung 2: Visualisierung Transformer-Architektur mit Encoder-Decoder-Struktur nach (Vaswani et al., 2017). Mehrere gestapelte Encoder- und Decoder-Blöcke verarbeiten die Eingabe mithilfe von Attention- und Feed-Forward-Komponenten, um kontextabhängige Repräsentationen zu erzeugen. Bild aus (Gaser, 2022)

Eingabe und Embeddings

Wie in Abbildung 2 dargestellt, erhält der Encoder im unteren Bereich zunächst den Raw Input, also den vom Menschen lesbaren Rohtext. Dieser wird vor dem Eintritt in die Modellarchitektur durch den Tokenizer in kleinere Einheiten (Tokens) zerlegt, beispielsweise Wörter, Wortbestandteile oder Zeichen, und anschließend in eindeutige numerische IDs übersetzt. Der Tokenizer ist kein expliziter Bestandteil der in Abbildung 2 dargestellten Architektur, sondern eine vorgelagerte Komponente der Datenvorverarbeitung.

Der Tokenisierungsprozess ist entscheidend, da er festlegt, wie Text segmentiert und vom Modell interpretiert wird. Moderne Tokenizer wie WordPiece, Byte Pair Encoding oder Unigram zerlegen auch unbekannte oder seltene Wörter in bekannte Bestandteile (Jurafsky & Martin, 2025). So wird etwa „Datenanalyse“ in „Daten“ und „analyse“ aufgeteilt, sodass das Modell die Bedeutung aus den bekannten Teilen erschließen kann. Dadurch bleibt der Wortschatz flexibel und neue Begriffe können zuverlässig verarbeitet werden.

Die resultierende tokenisierte Eingabesequenz bildet die Grundlage für den ersten Modellschritt, in dem die Token-IDs in kontinuierliche Vektoren überführt werden (Rogers et al., 2020; Vaswani et al., 2017).

Embeddings bezeichnen die Abbildung dieser diskreten Token-IDs in kontinuierliche Vektoren eines mehrdimensionalen Raums. Sie ermöglichen es dem Modell, sprachliche Bedeutung numerisch darzustellen, indem ähnliche Wörter durch ähnliche Vektoren repräsentiert werden. Damit stellen sie die Brücke zwischen symbolischer Sprache und der numerischen Verarbeitung im neuronalen Netz dar. Die so entstehenden Token-Embeddings bilden den Ausgangspunkt der weiteren Verarbeitung im Transformer (Pennington et al., 2014; Rogers et al., 2020).

Bereits in früheren neuronalen Ansätzen, etwa in rekurrenten Architekturen wie LSTMs, wurden Wörter in dichte Vektoren eingebettet, um semantische Ähnlichkeiten numerisch zu erfassen (Bengio et al., 2003). Dabei handelte es sich um statische Wortrepräsentationen, wie sie beispielsweise in GloVe (Pennington et al., 2014) oder Word2Vec (Mikolov et al., 2013) verwendet werden: Jedes Wort erhält dort einen festen Vektor, unabhängig vom jeweiligen Kontext. So wird das Wort Bank in allen Zusammenhängen identisch repräsentiert, gleichgültig, ob es eine Sitzgelegenheit oder ein Finanzinstitut bezeichnete.

Für jedes durch den Tokenizer erzeugte Token wird in einer trainierbaren Embedding-Schicht ein kontinuierlicher Vektor erzeugt. Diese Schicht ist Bestandteil der Modellarchitektur und wird während des Pretrainings gemeinsam mit dem gesamten Netzwerk optimiert. Die Embeddings sind somit modellspezifisch und zugleich abhängig vom verwendeten Tokenizer, da beide gemeinsam bestimmen, wie Text in den semantischen Raum des Modells abgebildet wird (Devlin et al., 2019; Vaswani et al., 2017). Dieser Schritt ist in Abbildung 2 links unten als Input Embedding dargestellt.

Da Transformer, im Gegensatz zu rekurrenten Modellen, keine inhärente Reihenfolge zwischen Tokens kennt, wird die Positionsinformation durch Positional Embeddings ergänzt. Diese Vektoren besitzen dieselbe Dimension wie die Token-Embeddings und werden additiv hinzugefügt, um eine positionssensitive Repräsentation zu erzeugen (Vaswani et al., 2017). In darauf aufbauenden Modellen wie BERT werden zusätzlich Segment-Embeddings eingeführt, um verschiedene Satzteile voneinander zu unterscheiden (Devlin et al., 2019). Die Kombination der verschiedenen Embeddings bildet die vollständige Eingabe für die erste Encoder-Schicht.

Encoder und Self-Attention

Wie in Abbildung 2 zu erkennen ist, besteht der Encoder aus mehreren identisch aufgebauten Schichten, die stapelartig angeordnet sind. Jede Schicht verfolgt das Ziel, die Repräsentationen der Eingabesequenz schrittweise zu verfeinern und semantisch reichhaltiger zu machen. Die Verarbeitung innerhalb einer solchen Schicht gliedert sich in drei Hauptkomponenten: Self-Attention, Feed-Forward-Netzwerk und Add & Norm (Rogers et al., 2020; Vaswani et al., 2017).

Im Zentrum der Transformer-Architektur steht der Self-Attention-Mechanismus, der es dem Modell ermöglicht, für jedes Token einer Eingabesequenz zu bestimmen, welche anderen Tokens für dessen Bedeutung relevant sind. Jedes Token wird dafür durch drei Vektoren beschrieben: **Query (Q)**, **Key (K)** und **Value (V)**. Diese Vektoren dienen dazu, die Beziehungen zwischen Tokens innerhalb der Sequenz zu berechnen. Dabei repräsentiert der Query-Vektor, wonach das aktuelle Token sucht, der Key-Vektor, welche Informationen ein Token anderen zur Verfügung stellt, und der Value-Vektor, welche Information letztlich weitergegeben wird.

Die Stärke der Abhängigkeit zwischen zwei Tokens ergibt sich aus dem Skalarprodukt zwischen dem Query-Vektor eines Tokens und den Key-Vektoren aller anderen Tokens. Dieses Ergebnis wird mithilfe einer Softmax-Funktion normalisiert, wodurch Aufmerksamkeitsgewichte entstehen, die angeben, wie viel Aufmerksamkeit ein Token den anderen innerhalb derselben Sequenz widmet. Anschließend werden die Value-Vektoren gemäß diesen Gewichten kombiniert. Dieses Verfahren wird als Scaled Dot-Product Attention bezeichnet und kann mathematisch wie folgt beschrieben werden (Jurafsky & Martin, 2025; Vaswani et al., 2017):

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Hierbei sind:

- Q: Querymatrix, welche die Abfrageinformationen enthält (Dimension: n x d_k)
- K: Key-Matrix, die die Schlüsselrepräsentationen für jedes Eingabeelement enthält (Dimension: n x d_k)
- V: Matrix der Werte, die die tatsächlichen Informationen enthalten, die an die nächste Schicht weitergegeben werden (Dimension: n x d_v)
- n: Anzahl der Token in einer Sequenz
- d_k: Dimension der Query- und Key Vektoren
- d_v: Dimension der Value-Vektoren

Der Faktor $\sqrt{d_k}$ dient der numerischen Stabilisierung, da große Werte im Skalarprodukt sonst zu extremen Softmax-Ergebnissen führen könnten.

Wie in Abbildung 3 dargestellt, erfolgt die Berechnung der Aufmerksamkeit schrittweise: Zunächst werden die Query-, Key- und Value-Matrizen durch Matrixmultiplikationen gebildet (MatMul), anschließend skaliert (Scale), optional maskiert (Mask), normalisiert (Softmax) und schließlich wieder mit den Value-Vektoren kombiniert (Vaswani et al., 2017).

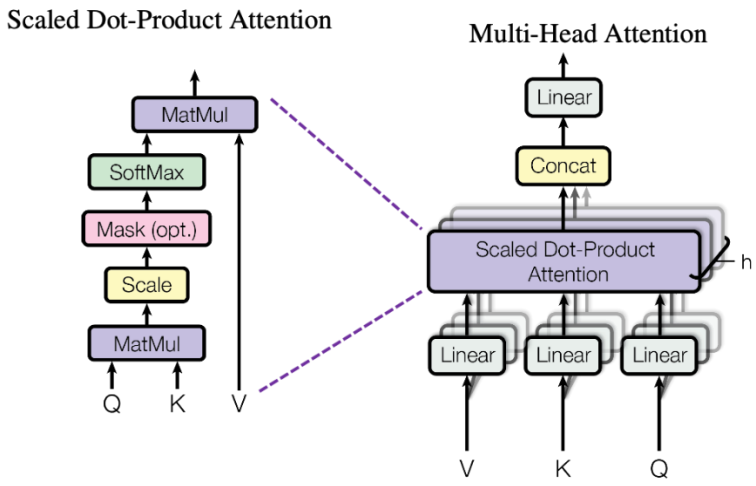


Abbildung 3: Multi Head Self-Attention-Mechanismus- Darstellung des Multi-Head Self-Attention-Mechanismus, bei dem mehrere parallele Self-Attention-Blöcke kontextabhängige Repräsentationen einer Sequenz erzeugen und anschließend zusammengeführt werden. Konzept und Abbildung aus (Vaswani et al., 2017)

Da semantische Beziehungen in Sprache vielfältig sind, etwa syntaktische, thematische oder anaphorische Abhängigkeiten, wird diese Berechnung mehrfach parallel ausgeführt. Dieser Mechanismus wird als Multi-Head Attention bezeichnet, was in Abbildung 3 auf der rechten Seite dargestellt ist. Jeder Head verwendet eigene Gewichtungen für Q, K und V und lernt dadurch, unterschiedliche Aspekte der Sequenz zu erfassen. Die Ergebnisse aller Attention-Heads werden konkateniert und über eine lineare Projektion (Linear + Concat) zusammengeführt (Jurafsky & Martin, 2025; Vaswani et al., 2017).

Feed-Forward-Netzwerk und Add & Norm

Nach der Berechnung der Self-Attention wird die Ausgabe durch ein Feed-Forward-Netzwerk weiterverarbeitet, das auf jedes Token einzeln angewendet wird. In Abbildung 2 ist dieser Schritt im blauen Block oberhalb der Attention-Ebene dargestellt. Das Netzwerk besteht aus zwei linearen Transformationen mit einer nichtlinearen Aktivierungsfunktion und ermöglicht es, komplexe Muster in den Daten zu lernen, die über reine Abhängigkeitsbeziehungen zwischen Tokens hinausgehen (Rogers et al., 2020).

Wie bereits in Abbildung 2 erkennbar, folgt sowohl auf den Self-Attention-Mechanismus als auch auf das Feed-Forward-Netzwerk ein sogenannter Add & Norm-Block.

Die Komponente Add stellt eine Residualverbindung dar, die die Eingabe einer Schicht unverändert zur Ausgabe addiert. Dadurch wird der Verlust wichtiger Informationen vermieden und das Training tiefer Netzwerke stabilisiert. Norm steht für Layer Normalization, welche die Werte innerhalb einer Schicht skaliert und verschiebt, um numerische Stabilität und gleichmäßige Gradientenflüsse zu gewährleisten (Vaswani et al., 2017).

Diese Residualverbindungen helfen zudem, das Problem der „vanishing gradients“ zu reduzieren, das bei tiefen neuronalen Netzen auftreten kann. Dabei werden die Gradienten der Verlustfunktion in früheren Schichten sehr klein, was das Lernen stark verlangsamt (Lecun et al., 1998). Durch die Kombination aus Attention, Feed-Forward-Netzwerken und Add & Norm-Blöcken entstehen mit jeder Schicht zunehmend abstrahierte und kontextualisierte Repräsentationen, die dem Decoder als Eingabe dienen.

Decoder

Der Decoder nutzt die vom Encoder erzeugten Repräsentationen, um darauf basierend eine neue Sequenz zu generieren. Die Ausgabe erfolgt autoregressiv, das heißt, jedes Token wird schrittweise erzeugt und hängt sowohl von den zuvor generierten Tokens als auch von den Encoder-Ausgaben ab. Neben einem eigenen Self-Attention-Mechanismus enthält der Decoder eine Cross-Attention-Komponente, die es ihm ermöglicht, gezielt auf relevante Informationen des Encoders zuzugreifen. Diese Architektur ist besonders für Aufgaben wie maschinelle Übersetzung oder Textgenerierung geeignet, bei denen eine sprachlich kohärente Ausgabe auf Basis einer Eingabe erzeugt werden soll (Sajun et al., 2024; Wacholder et al., 1997).Für die vorliegende Arbeit, die sich auf Named Entity Recognition konzentriert, ist die Decoder-Komponente jedoch nicht relevant, da keine neue Textsequenz generiert, sondern ein bestehender Text analysiert wird. Wenn, wie bei BERT, der Decoder Block nicht genutzt wird, spricht man von Encoder-Only-Modellen (Sajun et al., 2024).

Trainingsprozess

Modelle auf Basis der Transformer-Architektur, wie etwa BERT, werden in der Regel in zwei Schritten trainiert: einer Vortrainingsphase (Pretraining) und einer anschließenden Anpassungsphase (Finetuning). Solche Modelle werden häufig als Pretrained Language Models (PLMs) bezeichnet, da sie zunächst ein allgemeines Sprachverständnis aus großen Mengen unannotierter Texte erwerben, das anschließend für spezifische Aufgaben weiterverwendet werden kann (Devlin et al., 2019; Rogers et al., 2020).

Während des Pretrainings lernt das Modell grundlegende sprachliche Muster, ohne dass manuell gelabelte Daten erforderlich sind. Dies geschieht typischerweise über zwei Aufgaben: Beim Masked Language Modeling (MLM) werden zufällig ausgewählte Tokens einer Eingabesequenz maskiert, und das Modell muss anhand des umgebenden Kontexts vorhersagen, welche Wörter an den verdeckten Positionen stehen. Auf diese Weise lernt das Modell, Abhängigkeiten und Bedeutungsbeziehungen zwischen Wörtern kontextsensitiv zu erfassen (Devlin et al., 2019; Sanh et al., 2019).

Ergänzend dazu wird häufig die Aufgabe der Next Sentence Prediction (NSP) eingesetzt. Dabei soll das Modell entscheiden, ob zwei Sätze tatsächlich aufeinander folgen oder ob sie aus unterschiedlichen Kontexten stammen. Diese zweite Trainingsaufgabe fördert das Verständnis größerer semantischer Zusammenhänge (Devlin et al., 2019).

In der anschließenden Finetuning-Phase wird das vortrainierte Modell auf eine konkrete Zielanwendung, wie etwa Named Entity Recognition, spezialisiert. Dafür wird eine zusätzliche Klassifikationsschicht auf die Encoder-Ausgaben gesetzt, und das gesamte Modell wird auf einem kleineren, annotierten Datensatz weitertrainiert. Da das Modell bereits über ein umfassendes Sprachverständnis verfügt, genügen oft relativ wenige Trainingsbeispiele, um auch auf neuen Aufgaben und Domänen hohe Leistungsfähigkeit zu erreichen (Rogers et al., 2020). Aufgrund der geringen Datenmenge reagiert das Modell aber auch sehr empfindlich auf unzureichende Datenqualität (Náplava et al., 2021; Ribeiro et al., 2020).

2.3 Datenqualität und verwandte Konzepte

Die Frage, wie sich die Qualität von Daten auf die Stabilität und Leistungsfähigkeit maschineller Lernverfahren auswirkt, ist Gegenstand einer breiten interdisziplinären Forschung. Über die Zeit haben sich hierzu verschiedene Konzepte und Begrifflichkeiten entwickelt, die Aspekte wie Datenqualität, Störanfälligkeit und Widerstandsfähigkeit von Modellen beschreiben. Ihre Bedeutung und Verwendung ist jedoch nicht in allen Bereichen deckungsgleich, und insbesondere in der Sprachverarbeitung werden viele dieser Begriffe in unterschiedlicher Weise interpretiert oder genutzt (Manning, 2022). Im Folgenden werden die zentralen Konzepte erläutert, die für das Verständnis von Datenqualität und Robustheit im maschinellen Lernen relevant sind:

Datenqualität

Der Begriff der Datenqualität hat seinen Ursprung im Informationsmanagement und in der Wirtschaftsinformatik, wo er das Maß beschreibt, in dem Daten für einen bestimmten Zweck geeignet sind. Die sogenannte „fitness for use“ kann dabei in verschiedene Dimensionen unterteilt werden: Accuracy (Korrektheit), Completeness (Vollständigkeit), Consistency (Einheitlichkeit) und Relevance (Zweckmäßigkeit) (Batini et al., 2009; R. Y. Wang & Strong, 1996).

Diese Dimensionen dienen der Bewertung, inwieweit Daten verlässlich, vollständig und konsistent genug sind, um fundierte Analysen und Entscheidungen zu ermöglichen. Mit der zunehmenden Bedeutung datengetriebener Verfahren wurde das Konzept auf das maschinelle Lernen übertragen. Hier beschreibt Datenqualität nicht nur die formale Korrektheit oder Vollständigkeit der Daten, sondern ihre Eignung, den Lernprozess eines Modells zu unterstützen.

Sie bestimmt, ob die in den Daten enthaltenen Muster stabil genug sind, um generalisierbare Zusammenhänge zu erfassen, und wie zuverlässig ein Modell auf neue Eingaben reagieren kann (Bhadauria et al., 2024; Gong et al., 2023).

Datenqualität ist somit keine isolierte Eigenschaft einzelner Datenpunkte, sondern das Ergebnis der Wechselwirkung zwischen Datengrundlage, Modell und Lernaufgabe. Eine hohe Qualität bedeutet, dass Daten hinreichend präzise, konsistent und repräsentativ sind, um stabile Lernsignale zu erzeugen. Umgekehrt kann eine eingeschränkte Qualität dazu führen, dass Modelle fehlerhafte Korrelationen erlernen oder sensibel auf geringfügige Veränderungen in den Eingaben reagieren (Gong et al., 2023; Jain et al., 2020).

Robustheit (Robustness)

Der Begriff Robustheit stammt aus der Statistik und der Ingenieurwissenschaft, wo er die Widerstandsfähigkeit eines Systems gegenüber Störungen beschreibt. Im maschinellen Lernen bezeichnet Robustheit die Fähigkeit eines Modells, seine Leistung auch dann beizubehalten, wenn sich Eingabedaten verändern oder deren Qualität abnimmt (Madry et al., 2017; X. Wang et al., 2022). Robustheit ist damit ein Maß für die Stabilität von Lernverfahren gegenüber Variation, Unsicherheit oder Störungen in den Daten. Ein Mangel an Robustheit wird häufig als Brittleness bezeichnet, also die Neigung eines Modells, bereits bei geringfügigen Abweichungen deutlich an Genauigkeit zu verlieren (Hendrycks & Dietterich, 2019).

Rauschen (Noise)

Noise beschreibt unerwünschte oder zufällige Störungen, die die Informationsstruktur von Daten verändern oder verzerren. Der Begriff stammt ursprünglich aus der Signalverarbeitung und wird im maschinellen Lernen zur Bezeichnung unkontrollierter Abweichungen verwendet, die die Fähigkeit eines Modells beeinträchtigen können, zugrunde liegende Muster zu erkennen (Belinkov & Bisk, 2017).

In der Literatur wird häufig zwischen verschiedenen Formen von Noise unterschieden. Text Noise bezieht sich auf Abweichungen in den Eingabedaten, während Label Noise fehlerhafte oder uneinheitliche Zielvariablen beschreibt (Al Sharou et al., 2021; Merdjanovska et al., 2024).

Teilweise wird auch der Begriff Data Corruption synonym verwendet, in anderen Fällen bezieht er sich auf systematischere oder schwerwiegendere Veränderungen, die den Inhalt oder die Struktur der Daten deutlich verändern (Hendrycks & Dietterich, 2019).

Störung (Perturbation)

Eine Perturbation ist eine gezielt herbeigeführte, kontrollierte Veränderung von Daten, die dazu dient, die Sensitivität eines Modells gegenüber Abweichungen zu untersuchen Perturbationen werden in experimentellen Umgebungen eingesetzt, um die Stabilität von Modellen zu bewerten oder gezielt zu beeinflussen. Sie bilden damit ein methodisches Instrument, um die Auswirkungen von Veränderungen in den Eingaben systematisch zu analysieren und Modelle im Hinblick auf ihre Robustheit zu testen (Hendrycks & Dietterich, 2019; Moradi & Samwald, 2021).

Datenanreicherung (Data Augmentation)

Data Augmentation bezeichnet die künstliche Erweiterung von Trainingsdaten durch Variation oder Transformation bestehender Beispiele. Ziel ist es, die Vielfalt der Eingabedaten zu erhöhen, Überanpassung zu vermeiden und die Generalisierungsfähigkeit von Modellen zu verbessern. Die Methode hat ihren Ursprung in der Bildverarbeitung und wurde später in andere Bereiche des maschinellen Lernens übertragen. Durch kontrollierte Veränderungen der Trainingsdaten sollen Modelle lernen, stabile Merkmalsrepräsentationen auszubilden und weniger empfindlich auf Variationen in der Eingabe zu reagieren (Wei & Zou, 2019).

Adversariales Training (Adversarial Training)

Adversarial Training ist eine spezielle Form der Datenanreicherung, bei der Modelle mit gezielt veränderten Eingaben trainiert werden, um sie widerstandsfähiger gegenüber Störungen zu machen. Die dabei verwendeten adversarial examples sind minimal modifizierte Eingabedaten, die so generiert werden, dass sie Fehlklassifikationen provozieren. Durch das Einbeziehen solcher Beispiele in den Trainingsprozess soll das Modell lernen, robustere Merkmalsrepräsentationen auszubilden und weniger anfällig für kleine, gezielte Eingabeänderungen zu sein (I. J. Goodfellow et al., 2014).

Adversariale Angriffe (Adversarial Attacks)

Adversarial Attacks bezeichnen hingegen die gezielte Manipulation von Eingabedaten mit dem Ziel, die Vorhersagen eines Modells absichtlich zu verändern oder seine Schwachstellen offenzulegen (Ebrahimi et al., 2018). Sie unterscheiden sich von allgemeinen Perturbationen durch ihre Zielgerichtetheit und Optimierung: Während Perturbationen kontrollierte, aber neutral angelegte Veränderungen darstellen, werden Adversarial Attacks explizit so gestaltet, dass sie ein Modell in die Irre führen (Dirkson et al., 2021; Madry et al., 2017).

Adversarial Training nutzt diese Angriffe als Lernmechanismus. Es handelt sich also nicht um dieselbe Methode, sondern um eine defensive Strategie, die auf den Prinzipien adversarieller Angriffe basiert. Während Adversarial Attacks die Verwundbarkeit eines Modells aufzeigen, zielt Adversarial Training darauf ab, diese Verwundbarkeit zu verringern, indem das Modell lernt, korrekte Entscheidungen auch unter gezielten Störungen zu treffen. Beide Konzepte bilden somit komplementäre Ansätze im Forschungsfeld der Robustheit maschineller Lernsysteme (X. Jin et al., 2023).

Verzerrung (Bias)

Bias bezeichnet eine systematische Abweichung oder Ungleichverteilung in Daten, die dazu führt, dass bestimmte Muster über- oder unterrepräsentiert sind. Der Begriff stammt aus der Statistik, wo er eine Form struktureller Verzerrung beschreibt, die zu fehlerhaften Schlüssen führen kann (Torralba & Efros, 2011).

2.4 Evaluationsmetriken

Nachdem im vorangegangenen Abschnitt die zentralen Konzepte von Datenqualität und Robustheit definiert wurden, wird im Folgenden erläutert, anhand welcher Kennzahlen die Leistungsfähigkeit von Modellen bewertet werden kann. Für NER werden dabei typischerweise die Metriken Precision, Recall und F1-Score verwendet (Tsai et al., 2006).

Die Berechnung dieser Kennzahlen basiert auf vier grundlegenden Fällen, die das Ergebnis einer Modellvorhersage charakterisieren (Jurafsky & Martin, 2025):

- True Positive (TP): Eine Entität wurde korrekt erkannt und richtig klassifiziert.
- False Positive (FP): Das Modell erkennt eine Entität, die in Wirklichkeit nicht vorhanden oder anders klassifiziert ist.
- False Negative (FN): Eine Entität wurde vom Modell nicht erkannt.
- True Negative (TN): Ein Token wurde korrekt als keine Entität erkannt.

Precision gibt an, welcher Anteil der vom Modell erkannten Entitäten tatsächlich richtig ist. Sie misst also die Genauigkeit der positiven Vorhersagen:

$$Precision = \frac{TP}{TP + FP}$$

Recall beschreibt, wie viele der tatsächlich vorhandenen Entitäten vom Modell erkannt wurden. Diese Kennzahl bewertet somit die Vollständigkeit der Erkennung:

$$Recall = \frac{TP}{TP + FN}$$

Da Modelle häufig nicht gleichzeitig eine sehr hohe Precision und einen sehr hohen Recall erreichen, wird ihre Balance über den F1-Score zusammengefasst. Dieser bildet das harmonische Mittel beider Kennzahlen und liefert ein ausgewogenes Maß für die Modellleistung:

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Eine weitere häufig verwendete Kennzahl ist die Accuracy, die den Anteil aller korrekten Vorhersagen (TP + TN) an der Gesamtzahl der Fälle beschreibt. Sie liefert damit ein einfaches Maß für die allgemeine Treffgenauigkeit eines Modells. Für NER ist Accuracy jedoch nur bedingt aussagekräftig. Da der Großteil der Tokens keiner Entität angehört und somit der Klasse „O“ zugeordnet ist, kann ein Modell eine hohe Accuracy erzielen, selbst wenn es relevante Entitäten kaum korrekt erkennt (Tsai et al., 2006).

Für die Bewertung von NER-Modellen ist entscheidend, auf welcher Ebene die Leistung gemessen wird. Bei der Token-basierten Evaluation wird jedes Token einzeln betrachtet, während die Entitäts-basierte Evaluation nur dann eine korrekte Vorhersage zählt, wenn die vollständige Entität einschließlich ihres Typs exakt erkannt wurde (Tjong Kim Sang & Meulder, 2003).

Zur Aggregation der Ergebnisse werden meist Micro- oder Macro-Averaging verwendet. Beim Micro-Averaging werden alle Entitäten über sämtliche Klassen hinweg zusammengefasst, wodurch häufige Klassen stärker ins Gewicht fallen. Macro-Averaging berechnet dagegen die Kennzahlen je Klasse und mittelt sie gleichgewichtet, sodass jede Klasse unabhängig von ihrer Häufigkeit denselben Einfluss erhält.

Der micro-averaged F1-Score auf Entitätsebene gilt dabei als Standardmetrik, da er sowohl die Erkennungsgüte als auch die Verteilung der Klassen zuverlässig abbildet (Takahashi et al., 2022).

3 Methodik

Ziel dieses Kapitels ist es, das methodische Vorgehen der Arbeit zu erläutern und die Auswahl der verwendeten Ansätze zu begründen. Im Mittelpunkt steht die Untersuchung, wie sich unterschiedliche Arten und Intensitäten von Datenqualitätsproblemen auf die Robustheit von Transformer-basierten Named-Entity-Recognition-Modellen auswirken.

Da der bisherige Forschungsstand zu diesem Thema fragmentiert ist und vorhandene Studien häufig unterschiedliche Störungstypen, Datensätze oder Modelle untersuchen, erfordert die Beantwortung der Forschungsfragen ein Vorgehen, das sowohl den bestehenden Wissensstand strukturiert erfasst als auch unter kontrollierten Bedingungen empirisch überprüft (Bernier-Colborne & Langlais, 2020; Manning, 2022; Meng et al., 2021).

Um dies zu erreichen, kombiniert die Arbeit zwei methodische Ansätze: eine Systematic Literature Review nach Kitchenham und Charters (2007) sowie ein Laborexperiment nach dem Rahmenmodell von Wilde und Hess (2007). Diese Kombination erlaubt es, theoretische Erkenntnisse aus der Forschung mit empirischen Beobachtungen aus kontrollierten Experimenten zu verbinden und so ein umfassendes Verständnis der Zusammenhänge zwischen Datenqualität und Modellrobustheit zu gewinnen.

3.1 Systematic Literature Review

Ein Systematic Literature Review (SLR) ist ein Verfahren, mit dem vorhandenen Forschungsergebnissen zu einer klar abgegrenzten Fragestellung systematisch gesammelt, bewertet und zusammengeführt werden. Im Unterschied zu einer narrativen Literaturübersicht folgt eine SLR einem strukturierten und dokumentierten Vorgehen, das auf Transparenz und Reproduzierbarkeit ausgelegt ist. Ziel ist es, Verzerrungen bei der Auswahl und Bewertung der Literatur zu minimieren und ein objektives Bild des aktuellen Forschungsstands zu gewinnen (Kitchenham & Charters, 2007).

Nach Kitchenham und Charters (2007) besteht eine SLR aus den drei Phasen Planning, Conducting und Reporting. In der Planungsphase werden die Forschungsziele präzisiert und ein sogenanntes Review-Protokoll entwickelt, das als methodischer Leitfaden dient. Es legt fest, welche Forschungsfragen beantwortet werden sollen, welche Suchbegriffe und Datenbanken verwendet werden, welche Publikationstypen berücksichtigt werden und nach welchen Kriterien Studien ein- oder ausgeschlossen werden. Um die Suchstrategie zu validieren, wird eine Pilotsuche durchgeführt. Sie dient dazu, die Eignung und Treffgenauigkeit der Suchbegriffe zu prüfen, Synonyme oder verwandte Begriffe zu identifizieren und den finalen Suchstring zu verfeinern (Kitchenham & Charters, 2007; vom Brocke et al., 2015).

Im Rahmen des Review-Protokolls werden außerdem Einschluss- und Ausschlusskriterien definiert, anhand derer später entschieden wird, welche Arbeiten in die Analyse aufgenommen werden. Solche Kriterien können sich beispielsweise auf den thematischen Bezug, die Sprache, den Publikationstyp oder den empirischen Charakter einer Studie beziehen. Zur Gewährleistung der Nachvollziehbarkeit empfiehlt es sich, zu jedem Kriterium konkrete Include- und Exclude-Beispiele zu formulieren (vom Brocke et al., 2015).

In der zweiten Phase, dem Conducting des Reviews, erfolgt die eigentliche Literaturrecherche auf Grundlage des zuvor definierten Protokolls. Die gefundenen Arbeiten werden zunächst über Titel und Abstract und anschließend im Volltext geprüft. Für die ausgewählten Studien werden anschließend zentrale Informationen systematisch extrahiert und in strukturierter Form dokumentiert.

Die letzte Phase, das Reporting, umfasst die Aufbereitung und Synthese der Ergebnisse. Ziel ist es, die identifizierten Forschungsergebnisse inhaltlich zusammenzuführen und daraus ein konsistentes Gesamtbild des Forschungsstands zu entwickeln (Kitchenham & Charters, 2007).

Die SLR dient in dieser Arbeit der Beantwortung der ersten Forschungsfrage (FF1), die darauf abzielt, zu identifizieren, welche Arten von Datenstörungen in Datensätzen für NER auftreten. Diese Fragestellung bildet die Grundlage des empirischen Teils der Arbeit, da sie das Spektrum an Störungsarten definiert, das in den späteren Experimenten gezielt untersucht wird. Während die erste Forschungsfrage im Zentrum der SLR steht, liefern die übrigen Forschungsfragen (FF2 bis FF4) die konzeptionelle Verbindung zum experimentellen Teil, in dem die in der Literatur identifizierten Störungen unter kontrollierten Bedingungen überprüft und erweitert werden.

Ziel der SLR ist es, den bestehenden Forschungsstand zu Datenqualitätsproblemen in NER systematisch zu erfassen und die relevanten Konzepte und Vorgehensweisen zu verdichten. Im Mittelpunkt stehen dabei vier Erkenntnisbereiche, die unmittelbar auf die Planung und Interpretation der späteren Experimente einzahlen.

Erstens sollen relevante Typen von Datenstörungen identifiziert und kategorisiert werden, um ein strukturiertes Verständnis der in der bisherigen Forschung beschriebenen Störungsarten zu schaffen. Zweitens wird untersucht, unter welchen Bedingungen diese Störungen entstehen, also ob sie natürlich in realen Daten auftreten oder mithilfe von Frameworks, Libraries oder gezielten Manipulationen künstlich erzeugt wurden. Diese Information ist wesentlich, um zu beurteilen, ob bestehende Implementierungen zur Generierung von Störungen im experimentellen Teil übernommen oder ob eigene Implementierungen entwickelt werden müssen.

Drittens werden die in den jeweiligen Studien verwendeten Modelle erfasst, um die experimentellen Rahmenbedingungen der bisherigen Forschung nachzuvollziehen. Viertens werden, sofern in den Studien ausgewiesen, angegebene Veränderungen der Modellleistung dokumentiert. Diese Kennzahlen dienen in der späteren Analyse als Vergleichspunkte, soweit sich Fragestellungen und Untersuchungsbedingungen überlappen. Darüber hinaus ermöglichen sie eine Einordnung der neu gewonnenen experimentellen Ergebnisse in den bestehenden Forschungskontext.

Diese vier Erkenntnisdimensionen bilden zusammen die konzeptionelle Brücke zwischen der theoretischen und der empirischen Untersuchung. Sie ermöglichen es, bestehende Forschungsergebnisse in ein einheitliches Schema zu überführen und gleichzeitig neue empirische Erkenntnisse über die Robustheit von NER-Modellen zu generieren. Die in Abbildung 4 dargestellte Übersicht verdeutlicht diesen Zusammenhang zwischen der SLR, den erhobenen Informationen und deren Verwendung im Rahmen der experimentellen Untersuchung.

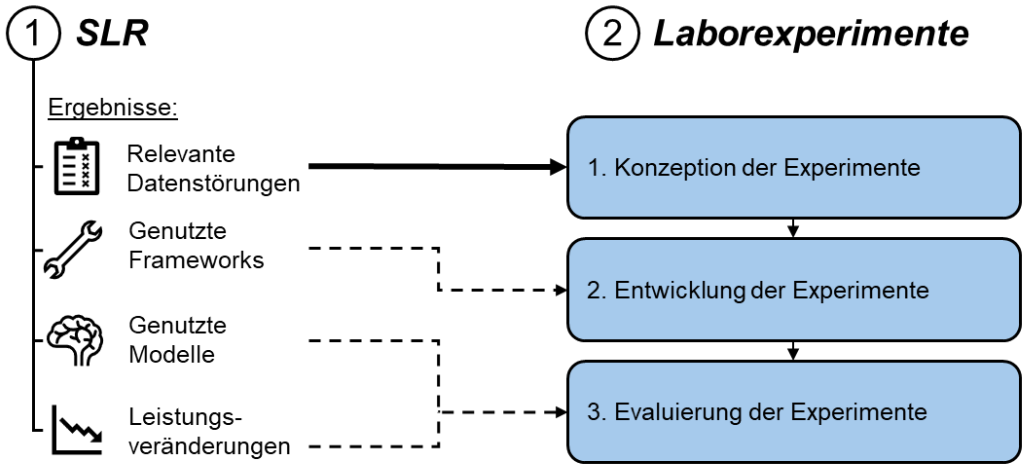


Abbildung 4: Zusammenspiel der Forschungsmethoden-Darstellung der methodischen Verknüpfung zwischen SLR und Laborexperimenten, wobei die aus der Literatur gewonnenen Erkenntnisse direkt in die Konzeption, Entwicklung und Evaluierung der Experimente einfließen.

Alternative methodische Ansätze wurden im Vorfeld geprüft, jedoch verworfen. Eine narrative Literaturübersicht hätte zwar einen ersten Überblick über den Forschungsstand bieten können, wäre jedoch weniger systematisch und anfälliger für Selektionsverzerrungen. Eine Metaanalyse wurde aufgrund der hohen methodischen Heterogenität der bestehenden Studien ausgeschlossen, da die Ziele der Studien, die verwendeten Modelle und Datensätze stark variieren und eine quantitative Aggregation der Ergebnisse nicht zulassen. Auch qualitative Fallstudien oder explorative Übersichten wurden verworfen, da sie keine strukturierte und nachvollziehbare Extraktion relevanter Forschungsmerkmale erlauben (DeVaney, 2016; Wilde & Hess, 2007).

3.2 Laborexperiment

Ein Laborexperiment ermöglicht es, Zusammenhänge zwischen gezielt veränderten Einflussgrößen und beobachtbaren Ergebnissen systematisch zu untersuchen. Im Gegensatz zu Untersuchungen in realen Anwendungsszenarien findet es in einer kontrollierten Umgebung statt, in der äußere Einflüsse weitgehend ausgeschlossen werden können. Auf diese Weise lassen sich Ursache-Wirkungs-Beziehungen präziser identifizieren und bewerten (Wilde & Hess, 2007).

In dieser Arbeit wird das Laborexperiment genutzt, um den Einfluss unterschiedlicher Arten und Intensitäten von Datenqualitätsproblemen auf die Robustheit von Transformer-basierten NER-Modellen zu analysieren. Aufbauend auf den Ergebnissen des SLR werden kontrollierte Szenarien entwickelt, in denen gezielt definierte Qualitätsminderungen simuliert werden. Die Art und Ausprägung der Störungen bilden dabei die unabhängigen Variablen, während die Modellleistung, gemessen anhand der in Kapitel 2.4 beschriebenen Evaluationsmetriken, die abhängige Variable darstellt.

Neben den verschiedenen Störungstypen wird auch die Wahl des Basismodells als zusätzlicher Parameter berücksichtigt, um mögliche Unterschiede in der Empfindlichkeit verschiedener Modellarchitekturen zu untersuchen. Die konkrete Auswahl der Modelle und Datensätze erfolgt in Kapitel 5, in dem das experimentelle Untersuchungsdesign detailliert beschrieben wird.

Das Laborexperiment bildet somit den empirischen Kern der Arbeit. Es ermöglicht, die in der Literatur identifizierten Zusammenhänge zwischen Datenqualität und Modellrobustheit gezielt zu überprüfen, systematisch zu erweitern und neue Erkenntnisse über die Stabilität von NER-Modellen unter variierenden Bedingungen zu gewinnen.

4 Systematic Literature Review

Nachdem in Kapitel 3 das methodische Vorgehen beschrieben und begründet wurde, folgt nun die konkrete Umsetzung des SLRs. Es orientiert sich dabei an den drei Phasen des Review-Prozesses nach Kitchenham und Charters (2007): Planning, Conducting und Reporting. Entsprechend behandelt Abschnitt 4.1 die konzeptionellen Vorbereitungen und die Entwicklung des Review-Protokolls, Abschnitt 4.2 die eigentliche Literatursuche und Abschnitt 4.3 die zusammengefassten Erkenntnisse der Review.

4.1 Vorbereitung

Wie in Kapitel 3.1 beschrieben, verfolgt die SLR das Ziel, vier zentrale Fragestellungen zu beantworten:

- Welche Datenqualitätsprobleme oder Störungstypen werden in der Forschung zu NER oder NLP beschrieben?
- Welche Modelle wurden in den jeweiligen Studien verwendet?
- Wie sind die Störungen entstanden, und wurden dabei bestimmte Frameworks oder Bibliotheken genutzt?
- Welche Effekte haben die Störungen auf die Modellleistung?

Die erste Frage stellt die Primärfragestellung der SLR dar, während die übrigen Fragen unterstützend dazu dienen, die nachfolgenden empirischen Untersuchungen vorzubereiten und einzuordnen. Die Analyse beschränkt sich dabei bewusst nicht ausschließlich auf NER, da angenommen wird, dass zahlreiche Ansätze und Erkenntnisse aus der allgemeinen NLP-Forschung auf NER übertragbar sind.

Einschluss- und Ausschlusskriterien

Um sicherzustellen, dass nur inhaltlich relevante und methodisch nachvollziehbare Studien in die Analyse einfließen, werden Einschluss- und Ausschlusskriterien definiert. Diese Kriterien bilden den Kern des Review-Protokolls und gewährleisten, dass die Auswahl der Literatur transparent, reproduzierbar und frei von subjektiver Verzerrung erfolgt (Kitchenham & Charters, 2007). Sie decken sowohl thematische als auch formale Aspekte ab, darunter Forschungsfokus, Modellarchitektur, Art der Störungen, Publikationstyp und Zeitraum. Tabelle 1 hält die verschiedenen Kriterien inklusive Include- und Exclude-Beispiele fest.

Kategorie	Include	Exclude
Thema	Arbeiten, die NLP-Robustheit oder Data-Quality-Noise bei NLP untersuchen	Arbeiten ohne Bezug zu NLP oder ohne inhaltlichen Fokus auf Datenqualität oder Robustheit.
Modell-architektur	Transformer-basierte Encodermodelle (z. B. BERT, RoBERTa, DeBERTa, etc.).	Modelle ohne Transformer-Bezug, z. B. CRF, LSTM, klassische statistische Modelle oder reine Decoder-Architekturen.
Störungstyp	Studien, die definierte und nachvollziehbare Störungen untersuchen, z. B. orthographische, syntaktische oder semantische Fehler, Label-Noise, adversarial word swaps, etc.	Arbeiten, in denen die Art, Quelle oder Reproduzierbarkeit der Datenstörung nicht transparent beschrieben oder nachvollziehbar ist (z. B. rein diskriminative Modelle ohne explizite Beschreibung der Eingabeveränderungen).
Publikations-typ	Peer-reviewte Konferenz- oder Journal-Beiträge, Preprints in Einreichung	Bücher, Workshop-Papers
Zeitraum	2017 – 2025	Vor 2017
Sprache	Englisch und Deutsch	Andere Sprachen
Verfügbarkeit	Volltext zugänglich	Kein Zugriff
Zitationen	Über 10	Unter 10

Tabelle 1: Einschluss- und Ausschlusskriterien SRL- Zusammenfassung der inhaltlichen und formalen Einschluss- und Ausschlusskriterien, die im Screening-Prozess zur Identifikation geeigneter Publikationen angewendet wurden.

Arbeiten ohne direkten Bezug zu NLP werden ausgeschlossen, da Fehlerquellen aus anderen Forschungsgebieten, etwa aus der Computer Vision oder Sensordatenauswertung, strukturell andere Ursachen und Auswirkungen aufweisen. Solche Störungstypen beeinflussen keine sprachbasierten Modelle und tragen daher nicht zum Erkenntnisinteresse dieser Arbeit bei.

Bei der Modellarchitektur werden ausschließlich Transformer-basierte Encodermodelle berücksichtigt, da sie seit 2017 den methodischen Standard im NLP bilden und die Grundlage moderner NER-Systeme darstellen. Frühere Architekturen wie LSTM oder CRF sind teilweise anfällig für Störungstypen, die bei Transformern aufgrund ihrer Architektur kaum mehr relevant sind. Durch die Beschränkung auf Transformer kann sichergestellt werden, dass nur solche Störungen erfasst werden, welche auch tatsächlich relevant für die Arbeit sind. Decoder-Modelle werden ausgeschlossen, da sie auf generative Aufgaben ausgerichtet sind und sich konzeptionell von den für NER relevanten Sequenzklassifikationsansätzen unterscheiden.

Beim Störungstyp werden nur Arbeiten berücksichtigt, in denen die Art und Entstehung der Störung klar beschrieben und reproduzierbar ist. Einbezogen werden Studien, die sich mit orthografischen, syntaktischen oder semantischen Abweichungen, Label-Noise oder adversarialen Wortveränderungen befassen. Ausgeschlossen werden hingegen Arbeiten mit unklarer oder nicht reproduzierbarer Datenstörung, bei denen nicht spezifiziert ist, was, wie oder warum verändert wurde. Dazu zählen insbesondere rein diskriminative Ansätze, bei denen zwar ein

Leistungsabfall gemessen, die zugrunde liegende Datenmanipulation jedoch nicht transparent dokumentiert wird.

Beim Publikationstyp werden peer-reviewte Konferenz- und Journalbeiträge sowie Preprints , die gerade in Einreichung sind, berücksichtigt. Da die Forschung zu Datenqualität und Robustheit in NLP ein sehr aktives und dynamisches Feld ist, erscheinen viele relevante Arbeiten zunächst als Preprints. Ihre Einbeziehung stellt sicher, dass aktuelle Entwicklungen erfasst werden. Das Kriterium der Zitationshäufigkeit dient dabei als ergänzender Qualitätsfilter, um sicherzustellen, dass nur Arbeiten mit einer gewissen wissenschaftlichen Relevanz in die Analyse aufgenommen werden.

Der Zeitraum ab 2017 wurde gewählt, da mit der Veröffentlichung der Transformer-Architektur (Vaswani et al., 2017) ein grundlegender methodischer Wandel im Bereich des Natural Language Processing (NLP) einsetzte. Studien, die vor diesem Zeitpunkt erschienen sind, basieren überwiegend auf vortransformer-basierten Modellarchitekturen und adressieren häufig Arten von Robustheitsproblemen oder Fehlerquellen, die bei modernen, Transformer-basierten NER-Modellen entweder nicht mehr auftreten oder nur eine untergeordnete Relevanz besitzen.

Bezüglich der Sprache werden ausschließlich englisch- und deutschsprachige Publikationen berücksichtigt. Diese Auswahl gewährleistet, dass die Arbeiten vom Autor der Arbeit sprachlich vollständig verstanden und inhaltlich korrekt analysiert werden können. Die Verfügbarkeit des Volltexts ist eine Grundvoraussetzung, da nur vollständig zugängliche Studien hinsichtlich Methodik, Datengrundlage und Ergebnissen zuverlässig bewertet werden können.

Abschließend wird eine Mindestanzahl von zehn Zitierungen festgelegt, um eine gewisse wissenschaftliche Relevanz und Güte der Quellen sicherzustellen. Die Schwelle ist bewusst moderat gewählt, um neuere Arbeiten mit potenziell hohem Erkenntniswert, aber bislang geringer Zitationszahl, nicht auszuschließen. Auf diese Weise wird ein Gleichgewicht zwischen Qualitätssicherung und Aktualität der Literatur erreicht.

Pilotsuche

Als Grundlage für die Suchstrategie dienen die in Kapitel 2.3 identifizierten Begriffe rund um Datenqualität, Rauschen und Robustheit. Diese stammen aus einer ersten, unstrukturierten Literaturrecherche und werden nun im Rahmen einer Pilotsuche daraufhin überprüft, inwiefern sie tatsächlich im Kontext von NLP oder NER verwendet werden. Dieses Vorgehen entspricht dem Ansatz von Kitchenham und Charters (2007), nach dem eine Pilotsuche genutzt wird, um die Eignung potenzieller Suchbegriffe empirisch zu validieren, bevor der finale Suchstring festgelegt wird.

Die zu überprüfenden Begriffe aus Kapitel 2.3 sind: “bias”, “adversarial”, “adversarial attack”, “adversarial training”, “data augmentation”, “robust”, “noise”, “textual noise”, “label noise”, “data quality”, “brittleness” und “data corruption”, “perturbation”. Dabei wurde bewusst sowohl der generische Begriff „noise“ als auch dessen spezifischere Unterkategorien „label noise“ und „textual noise“ einbezogen, um zu prüfen, ob eine präzisere Spezifikation der Suchbegriffe zu relevanteren Ergebnissen führt.

Bereits nach einer ersten Sichtung der Ergebnisse zeigte sich, dass viele der Begriffe ohne weiteren Kontext zu sehr allgemeinen Arbeiten aus dem Bereich des maschinellen Lernens führten, etwa zu Robustheitsanalysen in der Computer Vision oder bei allgemeinen Klassifikationsaufgaben. Die Suchanfragen wurden daher jeweils in Kombination mit NER, Named Entity Recognition, NLP oder Natural Language Processing formuliert:

[Suchbegriff] AND (NER OR “Named Entity Recognition“ OR NLP OR “Natural Language Processing”)

Dabei stellt die Verwendung von Anführungszeichen (“ “) sicher, dass der Text innerhalb der Anführungszeichen exakt in dieser Form im Titel oder Inhalt der Publikation vorkommt. Der Operator OR ermöglicht, dass mindestens einer der genannten Begriffe enthalten ist, während AND verlangt, dass sowohl der spezifische Suchbegriff als auch mindestens einer der NLP-bezogenen Begriffe gemeinsam im Dokument vorkommen

Die Pilotsuche wurde mithilfe der Suchmaschine Google Scholar am 27. Und 28. Juni 2025 durchgeführt. Für jeden Suchbegriff wurden die Abstracts der jeweils ersten zehn Treffer manuell gesichtet und hinsichtlich ihrer Relevanz für die Forschungsfrage bewertet. Die Ergebnisse dieser Pilotsuche sind in Tabelle 2 dargestellt.

Suchbegriff	Relevanz
adversarial	70%
adversarial attack	50%
adversarial training	40%
data augmentation	10%
robust	60%
noise	80%
textual noise	30%
label noise	50%
data quality	60%
brittleness	0%
data corruption	50%
bias	10%
perturbation	70%

Tabelle 2: Relevanz Begriffe Pilotsuche- Prozentuale Bewertung wie viele der ersten 10 Suchergebnisse als relevant klassifiziert wurden. Zur Bewertung der Relevant wurden die in Tabelle 1 definierten Einschluss- und Ausschlusskriterien genutzt

Die Ergebnisse der Pilotsuche zeigen deutliche Unterschiede in der Relevanz der getesteten Suchbegriffe (siehe Tabelle 2). relevante Treffer bei noise (80 %), adversarial (70 %), perturbation (70 %), robust (60 %) und data quality (60 %) auf. Diese Begriffe erwiesen sich als zentral für den Forschungsstand zu Datenqualität und Robustheit im NLP.

Spezifischere Varianten wie textual noise (30 %) und label noise (50 %) lieferten hingegen deutlich weniger relevante Ergebnisse, was darauf hindeutet, dass in der Literatur überwiegend der Oberbegriff noise verwendet wird. Gleiches gilt für adversarial. Auch data corruption (40 %) zeigte zwar einige relevante Treffer, lieferte jedoch insgesamt weniger aussagekräftige Ergebnisse. Da weniger als die Hälfte der Funde als relevant eingestuft wurden, wurde dieser Begriff nicht in die Hauptsuche aufgenommen, um den Fokus auf die fünf zentralsten und verlässlichsten Begriffe zu legen.

Zudem zeigte sich, dass in vielen Arbeiten die Schreibweise noisy anstelle von noise verwendet wird, weshalb diese Variante im finalen Suchstring berücksichtigt wurde. Die endgültige Suchkombination lautet:

("natural language processing" OR "NLP" OR "Named Entity Recognition" OR "NER")

AND

("data quality" OR robust OR nois OR perturbation OR adversarial)*

Die Analyse der Quellenverteilung der relevanten Treffer ergab, dass 37 % der Arbeiten aus den ACL Anthology-Konferenzen stammen, 29 % von arXiv, 9 % von der ACM Digital Library und 8 % von IEEE Xplore. Weitere Quellen trugen nur in geringem Umfang bei und wurden daher nicht weiter berücksichtigt. Die Einbeziehung von Preprints erwies sich dabei als sinnvoll, da sich zeigte, dass ein nicht unerheblicher Anteil der relevanten Literatur über arXiv verfügbar ist. Für die weitere Literaturrecherche werden daher diese vier Quellen herangezogen.

4.2 Durchführung

Die Durchführung der SLR erfolgte über mehrere Tage im Juli 2025 in den vier definierten Quellen ACL Anthology, arXiv, ACM Digital Library und IEEE Xplore. Für jede Quelle wurden die ersten 100 Ergebnisse auf Grundlage des finalen Suchstrings gesichtet. Die Bewertung und Auswahl der Arbeiten erfolgten gemäß den in Abschnitt 4.1 definierten Ein- und Ausschlusskriterien. Abbildung 5 zeigt den Auswahlprozess der SLR, während die vollständige Liste der geprüften Arbeiten einschließlich der Begründungen für Ein- und Ausschluss in Anhang 1 dokumentiert ist.

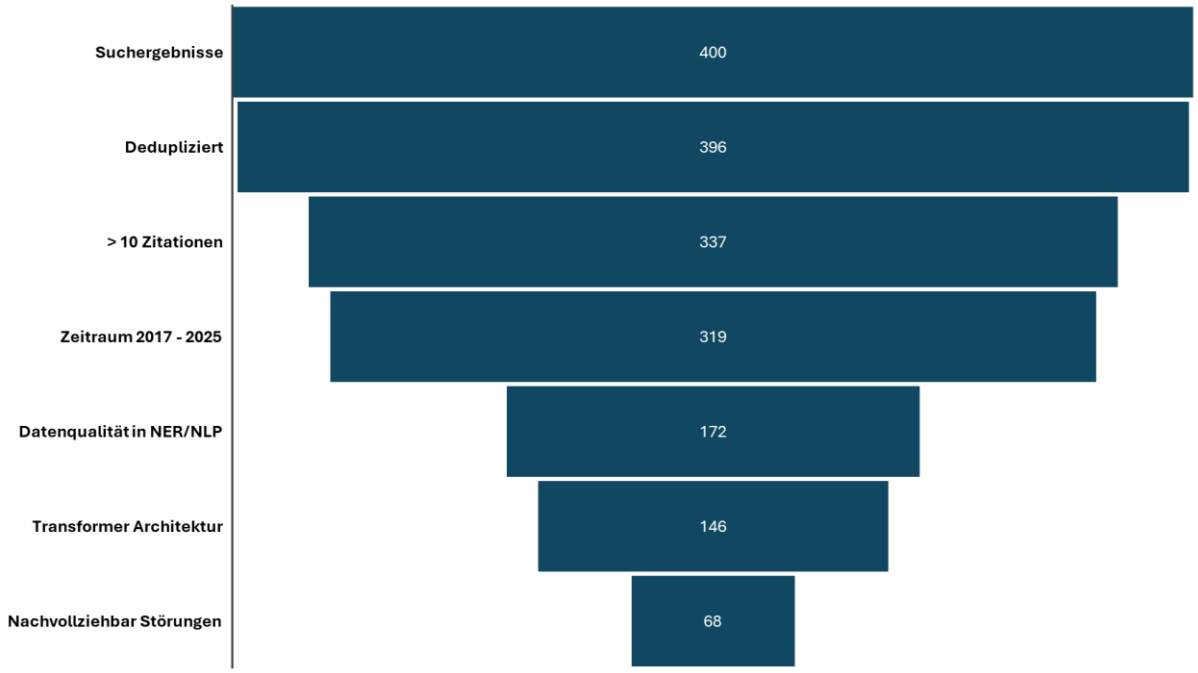


Abbildung 5: Literatur-Selektionsprozess- Abbildung zeigt Hauptsuche des SLR. Auf der linken Seite stehen die Kriterien, welche für den Ein- beziehungsweise Ausschluss ausschlaggebend waren. Die Kriterien wurden in Kapitel 4.1 festgelegt und begründet.

Die Literatursuche ergab zunächst 400 Treffer, die nach Deduplikation, Zitierungen und Zeitraumfilterung auf 319 Arbeiten reduziert wurden. Nach Anwendung der thematischen Kriterien verblieben 172 Arbeiten zur Datenqualität in NER/NLP. Zahlreiche Studien konzentrierten sich hier jedoch auf die reine Anwendung von NER oder die Vorstellung neuer Modellarchitekturen, ohne bestehende Datenqualitätsproblem zu untersuchen oder zu beschreiben. Zudem waren in mehreren Arbeiten die entstandenen Störungen nicht nachvollziehbar dokumentiert, sodass schließlich 68 Studien für die weitere Arbeit berücksichtigt wurden. Hauptausschlussgründe waren der Einsatz von Diskriminator-Netzwerken oder das Training auf verrauschten Datensätzen, bei denen unklar blieb, welche konkreten Qualitätsprobleme vorlagen oder wie diese gezielt erzeugt wurden.

4.3 Ergebnisse

Nach der Auswahl der relevanten Studien folgt im nächsten Schritt die Ergebnisauswertung. In Kapitel 4.3.1 werden zunächst die verschiedenen Datenstörungen identifiziert, um eine umfassende Antwort auf die erste Forschungsfrage (FF1) zu geben: Welche Arten von Datenstörungen treten in Datensätzen für Named Entity Recognition auf? Anschließend wird in Kapitel 4.3.2 untersucht, welche Methoden und Frameworks in den analysierten Arbeiten verwendet wurden und wie sich die Störungen auf die Modellleistung auswirkten. Den Abschluss bildet eine kurze Zusammenfassung

4.3.1 Identifizierte Datenstörungen

Neben den eigentlichen Störungen zeigte die Analyse, dass diese in der Forschung nur selten isoliert betrachtet werden. Stattdessen orientiert sich die Einteilung häufig an einer etablierten Taxonomie, die linguistische Ebenen berücksichtigt, auf denen Qualitätsprobleme auftreten können. Diese in der Literatur weit verbreitete Klassifikation, die unter anderem von Qiao et al. (2024), Simoncini & Spanakis (2021) sowie Srinivasan & Vajjala (2023) verwendet wird, unterscheidet drei Haupttypen textinhaltlicher Störungen: orthografische, syntaktische und semantische.

Neben diesen textbezogenen Störungsarten treten, wie bei Klassifikationsaufgaben üblich, auch Fehler auf, die nicht den Texteingang selbst, sondern die Zielvariablen betreffen. Diese werden der Labelebene zugeordnet. Darüber hinaus identifizierte die SLR mehrere Phänomene, die sich nicht eindeutig einer der genannten Kategorien zuordnen lassen oder stark vom jeweiligen Entstehungskontext abhängen. Diese werden in der Kategorie Sonstiges zusammengefasst.

Die im Rahmen der SLR identifizierten Störungstypen sind in Tabelle 3 dargestellt. Sie sind den fünf Hauptkategorien zugeordnet: orthografisch, syntaktisch, semantisch, Labelebene und Sonstiges.

	Problem	**Autoren**
Orthografisch	Allg. Tippfehler/Rechtschreibfehler	(Ai et al., 2024; Al Sharou et al., 2021; Aliakbarzadeh et al., 2025; Bagla et al., 2021; Bhadauria et al., 2024; Chen et al., 2023; Esmaail et al., 2024; L. Li et al., 2020; Malykh, 2019; Malykh & Lyalin, 2018; Moradi et al., 2021; Moradi & Samwald, 2021; Namysl et al., 2020; Náplava et al., 2021; Nguyen & Chen, 2023; Qiao et al., 2024)
	Tastaturfehler	(Araujo et al., 2020; Bagla et al., 2023; Bagla et al., 2021; Moradi et al., 2021)
	Phonetische Fehler	(Nguyen & Chen, 2023; Qiao et al., 2024)
	Morphologische Fehler	(Náplava et al., 2021)
	Wortverlängerung / Zeichenwiederholung	(Al Sharou et al., 2021; Moradi et al., 2021; Moradi & Samwald, 2021)
	OCR-Fehler	(Ai et al., 2024; Bhadauria et al., 2024; Boros et al., 2020; Das & Paik, 2022; Ehrmann et al., 2024; Hamdi et al., 2023; Namysl et al., 2020)
	Fehlerhafte Groß-/Kleinschreibung	(Ahmed et al., 2024; Al Sharou et al., 2021; Bodapati et al.; Das & Paik, 2022; Esmaail et al., 2024; Moradi & Samwald, 2021; Náplava et al., 2021; J. Zhu et al., 2025)
	Zeichenmanipulation	(Araujo et al., 2020; Ebrahimi et al., 2018; Garg & Ramakrishnan, 2020; Goyal et al., 2023; X. Jin et al., 2023; L. Li et al., 2020; Moradi et al., 2021; Moradi & Samwald, 2021; Namysl et al., 2020; Nguyen & Chen, 2023; Shi et al., 2024; Simoncini & Spanakis, 2021; Srinivasan & Vajjala, 2023; Y. Wang et al., 2022; Y. Yang et al., 2023; Zeng et al., 2020)
	Diakritische Fehler	(Al Sharou et al., 2021; Náplava et al., 2021)

Syntaktisch	Grammatikalische Fehler	(Al Sharou et al., 2021; Chen et al., 2023; Malykh, 2019; Malykh & Lyalin, 2018; Moradi & Samwald, 2021; Qiao et al., 2024; Srinivasan & Vajjala, 2023)
	Änderung der Wortreihenfolge	(Al Sharou et al., 2021; Liang et al., 2024; Moradi et al., 2021; Moradi & Samwald, 2021; Náplava et al., 2021; Qiao et al., 2024)
	Satzstruktur-Änderungen	(Bhadauria et al., 2024; Garg & Ramakrishnan, 2020; L. Li et al., 2020; Shi et al., 2024; Yuan et al., 2019; J. Zhu et al., 2025)
	Tokenisierungs- / Segmentierungsfehler	(Bernier-Colborne & Vajjala, 2024; Boros et al., 2020; Hamdi et al., 2023; Szymański et al., 2023)
	Interpunktionsfehler	(Al Sharou et al., 2021; Esmaail et al., 2024; Goyal et al., 2023; Náplava et al., 2021)
Semantisch	Ersetzung von Entitäten	(Dirkson et al., 2021; Lin et al., 2021; Lothritz et al., 2023; Morris et al., 2020; Qiao et al., 2024; Srinivasan & Vajjala, 2023; H. Wang & Li, 2024; Yan et al., 2021; Ying et al., 2022; Yu et al., 2025)
	Ersetzung von Kontextwörtern	(Araujo et al., 2020; Chen et al., 2023; Das & Paik, 2022; Dirkson et al., 2021; Garg & Ramakrishnan, 2020; Jia et al., 2019; L. Jin et al., 2021; L. Li et al., 2020; Lothritz et al., 2023; Moradi et al., 2021; Moradi & Samwald, 2021; Morris et al., 2020; Qiang et al., 2024; H. Wang & Li, 2024; S. Wu et al., 2024; Ying et al., 2022; Zeng et al., 2020; J. Zhu et al., 2025)
	Paraphrasierung	(Goyal et al., 2023; Qiang et al., 2024; Srinivasan & Vajjala, 2023; R. Wang & Henao, 2021; Zeng et al., 2020)
Label-bezogen	Inkorrekte Labels	(Bernier-Colborne & Vajjala, 2024; Chu et al., 2023; Chu et al., 2024; Fokam & Beukman, 2022; X. Huang et al., 2021; L. Jin et al., 2021; Mayhew et al., 2019; Meng et al., 2021; Merdjanovska et al., 2024; Si et al., 2023; Tian et al., 2023; J. Wu et al., 2022; T. Wu et al., 2022; D. Zhu et al., 2022)
	Fehlende Labels	(Cai & O'Connor, 2024; Chu et al., 2023; Chu et al., 2024; Fokam & Beukman, 2022; Mayhew et al., 2019; Meng et al., 2021; Merdjanovska et al., 2024; Si et al., 2023; Tian et al., 2023; D. Zhang et al., 2023; D. Zhu et al., 2022; Z. Zhu et al., 2023)
	Span- / Abgrenzungsfehler	(Bernier-Colborne & Vajjala, 2024; Chu et al., 2023; Chu et al., 2024; Merdjanovska et al., 2024; Tian et al., 2023; J. Wu et al., 2022; Y. Yang et al., 2023)
	Inkonsistente Annotationen	(Bernier-Colborne & Vajjala, 2024; Ehrmann et al., 2024; Meng et al., 2021)
	Label-Imbalance	(Esmaail et al., 2024; Liang, Bin and Li, Hongcheng et al., 2018; Sohn & Park, 2022; Ying et al., 2022)
	Falsch-Positive Annotationen	(Mayhew et al., 2019; Merdjanovska et al., 2024; Tian et al., 2023)
Sonstig	UGC-Artefakte	(Al Sharou et al., 2021; Esmaail et al., 2024)
	ASR-Fehler	(Bagla et al., 2021; Qiang et al., 2024; Szymański et al., 2023)
	Out-of-Vocabulary	(Bernier-Colborne & Langlais, 2020; Boros et al., 2020; Ehrmann et al., 2024; Esmaail et al., 2024)

Tabelle 3: Identifizierte Datenstörungen- Übersicht der in den analysierten Studien beschriebenen Störungstypen einschließlich zugehöriger Quelle. Die Zuordnung basiert auf der systematischen Auswertung der 68 in die Analyse einbezogenen Arbeiten

Wie in Tabelle 3 dargestellt, bilden **orthografische Probleme** die in der untersuchten Literatur am häufigsten beschriebene Kategorie. Sie umfassen alle Abweichungen, die die Schreibweise und die visuelle Darstellung von Wörtern betreffen, ohne zwangsläufig deren Bedeutung oder grammatikalische Funktion zu ändern. Dazu gehören allgemeine Tipp- und Rechtschreibfehler, wie sie von Esmaail et al. (2024), Malykh & Lyalin (2018) sowie Náplava et al. (2021) genannt werden. Spezifischere Fehlerquellen sind Tastaturfehler, bei denen Zeichen durch versehentlich getroffene, benachbarte Tasten auf einer QWERTY-Tastatur ersetzt werden (Araujo et al., 2020; Bagla et al., 2023; Moradi et al., 2021), sowie phonetische Fehler, bei

denen Wörter nach Gehör statt nach korrekter Orthografie geschrieben werden (Nguyen & Chen, 2023; Qiao et al., 2024).

Eine weitere Unterkategorie bilden diakritische Fehler, bei denen Akzente oder Sonderzeichen falsch gesetzt, ausgelassen oder durch nichtdiakritische Buchstaben ersetzt werden. Solche Fehler treten insbesondere in Sprachen mit akzentuierter Orthografie auf und können zu Bedeutungsverschiebungen führen (Náplava et al., 2021; Al Sharou et al., 2021).

Einen eigenen Bereich bilden Fehler, die aus der Digitalisierung oder spezifischen Textsorten stammen. Dazu zählen OCR-Fehler, die bei der automatischen Texterkennung entstehen und typische visuelle Verwechslungen umfassen, beispielsweise die fehlerhafte Erkennung von 'I' als 'l', '$' als '5' oder 'O' als '0' (Hamdi et al., 2023; Namysl et al., 2020). Davon abzugrenzen sind orthografische Varianten, die durch regionale oder, wie bei Boros et al. (2020) beschrieben, historische Schreibweisen entstehen und von modernen Modellen ebenfalls oft nicht erkannt werden.

Ein ebenfalls wesentliches Problem ist die fehlerhafte Groß- und Kleinschreibung. Sie reicht von uneinheitlicher oder zufälliger Kapitalisierung in nutzergenerierten Texten (Esmaail et al., 2024) bis hin zur vollständigen Kleinschreibung, die in der Forschung auch als Case Ablation bezeichnet wird (Bodapati et al.; Das & Paik, 2022). Darüber hinaus werden auch stilistische Schreibweisen, etwa bewusste Wortverlängerungen durch Zeichenwiederholungen wie „soooo schön“ zur emotionalen Betonung (Moradi et al., 2021; Al Sharou et al., 2021), als Störquelle beschrieben. Ebenso treten morphologische Fehler auf, die die korrekte Bildung von Wörtern betreffen. Dabei werden Präfixe oder Suffixe falsch verwendet.

Als künstlich erzeugte Fehlerkategorie zur Robustheitsmessung wird außerdem die gezielte Zeichenmanipulation durch das Einfügen, Löschen, Ersetzen oder Tauschen von Zeichen, oft als Ins, Del, Sub oder Swap bezeichnet, genannt (Ebrahimi et al., 2018; Goyal et al., 2023; X. Jin et al., 2023; L. Li et al., 2020; Simoncini & Spanakis, 2021).

Die zweite Kategorie umfasst **syntaktische** Probleme, die den Satzbau, die Struktur und die grammatikalische Korrektheit von Sätzen betreffen. Diese Störungen zielen auf die Fähigkeit des Modells ab, strukturelle Zusammenhänge korrekt zu verarbeiten. Hierzu zählen allgemeine grammatikalische Fehler (Malykh & Lyalin, 2018; Chen et al., 2023) sowie die bewusste Änderung der Wortreihenfolge im Satz (Liang et al., 2024; Náplava et al., 2021). Auch Änderungen der Satzstruktur durch Verkürzung, Erweiterung (Bhadauria et al., 2024; Shi et al., 2024) oder das strategische Einfügen und Verschmelzen von Wörtern (Li et al., 2020) werden als Störungsmethoden beschrieben. Als besonders kritisch für NER-Modelle erweisen sich hierbei Tokenisierungs- und Segmentierungsfehler (Ehrmann et al., 2024; Hamdi et al., 2023; Szymański et al., 2023).

Tokenisierungsfehler entstehen, wenn Wörter oder Wortbestandteile nicht korrekt voneinander getrennt werden, wodurch die eindeutige Identifizierung von Entitäten erschwert wird. Segmentierungsfehler führen zum Verlust klarer Satzgrenzen, was den für Transformer-Modelle relevanten Kontext beeinträchtigt und fehlerhafte Zusammenführungen von Sätzen zur Folge haben kann.

Als dritte Hauptkategorie wurden **semantische** Probleme identifiziert, welche die Bedeutungsebene des Textes stören. Im Gegensatz zu orthografischen Fehlern sind die Wörter hier oft korrekt geschrieben, jedoch ist der inhaltliche Sinn manipuliert, um die kontextuelle Inferenzfähigkeit der Modelle zu testen. Eine verbreitete Methode ist die Ersetzung von Kontextwörtern, häufig durch Synonyme, wie das Ersetzen von „perfekt“ durch „makellos“ (Morris et al., 2020). Solche Angriffe, wie sie auch von Li et al. (2020) oder Garg & Ramakrishnan (2020) implementiert wurden, zielen darauf ab zu prüfen, ob ein Modell eine Entität auch dann noch erkennt, wenn sich der vertraute Kontext ändert (Chen et al., 2023; Qiang et al., 2024; H. Wang & Li, 2024). Als Steigerung dieser Methode gilt die Ersetzung von Entitäten selbst, bei der Eigennamen gezielt ausgetauscht werden, sei es durch andere Entitäten derselben Kategorie, beispielsweise das Ersetzen eines Personennamens durch einen anderen (Dirkson et al., 2021), oder durch nicht zur Verteilung passende Begriffe (Lin et al., 2021; Ying et al., 2022). Auf der Ebene ganzer Sätze wird die Paraphrasierung eingesetzt, welche die Oberflächenstruktur bei gleichbleibender Semantik ändert (Srinivasan & Vajjala, 2023; R. Wang & Henao, 2021).

Als vierte Kategorie wurde die **Labelebene**, in der Literatur auch als Annotation Errors bezeichnet, identifiziert. Wie bei vielen Klassifikationsaufgaben liegt der Fehler hier nicht im Eingabetext, sondern in den Annotationen, die dem Modell als Referenz dienen. Die Literatur beschreibt verschiedene Formen solcher Fehler, darunter inkorrekte Labels, bei denen Entitäten falsch zugewiesen werden, etwa wenn eine LOCATION fälschlicherweise als ORGANIZATION markiert wird (Merdjanovska et al., 2024). Ebenso häufig treten fehlende Labels auf, bei denen vorhandene Entitäten irrtümlich als Nicht-Entität (O) annotiert werden (Fokam & Beukman, 2022; Si et al., 2023). Hinzu kommen Abgrenzungs- oder Spanfehler, bei denen die Grenzen einer Entität fehlerhaft gesetzt werden, etwa durch die Einbeziehung zusätzlicher Wörter oder durch nur teilweise korrekte Überlappungen (Bernier-Colborne & Vajjala, 2024; Chu et al., 2024; Merdjanovska et al., 2024).

Als eine zentrale Ursache solcher Annotationsfehler wird Rauschen durch Distant Supervision beschrieben. Dabei werden Labels nicht manuell vergeben, sondern automatisch aus externen Wissensquellen abgeleitet. Dieser Prozess ermöglicht eine schnelle Erstellung großer Datensätze, führt jedoch häufig zu systematischen Zuordnungsfehlern, wenn die automatisch übertragenen Labels nicht exakt mit dem Textkontext übereinstimmen (Cai & O’Connor, 2024; D. Zhu et al., 2022).

Die abschließende Kategorie **Sonstige** umfasst Phänomene, die sich keiner der zuvor beschriebenen linguistischen Ebenen eindeutig zuordnen lassen oder stark von der jeweiligen Datenquelle abhängen. Dazu zählen UGC-Artefakte aus sozialen Medien, also sprachliche und strukturelle Besonderheiten nutzergenerierter Inhalte wie Slang, Emojis, Jargon oder URLs, die für Modelle eine besondere lexikalische Herausforderung darstellen (Al Sharou et al., 2021; Esmaail et al., 2024). Ebenfalls hierzu gehören ASR-Fehler aus der automatischen Spracherkennung, die von fehlerhafter Worterkennung bis zur Ersetzung unbekannter Begriffe durch unzutreffende Wörter reichen (Szymański et al., 2023). Darüber hinaus wird das Auftreten von Out-of-Vocabulary-Wörtern (OOV), also Begriffen, die dem Modell nicht bekannt sind, als relevante Störungsquelle beschrieben (Bernier-Colborne & Langlais, 2020; Ehrmann et al., 2024).

4.3.2 Methoden und Leistungseinfluss

Über die reine Identifikation von Störungstypen hinaus liefert die SLR Aufschluss darüber, wie diese Datenqualitätsprobleme in der Forschung untersucht werden. Die Analyse der Methodiken (n = 68) zeigt, dass rund 68 % der Studien (46 Arbeiten) kontrollierte Störungen künstlich erzeugen, während etwa 32 % (22 Arbeiten) mit bereits verrauschten Datensätzen arbeiten, die natürliche Qualitätsminderungen enthalten. Die Gruppe, die auf reale Störquellen setzt, nutzt überwiegend Datensätze aus praxisnahen Domänen, in denen Fehler inhärent auftreten. Dazu zählen etwa nutzergenerierte Inhalte aus sozialen Medien (z. B. WNUT 2017–2020), durch Optical Character Recognition (OCR) erfasste historische Dokumente oder automatisch annotierte Korpora, die über Distant Supervision erstellt wurden. Typische Beispiele finden sich bei Esmaail et al. (2024) und Hamdi et al. (2023), die bewusst auf nachträgliche Datenmanipulation verzichten und die Modellleistung ausschließlich auf natürlich verrauschten Texten bewerten. Diese Studien zielen darauf ab, die Robustheit bestehender Modelle unter realistischen Bedingungen zu prüfen, wobei der Fokus auf der Beobachtung tatsächlicher Qualitätsdefizite liegt, die in der praktischen Anwendung unvermeidbar sind.

Die Mehrheit der Arbeiten, also etwa zwei Drittel der analysierten Studien, verfolgt hingegen einen experimentellen Ansatz, bei dem Störungen gezielt und kontrolliert in ansonsten saubere Datensätze eingebracht werden. In diesen Fällen werden spezifische Algorithmen, regelbasierte Skripte oder Frameworks wie NLPAug, TextAttack oder DeepWordBug eingesetzt, um unterschiedliche Typen und Intensitäten von Störungen zu simulieren. Durch dieses Vorgehen lassen sich isolierte Effekte einzelner Fehlerarten präzise messen und Modelle hinsichtlich ihrer Sensitivität gegenüber orthografischen, syntaktischen oder semantischen Abweichungen vergleichen. Auf dieser Basis erfolgt im nächsten Schritt die detaillierte Betrachtung der Studien entlang der fünf in der SLR identifizierten Problemkategorien.

Orthografische Störungen

Orthografische Störungen stellen in der SLR die am häufigsten untersuchte Form von Datenqualitätsproblemen dar. Etwa ein Drittel der analysierten Arbeiten (n ≈ 24) widmet sich Veränderungen auf der Zeichenebene, bei denen die Schreibweise von Tokens manipuliert wird, während deren semantische Bedeutung erhalten bleibt.

Bagla et al. (2021) simulierten auf dem CoNLL-2003-Datensatz zufällige Zeichenersetzungen, -einfügungen und -vertauschungen mithilfe eines QWERTY-basierten Fehlermodells. Bei einem Fehleranteil von zehn Prozent sank der F1-Wert ihres BERT-Modells von 94,49 auf 84,96 Prozent, bei 25 Prozent auf 75,25 Prozent. RoBERTa (96,05 → 91,18 → 83,6), XLNet (95,85 → 90,02 → 81,88) und T5-base (95,67 → 90,09 → 79,90) blieben dabei robuster.

Moradi und Samwald (2021) erzeugten mit einem Skript Störungen auf Buchstaben- und Wortebene, indem sie Zeichen innerhalb der Tokens löschten, hinzufügten oder vertauschten. Auf Wortebene wurden teilweise auch kontextuelle Varianten eingeführt, wodurch die Ergebnisse nicht vollständig vergleichbar sind. Auf CoNLL-2003, wo pro Wort ein Buchstabe verändert wurde, verlor BERT 12,2 Punkte F1, RoBERTa 12,4, XLNet 12,2 und ELMo 10,2 Punkte.

Orthografische Varianten durch diakritische Veränderungen und Akzentfehler wurden von Náplava et al. (2021) untersucht. Sie nutzten ein selbst entwickeltes Skript, das systematisch Akzente entfernt oder ersetzt. Im Czech Named Entity Corpus 2.0 sank der F1-Wert des Czert-Modells von 87,8 auf 78,5 Prozent, also um 9,3 Punkte. In Kombination mit Buchstabenvertauschungen lag der Verlust bei etwa zwölf Punkten. Náplava et al. zeigten zudem, dass die Fehleranzahl einen stärkeren Einfluss auf die Robustheit hat als die Art des Fehlers selbst.

Araujo et al. (2020) prüften BERT-Modelle auf dem BC5CDR-Datensatz, indem sie Tastaturfehler, Buchstabenvertauschungen und synonymbasierte Ersetzungen simulierten. Alle relevanten Entitäten wurden verändert. Tastaturrauschen führte zu Einbußen von bis zu 30 Punkten, während andere Fehlerarten geringere, aber signifikante Verluste verursachten.

Moradi et al. (2021) beschrieben ergänzend, dass Wortverlängerungen durch Buchstabenwiederholungen bei einer Veränderungsrate von zehn Prozent zu einem F1-Verlust von etwa sechs Punkten führten.

Simoncini und Spanakis (2021) entwickelten mit SeqAttack ein Framework zur automatischen Erzeugung adversarialer Beispiele für NER. Mithilfe von DeepWordBug wurden Zeichen und Wörter gezielt verändert. Auf CoNLL-2003 sank der F1-Wert von BERT um rund 15 Punkte, konnte nach adversarialem Training jedoch auf unter fünf Punkte Verlust reduziert werden.

Fehler in der Groß- und Kleinschreibung erwiesen sich als besonders kritisch für Subword-Tokenisierung. Das & Paik (2022) berichteten, dass der F1-Wert von bert-base-cased bei vollständiger Kleinschreibung aller Tokens auf CoNLL-2003 von 92,3 auf 83,1 Prozent fiel.

Ähnliche Einbußen zwischen acht und elf Punkten fanden Al Sharou et al. (2021).

Shi et al. (2024) erzeugten in ihrer Studie komplexe Zeichenfehler wie Mehrfachvertauschungen, Buchstabenverdopplungen und fehlerhafte Trennzeichen. Diese Störungen wurden automatisiert generiert, indem mehrere Fehlerregeln kombiniert und kontrolliert auf einen Teil der Tokens angewendet wurden. Auf OntoNotes 5 sank der F1-Wert von BERT von 90,4 auf 81,7 Prozent, während RoBERTa auf 85,9 Prozent fiel.

Bhadauria et al. (2024) untersuchten orthografische Störungen mit der Bibliothek NLPAug, um realistische Tipp- und OCR-Fehler zu erzeugen. Dabei wurden 10 bis 30 Prozent der Tokens verändert. Dies beinhaltete zufällige Buchstabenvertauschungen, Einfügungen und Löschungen sowie OCR-Rauschen, das durch visuell ähnliche Zeichen ersetzt wurde. Auf CoNLL-2003, WNUT-16 und OntoNotes 5 führten Tippfehler zu Verlusten von fünf bis acht Punkten, OCR-Fehler zu bis zu 18 Punkten. Besonders robust war das charakterbasierte Flair-Modell, während BERT auf OCR-Störungen am empfindlichsten reagierte.

Namysl et al. (2020) führten ein Noise-Aware Training (NAT) ein, das gezielt orthografische Fehler in die Trainingsdaten einbringt. Die Autoren erstellten eine Fehlermatrix basierend auf häufigen OCR- und Tippfehlern und erzeugten daraus systematisch Störungen durch Buchstabenlöschungen, -einfügungen und -vertauschungen. Etwa ein Viertel der Tokens wurde so verändert, was zunächst zu Leistungseinbußen von bis zu 15 F1-Punkten führte. Durch das anschließende gemeinsame Training mit verrauschten und sauberen Daten gewann das Modell bis zu 10 Punkte zurück.

Auch bei realistisch verrauschten Datensätzen zeigte sich ein deutlicher Leistungsabfall. Esmaail et al. (2024) fanden für BERTweet und RoBERTa auf nutzergenerierten Texten F1-Werte zwischen 43 und 55 Prozent, gegenüber über 80 Prozent auf bereinigten Benchmarks. Hamdi et al. (2021) beobachteten auf OCR-Daten einen Rückgang um etwa 13 Punkte.

Syntaktische Störungen

Syntaktische Störungen betreffen Veränderungen der Wortstellung, der Satzgrenzen oder der internen Abhängigkeiten innerhalb eines Satzes. Etwa 15 % der in der SLR erfassten Arbeiten berücksichtigen explizit Eingriffe auf Satzebene.

Moradi & Samwald (2021) untersuchten syntaktische Eingriffe im Rahmen einer umfassenden Analyse zur Robustheit verschiedener Sprachmodelle (BERT, RoBERTa, XLNet, ELMo). Sie veränderten Wortreihenfolgen mithilfe der POS-Tags. Die Noise-Intensität wurde über den Anteil der veränderten Sätze gesteuert. Bei steigendem Noise sank der F1-Wert im NER-Task auf CoNLL-2003 um bis zu 16 Prozentpunkte, wobei ELMo am empfindlichsten auf Wortstellungsfehler reagierte, während RoBERTa relativ robust blieb.

Ähnlich verfuhren Náplava et al. (2021) in deren Arbeit, in der tschechische Sätze gezielt umgestellt und Artikel-Nomen-Positionen vertauscht wurden. Das Czert-Modell verlor dadurch je nach Szenario 8–12 F1-Punkte.

Nguyen & Chen (2023) analysierten in einer Cross-Lingual-Umgebung syntaktische Fehler, die aus inkonsistenter Satzsegmentierung resultieren. Durch künstlich erzeugte Kommasetzung und Nebensatzvertauschung wurde der Einfluss auf multilingual feingetunte BERT-Modelle getestet. Die F1-Werte sanken um 4–6 Punkte.

Bhadauria et al. (2024), Liang et al. (2024) und Ai et al. (2024) erzeugten syntaktische Störungen, indem sie zufällig Wörter oder ganze Satzteile löschten, Teilsätze und Wörter vertauschten sowie zusammenführten. Diese Verfahren simulieren Parser- oder Segmentierungsfehler und wurden zur Datenaugmentation in Kombination mit BERT-CRF, Flair und RoBERTa eingesetzt. Über mehrere Datensätze hinweg zeigten sich vergleichbare Effekte: Bei reinem Test-Noise gingen die F1-Werte typischerweise um 5 bis 9 Punkte zurück, während Modelle, die bereits im Training syntaktischen Störungen ausgesetzt waren, auf verrauschten Testdaten 2 bis 4 Punkte höhere F1-Werte als die zuvor genannten erzielten.

Semantische Störungen

Im Zentrum der semantischen Störungen konnten zwei Ansätze identifiziert werden: die Veränderung des Entitätskontexts und die direkte Manipulation der Entitäten. Unterschiede in der methodischen Umsetzung, etwa bei der Auswahl betroffener Tokens, der Störungsstärke oder des verwendeten Sprachmodells, führen zu teils deutlich abweichenden Ergebnissen. Zur Bewertung solcher Angriffe werden neben klassischen Metriken wie dem F1-Score zunehmend auch Erfolgsraten adversarialer Attacken (Attack Success Rate, ASR) herangezogen, die angeben, in welchem Anteil der Fälle eine Störung das Modell zu Fehlklassifikationen verleitet (Dirkson et al., 2021; Yu et al., 2025).

Die Manipulation des Entitätskontexts erwies sich bereits als hochwirksam. Chen et al. (2023) zeigten, dass ein BERT-base-Modell auf CoNLL-2003 bei der Ersetzung von fünf Kontextwörtern durch WordNet-Synonyme von 91,13 % auf 83,69 % F1 sank. Bei der Verwendung von Masked Language Modeling (MLM), bei dem maskierte Wörter durch kontextuell passende Alternativen ersetzt werden, sank der Wert sogar auf 80,50 %. Ähnliche Ergebnisse berichteten Srinivasan & Vajjala (2023), deren BERT-base-cased-Modell durch Synonymaustausch um sieben Prozentpunkte auf 84,1 % F1 absank.

Die Studie zu RockNER von Lin et al. (2021) untersuchte ebenfalls einen „Context Attack“ auf einem BERT-CRF-Modell (Baseline-F1: 90,6 % auf OntoNotes) und einem RoBERTa-CRF-Modell (Baseline-F1: 92,4 % auf OntoNotes). Durch die Ersetzung von Kontextwörtern mittels

BERT-MLM fiel der F1-Score auf 85,8 % beziehungsweise 87,2 %. Dabei wurden semantisch reiche Wörter wie Nomen und Verben, höchstens drei pro Satz, maskiert und anschließend deren Alternativen generiert. Noch stärkere Einbußen traten auf, wenn Entitäten direkt verändert wurden: Der Austausch von Entitäten durch andere derselben Klasse aus Wikidata senkte die Werte auf 59,2 % (BERT-CRF) und 63,4 % (RoBERTa-CRF).

Dirkson et al. (2021) bezeichneten BERT-Modelle als besonders anfällig für sogenannte „emergent entities“, also Entitäten, die im Training nicht vorkamen und daher vom Modell nicht korrekt erkannt werden. In ihren Experimenten führten sie mehrere Angriffsszenarien durch, bei denen mithilfe einer Importance-Ranking-Funktion und Paragram-SL999-Word-Vektoren semantisch unterschiedliche, zuvor unbekannte Entitätsnamen erzeugt wurden. Diese wurden anschließend gefiltert, um Duplikate und zu ähnliche Varianten zu vermeiden. Obwohl kein F1-Score gemessen wurde, zeigten ihre Ergebnisse, dass BERT-Modelle insbesondere auf medizinischen Datensätzen empfindlich auf solche Veränderungen reagierten: Zwischen 20 % und 40 % der Entitäten wurden nicht mehr korrekt erkannt.

Auch Srinivasan und Vajjala (2023) implementierten Manipulationen, die Entitäten direkt betrafen. Diese Methode führte bei ihrem BERT- Modell zu einem F1-Abfall von 7,1 Prozentpunkten, also von 91,1 % auf 84,0 %. Die Ersetzungen erfolgten mithilfe von Gazetteers, die auf der Python Faker-Library basierten.

Einige Studien kombinierten beide Ansätze. Bei RockNER führte dies bei BERT-CRF zu einem F1-Wert von 54,6 % (−36 Prozentpunkte) und bei RoBERTa-CRF zu 58,5 % (−33,9 Prozentpunkte). Jin et al. (2023) kombinierten ebenfalls beide Störungen, indem sie auf Wortattributionen basierende, semantisch gewichtete Tokens veränderten, also gezielt die für das Modell wichtigsten Wörter ersetzten. Für Entitäten wurden mithilfe von Wikidata alternative Begriffe derselben Kategorie gewählt, während GPT-J für Kontextwörter passende Ersetzungen vorschlug, indem es maskierte Sätze vervollständigte und die ähnlichsten Varianten auswählte. Dabei wurden nur ein bis drei Wörter pro Satz verändert, um die Bedeutung weitgehend zu erhalten. Diese semantisch kontrollierten Störungen führten zunächst zu deutlichen Leistungseinbrüchen (OntoNotes 5.0: F1 ≈ 90 → 51 %; CoNLL-2003: 98 → 79 %). Durch den Einbezug der adversarialen Beispiele in das Training stiegen die Werte jedoch wieder deutlich an, auf 69 % bzw. 87 % F1, also um 18 bzw. 8 Prozentpunkte.

Semantische Störungen werden in neueren Arbeiten zunehmend auch für robustheitsorientiertes Training genutzt. Simoncini und Spanakis (2021) zeigten mit SeqAttack, dass semantische Substitutionen zwar hohe Angriffsraten verursachen, adversariales Training damit jedoch die Robustheit deutlich verbessert, beispielsweise um 6 bis 20 Prozentpunkte im Nach-Angriff-F1. Ai et al. (2024) fanden ebenfalls, dass kontrastive Augmentation die Robustheit eines RoBERTa-CRF-Modells um 3,1 F1-Punkte erhöhen kann.

Ying et al. (2022) nutzten die Ideen von RockNER als Data Augmentation im Training. Dies machte ihr BERT-CRF-Modell auf dem Ontonotes4.0-Datensatz deutlich robuster: Der Schaden durch Angriffe auf die Testdaten wurde von 32% F1-Verlust auf nur noch 2-5% F1-Verlust reduziert.

Darüber hinaus existiert eine Reihe weiterer Arbeiten, die verschiedene Angriffsverfahren präsentieren, darunter CLARE (D. Li et al., 2021), BERT-Attack (L. Li et al., 2020) , BAE (Garg & Ramakrishnan, 2020) und andere. Diese nutzen Techniken wie MLM-gestützte Maskierung zur kontextsensitiven Ersetzung, Nearest-Neighbor-Suchen in statischen oder kontextuellen Embedding-Räumen, Entity-Replacement über Wikidata oder Gazetteers sowie Importance-Ranking. In vielerlei Hinsicht erzeugen die generierten Attacken keine grammatikalisch oder inhaltlich sinnvollen Sätze, sondern dienen vor allem dazu, zu testen, wie einem Modell maximaler Schaden zugefügt werden kann.

Einige Studien erzeugten außerdem Paraphrasen, die sich als wirksam für Entity Attacks erwiesen. Allerdings gaben Srinivasan und Vajjala (2023) an, dass es zu Schwierigkeiten beim Rückmapping der Labels kam, da in ihrem Fall QuillBot die Entitäten nicht immer beibehielt.

Label-Ebene

Störungen auf Label-Ebene (Label Noise) werden in der Forschung auf unterschiedliche Weise adressiert. Ein Großteil der Arbeiten evaluiert Modelle auf Datensätzen, die bereits reale Annotationsfehler aufweisen, oft resultierend aus Distant Supervision oder Crowdsourcing. Die Noisebench-Studie von Merdjanovska et al. (2024) ist hierfür exemplarisch. Sie kuratierte Datensätze mit realem Rauschen wie "Missing mentions" oder "Incorrect entity type" und quantifizierte den F1-Verlust im Vergleich zu sauberen Daten je nach Rauschtyp auf -4,1 bis zu drastischen -31,4 Punkten. Ein Modell wird auf diesen Trainingsvarianten trainiert, und dann auf einem sauberen Test-Set ausgewertet. Ähnlich zeigten Zhu et al. (2022), dass Rauschen aus "Weak Supervision" zu Leistungsverlusten von bis zu 35 Prozentpunkten führen kann.

Als Reaktion auf diese Problematik versuchen einige Studien, die Daten zu bereinigen und den Effekt zu messen. Cai & O'Connor (2024) zeigten, dass eine manuell korrigierte Version, eine durchschnittliche F1-Verbesserung von 14 Punkten gegenüber dem fehlerhaften Original erzielte.

Ein dritter Ansatz ist die gezielte Generierung synthetischer Labelstörungen, um die Robustheit von Modellen zu testen. Fokam & Beukman (2022) implementierten hierfür kontrollierte „corruption strategies“ auf Trainingsdaten, darunter das Löschen von Labels, bei dem Entitäten durch die „O“-Klasse ersetzt wurden, sowie das Vertauschen von Entitätstypen. Bei einer maximalen Korruptionsstufe, bei der 90 Prozent aller Entitätslabels verändert wurden, brach die

Modellleistung um etwa 90 Prozent des ursprünglichen F1-Scores ein. Bemerkenswert war, dass Modelle trotz einer Reduktion auf nur 10 Prozent der Trainingssätze noch rund 75 bis 80 Prozent ihrer ursprünglichen F1-Performance beibehielten, solange die verbleibenden Labels korrekt waren. Damit zeigte die Studie deutlich, dass die Qualität der Annotationen wichtiger ist als die Menge der Trainingsdaten. Die Untersuchung umfasste vier vortrainierte Sprachmodelle, darunter AfriBERTa, Afro-XLM-R, XLM-R und mBERT. Alle Modelle reagierten ähnlich empfindlich auf fehlerhafte Labels, zeigten jedoch eine bemerkenswerte Robustheit gegenüber reduzierter Datenmenge. Afro-XLM-R erzielte im Durchschnitt die besten Ergebnisse, während mBERT etwas schwächer abschnitt.

Besonders differenzierte Angriffe generierten Tian et al. (2023) Tian et al., um die Effektivität ihres UseClean-Frameworks zu testen. Dazu konstruierten sie synthetische Rauschdatensätze, in denen typische Fehleroperationen auf Token- und Spannebene simuliert wurden. Zu diesen Fehlern gehörten das gezielte Flippen von Entitäts-Labels zur 'O'-Klasse und um-gekehrt (Miss/Over), das programmatische Verschieben, Erweitern oder Verkürzen der exakten Entitätsgrenzen (sogenannte Span-Fehler wie Shift, Extend, Shrink) sowie komplexe Klassen-Fehler. Letztere umfassten das "Swap", also das Flippen einer Klasse zu einer zufäl-ligen anderen Klasse, und das "Bias"-Verfahren, bei dem eine Klasse basierend auf einer vor-definierten Übergangsmatrix gezielt zu einer bestimmten anderen Klasse geändert wurde. Die Rauschintensität wurde schrittweise zwischen 30 und 100 Prozent variiert, um unterschiedliche Fehlerszenarien zu erzeugen.

Sonstige Störungen

Studien zu sonstigen Störungen analysieren oft real verrauschte Datensätze, ohne Fehler künstlich zu generieren. Esmaail et al. (2024) fassen für User-Generated Content Störungen wie "Slang", "Emojis" und "URLs" zusammen und stellen fest, dass Standardmodelle hier eine schlechte Performanz aufweisen. Argumentiert wird es mit allgemein schlechter Leistung auf WNUT-Datensätzen

Einen anderen Ansatz zur Analyse inhärenter Schwächen verfolgten Bernier-Colborne & Langlais (2020) mit ihrem "HardEval"-Framework. Sie generierten keine Fehler, sondern nutzten die Standard-Evaluierung, um die Gesamtmenge aller Fehler eines Modells zu identifizieren. Anschließend analysierten sie durch Fehler-Attribution, ob diese Fehler auf Token entfielen, die sie als "schwierig" kategorisiert hatten (spezifisch "Unknown words" und "Label shift"). Ihre Auswertung belegte, dass diese kleine Gruppe von "challenging tokens", obwohl sie nur einen Bruchteil des Test-Sets ausmachte, für die Mehrheit der Modellfehler verantwortlich war.

4.3.3 Zusammenfassung

Die SLR zeigt, dass in der bisherigen Forschung eine Vielzahl unterschiedlicher Datenstörungen untersucht wird, die sich fünf Hauptkategorien zuordnen lassen: orthografische, syntaktische, semantische, Label-bezogene und sonstige Störungen. Orthografische Veränderungen bilden dabei die am häufigsten analysierte Gruppe, während syntaktische und semantische Eingriffe sowie Label Noise deutlich seltener systematisch betrachtet werden.

Wird Noise auf den Testdatensatz angewendet, zeigen die Modelle über alle Kategorien hinweg deutliche Leistungseinbußen, deren Ausmaß von Art und Intensität der Störung abhängt. Orthografisches Rauschen führt typischerweise zu F1-Verlusten zwischen 5 und 20 Punkten, syntaktische Veränderungen zu etwa 5–15 Punkten. Semantische Störungen verursachen die größten Einbußen mit Spannweiten von 7 bis über 35 Punkten, vereinzelt auch darüber, insbesondere wenn Entitäten oder ihr Kontext verändert werden.

Werden Störungen dagegen gezielt im Training integriert, können die Verluste in unterschiedlichem Maße kompensiert werden. Bei orthografischem Noise werden regelmäßig Rückgewinne von 5 bis 10 F1-Punkten beobachtet, teils verbunden mit einer gesteigerten Generalisierungsfähigkeit. Für syntaktisches Rauschen fallen die Rückgewinne geringer aus (meist unter 5 Punkte) und sind nicht in allen Studien nachweisbar. Bei semantischen Störungen im Trainingsprozess variieren die Ergebnisse stark, auch davon abhängig wie sehr die Werte davor gefallen sind. Viele dieser Arbeiten zielen zudem weniger auf eine systematische Robustheitsanalyse ab, sondern auf die Konstruktion gezielter Angriffe, die teils wenig mit real vorkommenden Textvariationen gemein haben.

Bei Label Noise wird ausschließlich der Trainingsdatensatz verändert. Durch fehlerhafte oder vertauschte Annotationen lernt das Modell falsche Zusammenhänge, was die Erkennungsleistung nachhaltig mindert. Beobachtete F1-Verluste liegen je nach Anteil fehlerhafter Labels zwischen etwa 4 und über 30 Punkten.

Die teils erheblichen Unterschiede in den Ergebnissen lassen sich vor allem auf methodische Heterogenität und die uneinheitliche Definition der Störungsintensität zurückführen. Studien unterscheiden sich deutlich darin, in welchem Umfang und in welcher Form Qualitätsminderungen eingebracht werden. Häufig werden einzelne Fehlerarten aus bestimmten Störungskategorien isoliert betrachtet, ohne dass die weiteren, in der Praxis tatsächlich vorkommenden Formen von Qualitätsminderung einbezogen werden. Ein systematischer Vergleich zwischen den verschiedenen Kategorien findet in der bestehenden Forschung kaum statt.

Darüber hinaus variiert, wie die Intensität der Störungen gemessen wird. In einigen Arbeiten wird der Veränderungsanteil gar nicht quantifiziert, in anderen kommen unterschiedliche Messgrößen zum Einsatz, etwa der prozentuale Anteil veränderter Tokens, Sätze oder Entitäten.

Ein Wert von „10 % Störung“ kann daher je nach Studie etwas völlig anderes bedeuten. Teilweise werden zudem selbstdefinierte Stufenmodelle wie „low“, „medium“ oder „high“ verwendet, deren Umfang nicht direkt vergleichbar ist.

Diese Unterschiede führen dazu, dass die tatsächliche Intensität der Qualitätsminderung selbst bei identischen Bezeichnungen stark variiert – sowohl innerhalb als auch zwischen den Kategorien orthografischer, syntaktischer und semantischer Störungen. Hinzu kommt, dass einige Arbeiten nicht primär die Robustheit, sondern gezielt die Verletzbarkeit von Modellen untersuchen, was erwartungsgemäß zu stärkeren Leistungseinbrüchen führt.

Diese Uneinheitlichkeit in Definition, Messung und Zielsetzung erschwert eine vergleichbare Bewertung der Robustheit. Sie verdeutlicht die Notwendigkeit standardisierter Experimente, in denen Art und Intensität der Störungen kontrolliert und konsistent variiert werden, um ihren Einfluss auf die Modellleistung systematisch zu erfassen.

Bei der Generierung von Störungen wurden überwiegend eigene Skripte eingesetzt. Zusätzlich kamen jedoch auch Frameworks wie NLPAug, TextAttack, SeqAttack sowie einzelne Methoden und Implementierungen wie CLARE, BERT-Attack, BAE oder DeepWordBug zum Einsatz, die auch für die Umsetzung der eigenen Experimente relevant sein können.

5 Experimente

Das folgende Kapitel beschreibt die Konzeption und Umsetzung der Experimente, mit denen systematisch untersucht wird, wie unterschiedliche Störungstypen und Intensitäten die Modellleistung beeinflussen. Zudem wird in Bezug auf die Forschungsfragen FF3 und FF4 analysiert, wie sich diese Effekte zwischen Modellarchitekturen unterscheiden und wie identische Qualitätsminderungen in Trainings- und Testdaten unterschiedlich wirken.

5.1 Generelles Vorgehen

Die SLR zeigte, dass die meisten Arbeiten Störungen auf den Testdatensatz anwenden, um die Robustheit der Modelle im praktischen Einsatz zu bewerten. Weniger häufig wird dagegen der Trainingsdatensatz verändert, um zu prüfen, ob und in welchem Umfang sich die Robustheit durch das gezielte Einbringen von Störungen während des Lernprozesses kompensieren oder verbessern lässt. Nur selten wird dabei jedoch systematisch analysiert, ab welchem Punkt der Nutzen solcher Maßnahmen durch eine Verschlechterung der allgemeinen Modellleistung wieder aufgehoben wird. Dies soll im Rahmen dieser Experimente geschehen.

Ein weiterer bislang wenig beachteter Aspekt betrifft den Validierungsdatensatz. In der Literatur wird dieser sehr unterschiedlich behandelt, da manche Studien ihn zur Leistungsbewertung heranziehen, während andere ausschließlich auf einem separaten Testdatensatz evaluieren. Grundsätzlich sollte angemerkt werden, dass die Bewertung eines Modells auf Basis des Validierungsdatensatzes häufig nur begrenzt aussagekräftig ist, da sich das Modell während des Trainings bereits an diese Daten anpassen kann (I. Goodfellow et al., 2016). Aus diesem Grund erfolgt in allen nachfolgenden Experimenten eine klare Trennung von Trainings-, Validierungs- und Testdaten, wobei die finale Leistungsbewertung ausschließlich auf dem Testdatensatz durchgeführt wird.

In der Literatur bleibt zudem häufig unklar, ob der Validierungssatz während eines Trainings mit gestörten Daten unverändert bleibt oder ebenfalls Störungen aufweist. Um diesen Punkt zu adressieren, wird im Rahmen dieser Arbeit festgelegt, dass bei gestörtem Training der Validierungssatz dieselben Störungsbedingungen erfährt wie der Trainingsdatensatz.

Aus diesen Überlegungen ergeben sich vier grundlegende Versuchsanordnungen, die verschiedene Kombinationen von Störungsbedingungen in Training, Validierung und Test abbilden. Diese lauten:

(1) Training ohne Störungen, Validierung ohne Störungen, Test mit Störungen
(2) Training mit Störungen, Validierung mit Störungen, Test mit Störungen
(3) Training mit Störungen, Validierung mit Störungen, Test ohne Störungen

Für Label-bezogene Störungen sind ausschließlich die dritte Versuchsanordnung relevant. Da eine Verfälschung der Labels im Testdatensatz zwangsläufig zu einem unmittelbaren Verlust der F1-Werte führt, unabhängig von der tatsächlichen Modellgüte, wäre eine solche Untersuchung nicht aussagekräftig. Entsprechend konzentriert sich die Analyse Label-bezogener Qualitätsminderungen auf Szenarien, in denen die Störungen im Trainings- oder Validierungsdatensatz auftreten und somit den Lernprozess selbst beeinflussen.

Für die Evaluierung werden die in der SLR identifizierten Datenstörungen, gruppiert nach den Kategorien Orthographisch, Syntaktisch, Semantisch und Label-bezogen, synthetisch generiert und untersucht. Dies ermöglicht einen direkten Vergleich der Auswirkungen verschiedener Störungsarten. Für die orthografischen und semantischen Störungskategorien werden zusätzlich gezielte Experimente durchgeführt, bei denen entweder nur Tokens innerhalb der Entitäten oder ausschließlich Tokens im umgebenden Kontext verändert werden. Dadurch kann untersucht werden, ob Modelle empfindlicher auf Veränderungen der Entitäten selbst oder auf Abweichungen ihres Kontexts reagieren. Die genaue Implementierung der Störungsgenerierung wird in Kapitel 5.5 beschrieben.

Die Kategorie 'Sonstige' wird von dieser Untersuchung ausgeschlossen. Die darin enthaltenen UGC-Artefakte (z. B. Slang, Emojis) oder ASR-Noise sind methodisch nur schwer zu generieren. Auch in der Literatur wurden keine Implementierungen genannt. Insbesondere realistischer Slang oder kontextuell passende Emojis lassen sich kaum systematisch steuern. Darüber hinaus handelt es sich um hybride Störungen. Im Falle eines Leistungsabfalls bliebe unklar, ob dieser auf die unkonventionelle Grammatik, also die syntaktische Ebene, oder ein unbekanntes Wort, also die semantische Ebene, zurückzuführen ist. Der Fokus dieser Arbeit liegt daher bewusst auf isolierbaren, atomaren Störungsarten, um eine trennscharfe Analyse der Forschungsfragen zu gewährleisten.

Zur Quantifizierung der Störungsintensität wird der prozentuale Anteil der veränderten Tokens als zentrale Messgröße verwendet. Um die Entwicklung der Modellleistung nachvollziehbar zu untersuchen, werden die Experimente in aufsteigenden Intervallen von zehn Prozent durchgeführt. Es werden somit Störungsstufen von 10, 20, 30 Prozent analysiert. Intensitäten oberhalb von 30 Prozent werden als in der Praxis unrealistisch betrachtet und daher nicht berücksichtigt. Jede Experimentkonfiguration wird fünfmal wiederholt, um zufällige Schwankungen zu minimieren und die Stabilität der Ergebnisse zu überprüfen. Auf diese Weise kann auch bewertet werden, in welchem Maß sich die beobachteten Effekte reproduzieren lassen. Die Streuung der Ergebnisse wird anhand der Standardabweichung ausgewiesen. Wie in Kapitel 2.4 erläutert, eignen sich die Metriken Precision, Recall und insbesondere der F1-Score in seiner micro-averaged Form besonders für die Bewertung von NER-Modellen. Sowohl in der SLR als auch in den hier beschriebenen Experimenten erfolgt die Leistungsbewertung daher auf dieser Grundlage.

Im Rahmen der Experimente stellen darüber hinaus die gewählten Modelle und der verwendete Datensatz zwei zentrale unabhängige Variablen dar. Ihre Auswahl sowie die jeweiligen Eigenschaften und Begründungen werden in den nachfolgenden Kapiteln beschrieben.

5.2 Auswahl Modelle

Die SLR zeigte, dass in der bisherigen Forschung überwiegend BERT-basierte Modelle verwendet wurden. Vereinzelt kamen auch XLNet und RoBERTa zum Einsatz. Um eine Vergleichbarkeit der hier erzielten Ergebnisse mit den in der Literatur berichteten Befunden zu gewährleisten, werden diese Modelle ebenfalls in die Experimente einbezogen. Darüber hinaus werden mit DeBERTa, DistilBERT und CANINE drei weitere Modellvarianten einbezogen, die durch unterschiedliche architektonische oder trainingsbezogene Anpassungen charakterisiert sind. Diese Modelle sind weit verbreitet, unterscheiden sich jedoch in zentralen Aspekten wie der Repräsentationsebene, der Größe oder der Attention-Struktur. Dadurch eignen sie sich besonders gut, um die in Forschungsfrage FF4 formulierten Zusammenhänge zwischen Architekturmerkmalen und Robustheit zu untersuchen. Diese werden im Folgenden näher beschrieben.

BERT

BERT nach Devlin et al. (2019) bildet das Grundmodell der meisten heutigen Sprachverarbeitungsarchitekturen. Wie in Kapitel 2.2 beschrieben, nutzt es den Encoder des Transformers und erweitert diesen um zwei Pretraining-Aufgaben: das Masked Language Modeling, bei dem zufällig ausgewählte Tokens anhand des Kontexts rekonstruiert werden, und die Next Sentence Prediction, mit der das Modell lernt, ob zwei Sätze inhaltlich zusammengehören.

Neben Token- und Positions-Embeddings werden Segment-Embeddings eingesetzt, um Satzgrenzen zu kennzeichnen. Die Tokenisierung erfolgt mithilfe des WordPiece-Verfahrens, das Wörter in häufige Untereinheiten zerlegt. In dieser Arbeit wird das Modell BERT-Base verwendet, das aus zwölf Encoder-Schichten mit jeweils zwölf Attention-Heads und rund 110 Millionen Parametern besteht. (Devlin et al., 2019).

RoBERTa

RoBERTa (Robustly Optimized BERT Approach) nach (Y. Liu et al., 2019)baut direkt auf BERT auf, unterscheidet sich jedoch im Trainingsverfahren. Auf die Next Sentence Prediction wird verzichtet, um die gesamte Rechenkapazität auf das MLM zu konzentrieren. Das Maskierung erfolgt dynamisch, das heißt, die verdeckten Tokens werden in jeder Epoche neu bestimmt, wodurch das Modell eine größere Vielfalt sprachlicher Kontexte erlernt.

Zudem wurde RoBERTa auf einer etwa zehnmal größeren Datenbasis trainiert, die rund 160 GB Text aus Common Crawl, OpenWebText und Wikipedia umfasst. Die Modellarchitektur bleibt unverändert und besteht aus zwölf Encoder-Schichten mit zwölf Attention-Heads und 768-dimensionalen Hidden States (Y. Liu et al., 2019).

XLNet

XLNet nach Yang et al. (2019) erweitert die Transformer-Architektur durch das Permutation Language Modeling, bei dem die Reihenfolge der Tokens während des Trainings variiert wird. Dadurch kann das Modell kontextuelle Abhängigkeiten in beide Richtungen erfassen, ohne Tokens maskieren zu müssen.

Zur Umsetzung nutzt XLNet den Two-Stream Self-Attention-Mechanismus, bestehend aus einem Content Stream, der den bisherigen Kontext verarbeitet, und einem Query Stream, der das nächste Token vorhersagt, ohne dessen Inhalt zu kennen. Die Berechnung erfolgt weiterhin über Multi-Head Self-Attention, wobei jeder Head unterschiedliche Kontextaspekte innerhalb der beiden Streams modelliert. Abbildung 6 veranschaulicht den Aufbau dieses Mechanismus.

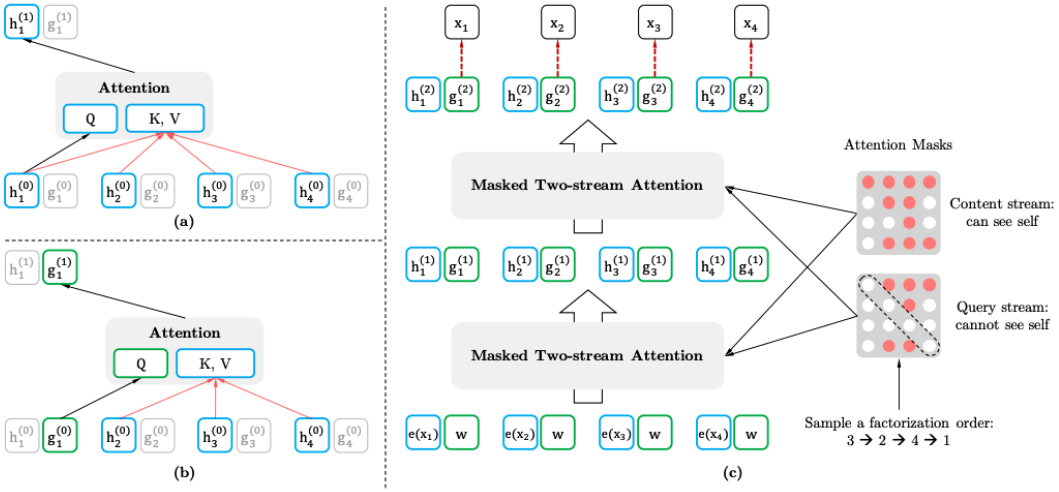


Abbildung 6: Two-Stream Self-Attention-Mechanismus in XLNet- Teil (a) zeigt Content-Stream Attention, welche gleich wie BERTs Standard-Self-Attention ist. Teil (b) stellt die erweiterte Variante für den Query Stream dar, in der das aktuelle Token ausgeschlossen wird. Teil (c) zeigt schließlich die vollständige Struktur des Masked Two-Stream-Attention-Verfahrens, bei dem beide Streams gemeinsam arbeiten. Die Attention Masks rechts regeln welche Tokens sich gegenseitig sehen dürfen Abbildung aus (Z. Yang et al., 2019).

Zusätzlich verwendet XLNet relative Positions-Embeddings und das Transformer-XL-Framework, wodurch auch längere Textzusammenhänge berücksichtigt werden können. Die Architektur entspricht in Größe BERT-Base mit zwölf Encoder-Schichten und zwölf Attention-Heads.(Z. Yang et al., 2019).

DeBERTa

DeBERTa (Decoding-enhanced BERT with Disentangled Attention) von He et al. (2020) stellt eine architektonische Weiterentwicklung der BERT-Struktur dar. Während klassische Modelle wie BERT die inhaltliche und positionsbezogene Information eines Tokens in einem gemeinsamen Vektor kombinieren, trennt DeBERTa diese beiden Komponenten. Jedes Token wird durch einen Content-Vektor, der seine semantische Bedeutung repräsentiert, und einen Position-Vektor, der seine Position innerhalb der Sequenz beschreibt, dargestellt. Während XLNeT die Richtung und Struktur der Aufmerksamkeit verändert, verändert DeBERTa die inhaltliche Zusammensetzung der Vektoren. Die Architektur entspricht in ihrem Aufbau der BERT-Base-Struktur mit zwölf Encoder-Schichten und zwölf Attention-Heads, umfasst jedoch durch die erweiterten Gewichtungen rund 135 Millionen Parameter (He et al., 2020).

DistilBERT

DistilBERT von Sanh et al. (2019) ist eine komprimierte Variante von BERT, die mithilfe des Verfahrens der Knowledge Distillation trainiert wurde. Dabei übernimmt ein kleineres Student-Modell das Wissen eines großen, vollständig trainierten Teacher-Modells. Im Fall von DistilBERT fungiert BERT als Lehrer, dessen Wahrscheinlichkeitsverteilungen und versteckte Zustände das kleinere Modell während des Trainings nachahmt.

Die Architektur wurde von zwölf auf sechs Encoder-Schichten reduziert, während die Struktur der Self-Attention und die Dimension der Hidden States unverändert bleiben. Durch diese Vereinfachung sinkt die Parameterzahl auf rund 66 Millionen. Auf NSP wurden ebenfalls verzichtet (Sanh et al., 2019).

CANINE

CANINE (Character Architecture with No Tokenization in Encoding) wurde von Clark et al. (2022) entwickelt und unterscheidet sich grundlegend von den bisher beschriebenen Subword-basierten Modellen. Anstatt Wörter oder Wortbestandteile zu verwenden, verarbeitet CANINE Texte direkt auf Zeichenebene. Damit entfällt die Notwendigkeit einer Tokenisierung und eines festen Vokabulars

Wie in Abbildung 7 dargestellt, kombiniert CANINE konvolutionale und Transformer-basierte Komponenten. Zunächst werden Zeichen in Character-Embeddings überführt und in einem lokalen Transformer kontextualisiert. Anschließend reduziert eine strided Convolution die Sequenzlänge, um benachbarte Zeichen zu bündeln. Die so verdichtete Repräsentation wird in einem tiefen Transformer-Stack global verarbeitet, bevor sie über ein Upsampling wieder auf Zeichenebene projiziert und durch einen abschließenden Transformer verdichtet wird.

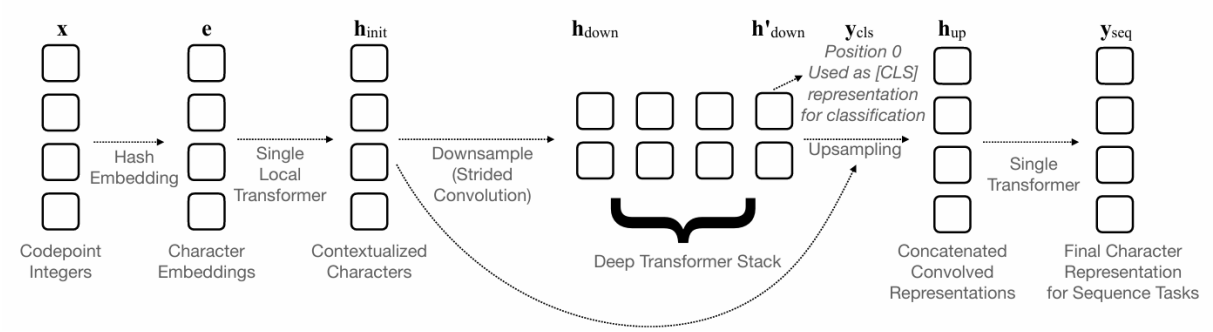


Abbildung 7: CANINE-Architektur- Abbildung zeigt mehrstufigen Aufbau des Modells mit zeichenbasierter Eingabe und der Kombination lokaler sowie globaler Verarbeitungsschritte (Clark et al., 2022)

Das Training erfolgt selbstüberwacht nach dem Prinzip des Masked Language Modeling, jedoch auf Zeichenebene. Die Base-Version umfasst etwa 120 Millionen Parameter und bildet eine vollständig tokenfreie Variante der Transformer-Modelle (Clark et al., 2022).

5.3 Auswahl Datensatz

Für die Analyse der Auswirkungen von Datenstörungen wird ein Datensatz mit möglichst hoher Ausgangsqualität benötigt, um Veränderungen in der Modellleistung eindeutig den eingeführten Störungen zuordnen zu können. Ein etablierter und vielfach genutzter Datensatz ist CoNLL-2003 (Tjong Kim Sang & Meulder, 2003).Er eignet sich durch seine saubere Struktur und Standardisierung besonders gut für Named-Entity-Recognition-Experimente und wird auch in zahlreichen Studien der SLR verwendet, was eine hohe Vergleichbarkeit der Ergebnisse ermöglicht.

In dieser Arbeit wird bewusst nur ein einzelner Datensatz eingesetzt, um eine größere Zahl systematischer Experimente mit unterschiedlichen Modellarchitekturen und Störungsarten durchführen zu können. Der englischsprachige CoNLL-2003-Datensatz basiert auf Texten der Nachrichtenagentur Reuters und umfasst vier Entitätskategorien: PER (Personen), LOC (Orte), ORG (Organisationen) und MISC (sonstige Entitäten). Er enthält rund 22.000 Sätze mit etwa 300.000 Tokens, die in Trainings-, Validierungs- und Testdaten unterteilt sind (Tjong Kim Sang & Meulder, 2003).

5.4 Entwicklung Baseline Modell

Jedes der in Kapitel 5.2 beschriebenen Modelle wird einmal auf Basis des CoNLL-2003-Datensatzes trainiert, um eine Referenz für die spätere Analyse zu schaffen, wie stark sich Modellleistungen durch Datenstörungen verändern. Das Training erfolgt mithilfe der Hugging Face Transformers-Bibliothek (Wolf et al., 2020) unter Verwendung der Trainer-API, die Trai-

ning, Validierung und Evaluation in einer einheitlichen Umgebung zusammenführt (HuggingFace, 2025d). Der vollständige Code zur Implementierung, einschließlich Datenvorverarbeitung, Training und Evaluierung, ist über ein öffentlich zugängliches GitHub-Repository verfügbar.[1]

Die Datensätze werden über die Datasets-API geladen und in ein standardisiertes Format überführt, das Tokens und zugehörige Entitätslabels im, in Kapitel 2.1 erklärten, BIO-Schema enthält. Diese Struktur ermöglicht eine effiziente Verarbeitung und Transformation der Daten, insbesondere in Kombination mit dem Trainer-Framework von Hugging Face (HuggingFace, 2025a).

Wie in Kapitel 2.2 erläutert, erfolgt die Vorverarbeitung der Eingabedaten zunächst durch den Tokenizer, der den Rohtext in kleinere Einheiten zerlegt und in numerische IDs übersetzt. Bei Subword-basierten Modellen wie BERT, RoBERTa, DeBERTa, XLNet oder DistilBERT geschieht dies mithilfe von Verfahren wie WordPiece oder Byte-Pair Encoding. Dabei werden Wörter anhand statistischer Häufigkeiten in häufig vorkommende Untereinheiten zerlegt. So kann ein einzelnes Wort aus mehreren Subtokens bestehen, die jeweils über eigene Vektorrepräsentationen verfügen (Devlin et al., 2019; Rogers et al., 2020).

Da die ursprünglichen Labels des CoNLL-Datensatzes auf Wortebene vergeben sind, entsteht durch diese Zerlegung eine Schieflage zwischen der Anzahl der Tokens und der Anzahl der Labels. Um dies auszugleichen, ordnet die tokenize_and_align()-Methode[2] standardmäßig das Label eines Wortes nur dem ersten Subtoken zu, während alle nachfolgenden Subtokens mit einem neutralen Platzhalterwert (−100) versehen werden, der beim Training ignoriert wird. Dieses Vorgehen verhindert, dass lange Wörter mit vielen Subtokens überproportional in die Berechnung des Modellverlusts eingehen. Andernfalls würde ein Wort, das in viele Untereinheiten zerfällt, mehrfach in den Lernprozess einfließen und dadurch das Gewicht seiner Entität künstlich erhöhen (HuggingFace, 2025b, 2025c).

Trotz dieser Reduktion auf das erste Subtoken wird bei der späteren Evaluation weiterhin die gesamte Entität betrachtet. Eine Entität gilt also nur dann als korrekt erkannt, wenn alle zugehörigen Wörter vollständig und mit dem richtigen Typ vorhergesagt wurden. Auf diese Weise bleibt die semantische Integrität der Entitäten erhalten, während gleichzeitig eine faire Gewichtung während des Trainings gewährleistet wird. Es handelt sich dabei um die etablierte Standardpraxis in NER-Projekten mit Subword-basierten Sprachmodellen und entspricht den Evaluierungskriterien, wie sie auch in der ursprünglichen CoNLL-2003-Benchmark verwendet werden (HuggingFace, 2025b; Tjong Kim Sang & Meulder, 2003).

[1] https://github.com/denis-trtnr/ner-quality-impact
[2] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/data_preprocessing.py

Für das zeichenbasierte Modell CANINE wird die angepasste Methode tokenize_and_align_chars() eingesetzt, die den textuellen Input auf der Ebene einzelner Zeichen verarbeitet. Im Gegensatz zu Subword-basierten Modellen wird der Text hierbei vollständig in seine einzelnen Buchstaben zerlegt, sodass jedes Zeichen eine eigene Eingabeeinheit für das Modell bildet. Da die Annotationen des CoNLL-Datensatzes weiterhin auf Wortebene vorliegen, überträgt die Methode die zugehörigen Labels auf die Zeichenebene, um eine konsistente und modellgerechte Trainingsstruktur zu erzeugen.[3]

Während des Trainings wird das Label eines Wortes über alle seine Zeichen hinweg ausgedehnt. Befindet sich ein Wort beispielsweise am Anfang einer Entität, die im BIO-Schema mit einem B-Label markiert ist, erhalten alle nachfolgenden Zeichen dieses Wortes ein entsprechendes I-Label, sodass der zusammenhängende Entitätskontext erhalten bleibt. Zwischen zwei Wörtern wird ein neutrales Label eingefügt, das Leerzeichen oder Trennsymbole repräsentiert. Auf diese Weise wird der Wortkontext über die gesamte Zeichenfolge hinweg abgebildet.

Für die Evaluation wird das Vorgehen angepasst, um eine faire Vergleichbarkeit mit den Subword-basierten Modellen sicherzustellen. Hierbei wird nur das erste Zeichen eines Wortes mit dem entsprechenden Label versehen, während alle weiteren Zeichen mit −100 markiert und bei der Bewertung ignoriert werden. Dadurch wird jedes Wort, unabhängig von seiner Länge, nur einmal berücksichtigt, und die Auswertung erfolgt weiterhin auf Wort- und Entitätsebene. Die Methode stellt somit sicher, dass die Besonderheiten der Zeichenverarbeitung von CANINE berücksichtigt werden, ohne von den etablierten NER-Evaluationsprinzipien abzuweichen.[4]

Das anschließende Fine-Tuning der Modelle erfolgt mit einheitlichen Trainingsparametern, um eine faire Vergleichbarkeit sicherzustellen. Die Modelle werden mit den Lernraten 2×10^{-5}, 3×10^{-5} und 5×10^{-5} über 5 Epochen mit einer Batch-Größe von 16 trainiert.

Während des Trainings sorgt ein sogenannter Data Collator für die dynamische Batch-Erstellung. Er vereinheitlicht die Längen der Sequenzen durch Padding und passt die zugehörigen Label-Sequenzen entsprechend an. Die gepaddeten Positionen werden mit dem Wert −100 markiert, sodass sie bei der Berechnung der Verlustfunktion ignoriert werden. Dadurch fließen nur tatsächlich vorhandene Wort- oder Zeichenlabels in die Optimierung ein, was ein stabiles und verzerrungsfreies Training gewährleistet (HuggingFace, 2025b).

Zur Evaluation der Modellleistung wird das Framework seqeval verwendet, das speziell für Sequenzkennzeichnungsaufgaben wie Named Entity Recognition entwickelt wurde (Nakayama, 2018). Es unterstützt die in Kapitel 2.4 beschriebenen Metriken Precision, Recall

[3] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/data_preprocessing.py
[4] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/train.py

und F1-Score auf Entitätsebene und ermöglicht damit eine konsistente und objektive Bewertung. Eine Entität gilt nur dann als korrekt erkannt, wenn sowohl ihre Spanne als auch ihr Typ exakt mit der Referenzannotation übereinstimmen. Der F1-Score wird in der micro-averaged Variante berechnet, bei der alle erkannten Entitäten gemeinsam aggregiert und gewichtet werden. Häufiger vorkommende Klassen fließen dadurch stärker in die Bewertung ein (Tjong Kim Sang & Meulder, 2003).[5]

5.5 Implementierung Qualitätsminderungsverfahren

Auf Grundlage der in Kapitel 4 identifizierten Störungstypen erfolgt in diesem Abschnitt die Implementierung der Methoden zur kontrollierten Erzeugung von orthografischen, syntaktischen, semantischen und Label-bezogenen Störungen. Ziel ist es, die in der Literatur beschriebenen Qualitätsminderungen systematisch und reproduzierbar zu simulieren, um deren Einfluss auf die Modellleistung in unterschiedlichen Intensitäten zu untersuchen. Im Vorfeld der Implementierung wurden die in der Forschung häufig verwendeten Frameworks wie TextAttack (Morris et al., 2020), NLPAug (E. Ma, 2019), SeqAttack (Simoncini & Spanakis, 2021), RockNER (Lin et al., 2021), DeepWordBug (Gao et al., 2018), CLARE (D. Li et al., 2021), BAE (Garg & Ramakrishnan, 2020) und BERT-Attack (L. Li et al., 2020) hinsichtlich ihrer Eignung für den vorliegenden Anwendungsfall analysiert.

Keines der bestehenden Frameworks deckt alle im Rahmen der systematischen Analyse identifizierten Störungstypen vollständig ab. Zwar bieten insbesondere TextAttack und NLPAug eine große Auswahl an Funktionen zur Textmanipulation, doch wurden beide Frameworks ursprünglich für allgemeine NLP-Augmentierungen und Textklassifikationsaufgaben entwickelt und sind daher nicht speziell auf die Anforderungen von Named Entity Recognition ausgerichtet. Das zugrunde liegende BIO-Labelschema wird bei den Transformationen nicht berücksichtigt, sodass die erzeugten Textvarianten nach der Störungserzeugung an die ursprünglichen Labels zurückgeführt werden müssen. Dieser Zwischenschritt ist fehleranfällig, insbesondere wenn durch Einfügungen oder Löschungen die Tokenanzahl verändert wird oder neue Token entstehen, die im Originalsatz nicht vorhanden waren.

SeqAttack konzentriert sich auf Named Entity Recognition und integriert verschiedene Angriffsmethoden wie BERT-Attack, CLARE oder BAE, ist dabei jedoch eng an bestimmte Modellarchitekturen und Tokenizer gebunden, sodass für zeichenbasierte Modelle wie CANINE keine direkte Unterstützung besteht. RockNER fokussiert auf den gezielten Austausch von Entitäten zur Untersuchung kontextueller Robustheit und ist damit besonders auf Entity-Replacement-Szenarien ausgelegt, lässt sich aber nicht ohne weiteres zu einer allgemeinen, prozentual steuerbaren Störungsinfrastruktur erweitern.

[5] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/metrics.py

Methoden wie DeepWordBug oder CLARE arbeiten primär mit zeichenbasierten Manipulationen beziehungsweise kontextuellen Ersetzungen, bieten jedoch keine standardisierte Möglichkeit zur exakten Steuerung des Anteils veränderter Tokens und berücksichtigen nicht durchgängig unterschiedliche linguistische Ebenen, zudem kombinieren sie häufig verschiedene Kategorien von Störungen, sodass keine klare Trennung nach den in dieser Arbeit verwendeten Kategorien möglich ist, was ihre direkte Anwendung für die hier geplanten, strikt vergleichbaren Experimentreihen weiter einschränkt.

Es lässt sich festhalten, dass bestehende Frameworks erweitert werden müssten, um den Anforderungen dieser Arbeit zu genügen. Aus Gründen der besseren Kontrolle, geringeren Abhängigkeiten und höheren Reproduzierbarkeit wird daher eine Eigenentwicklung bevorzugt. Diese ermöglicht eine präzise Steuerung der Störungsintensität über definierte Prozentsätze veränderter Tokens. Darüber hinaus erlaubt sie eine klare Trennung zwischen Entitäts- und Kontextstörungen. Dadurch kann gezielt untersucht werden, ob ein Leistungsabfall auf Veränderungen der eigentlichen Entitäten oder auf Modifikationen ihres umgebenden Kontextes zurückzuführen ist. Dieser Aspekt wird von bestehenden Frameworks bislang nicht unterstützt. Die Implementierung ermöglicht zudem eine konsistente Anwendung auf unterschiedliche Modellarchitekturen und Tokenisierungsebenen sowie die explizite Überprüfung und Sicherung der Labelzuordnung, auch wenn durch Einfügungen oder Löschungen die Tokenstruktur verändert wird.

Ein weiterer Vorteil besteht darin, dass zusätzliche linguistische Informationen in die Auswahl und Platzierung der Störungen integriert werden können. Dazu gehören Part-of-Speech-Tags, also grammatikalische Kategorien einzelner Wörter wie Nomen, Verb oder Adjektiv. Durch die Berücksichtigung dieser Informationen können Störungen gezielter und sprachlich plausibler eingeführt werden, beispielsweise indem nur bestimmte Wortarten verändert oder ausgeschlossen werden.

Bei der Entwicklung dienen bestehende Frameworks und die in der Literatur beschriebenen Einzelmethoden als konzeptionelle Grundlage, deren Ideen und Mechanismen selektiv übernommen und an die experimentellen Anforderungen dieser Arbeit angepasst werden. Dadurch kann die Robustheit der Modelle über alle Störungskategorien hinweg kontrolliert und reproduzierbar untersucht werden.

Die Umsetzung folgt dabei einem modularen Ansatz, der eine flexible und transparente Steuerung der Experimente ermöglicht. Ein zentrales Element bilden sogenannte Profile, in denen sämtliche Parameter eines Experiments festgelegt werden. Ein Profil definiert, welche Störungsmethoden angewendet werden, auf welche Datensätze diese angewendet werden und welcher prozentuale Anteil der Tokens verändert wird.

Darüber hinaus können in den Profilen methodenspezifische Parameter übergeben werden, die eine feinere Steuerung der jeweiligen Transformationen erlauben. Es ist außerdem möglich, mehrere Störungsmethoden innerhalb eines Profils zu kombinieren, um zusammengesetzte Szenarien abzubilden. Auf diese Weise lassen sich sämtliche Experimente eindeutig reproduzieren und nachvollziehen, da die vollständige Konfiguration der Datenveränderungen zentral dokumentiert ist.[6]

Die Implementierung ist vollständig in Python entwickelt und nutzt PyTorch als zentrale Deep-Learning-Bibliothek für das Modelltraining. NumPy wird für numerische Berechnungen und die Verarbeitung von Arrays eingesetzt, während CUDA die hardwarebeschleunigte Ausführung auf Graphics Processing Units (GPUs) ermöglicht. GPUs sind spezialisierte Prozessoren, die aufgrund ihrer hohen Parallelisierungsfähigkeit besonders für rechenintensive Operationen in neuronalen Netzen geeignet sind. Da diese Bibliotheken eigene Zufallskomponenten enthalten, werden alle relevanten Zufallsgeneratoren, darunter random, NumPy, PyTorch und die CUDA-Module, über ein globales Seeding-Verfahren auf denselben Startwert gesetzt. Dadurch wird sichergestellt, dass bei identischen Profileinstellungen exakt dieselben Störungen und Trainingsverläufe entstehen.[7]

Für jede Störungskategorie, also orthografisch, syntaktisch, semantisch und Label-bezogen, wurde eine eigene Steuerkomponente entwickelt, die die innerhalb der Kategorie vorhandenen Einzelmethoden koordiniert. Diese Komponenten können so konfiguriert werden, dass entweder alle Methoden einer Kategorie oder nur ausgewählte Transformationen ausgeführt werden.[8]

Das Training der Modelle erfolgt, wie bereits in Kapitel 4.4 beschrieben, mithilfe des Transformers Frameworks (Wolf et al., 2020). Die definierten Störungsprofile werden dabei automatisiert angewendet, bevor die jeweiligen Trainings-, Validierungs- oder Testdurchläufe gestartet werden. Dieser Aufbau gewährleistet eine klare Trennung zwischen der Definition der Störungsbedingungen und der Modellverarbeitung. Im Folgenden wird auf die einzelnen Störungsmethoden innerhalb der jeweiligen Kategorien detaillierter eingegangen.

Orthografische Störungen

Für die Simulation von Tastaturfehlern wird ein QWERTY-basiertes Fehlermodell eingesetzt, wie es auch in den Arbeiten von Bagla et al. (2023) sowie Araujo et al. (2020)verwendet wurde, um typische Eingabeversehen abzubilden. Dies wird dafür genutzt zufällig Zeichen einzufügen, bestehende Zeichen durch Tastaturnachbarn austauschen.

---

[6] https://github.com/denis-trtnr/ner-quality-impact/tree/main/src/profiles
[7] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/train.py
[8] https://github.com/denis-trtnr/ner-quality-impact/tree/main/src/noise

Darüber hinaus gibt es auch Methoden zum Löschen einzelner Zeichen, dem Positionswechsel einzelner Zeichen innerhalb eines Wortes sowie das zufällige Wechseln der Groß- und Kleinschreibung.

Ergänzend kommen Operationen zum Entfernen diakritischer Zeichen und zur Ersetzung durch visuell ähnliche Zeichen zum Einsatz.[9]

Die Behandlung diakritischer Zeichen sowie die Ersetzung durch visuell ähnliche Zeichen, sogenannte Homoglyphen, beruhen auf statischen Zuordnungstabellen, die aus dem NLPAug Framework (E. Ma, 2019) und der Implementierung von Moradi & Samwald (2021) stammen.[10] Bei den Homoglyphersetzungen wurden ausschließlich ASCII-Äquivalente berücksichtigt, da der Fokus dieser Arbeit auf einer realistischen Robustheitsevaluation liegt und nicht auf der gezielten Erzeugung von Angriffen wie bei TextAttack.

Die verschiedenen Operationen werden über eine Steuermethode koordiniert, die zunächst basierend auf der Störungsintensität festlegt, welche Token Kandidaten für eine Änderung sind. Daraufhin wird für jedes dieser Token zufällig eine der zuvor beschriebenen Methoden ausgeführt. Über eine konfigurierbare Strategie kann zusätzlich bestimmt werden, ob ausschließlich Entitäten, nur Kontexttokens oder alle Tokens gleichermaßen verändert werden. So lassen sich gezielte Experimente durchführen, die getrennt die Robustheit gegenüber Veränderungen innerhalb von Entitäten und im umgebenden Kontext untersuchen.

In Tabelle 4 sind alle beschriebenen orthografischen Methoden zusammengefasst und jeweils mit einem Beispiel illustriert.

Methode	Originaltext	Gestörter Text
Einfügen	The company said it expects higher profits next year.	The company said it expects higber profits next year .
Löschen	Peter Blackburn reported from London.	Peter Blackburn reported from Londo.
Austauschen	France and Germany agreed on the proposa .	France and Germany agrred on the proposal.
Groß-/Kleinschreibung	IBM said the market was stable after recent reports.	Ibm said the market was stable after recent reports.
Positionswechsel	… would continue to support economic reforms in Europe.	… would continue to uspport economic reforms in Europe.
Diakritika	José Mourinho joined the club after talks with Chelsea officials.	Jose Mourinho joined the club after talks with Chelsea officials.
Homoglyphen	Google announced a new partnership with Apple on Monday.	Google announced a new partnership with App1e on Monday.

Tabelle 4: Übersicht implementierte orthografische Qualitätsminderungsmethoden-Beispiele aus dem CoNLL-2003-Korpus vor und nach Anwendung orthografischer Störungen, die typische Tipp- und Schreibfehler simulieren.

[9] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/noise/orthographic.py
[10] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/noise/utils/mapping_utils.py

Syntaktische Störungen

Die syntaktischen Störungen simulieren hingegen strukturelle Veränderungen innerhalb eines Satzes, um die Robustheit der Modelle gegenüber Abweichungen in der Satzorganisation, Segmentierung und Zeichensetzung zu untersuchen. Die Implementierung umfasst eine Reihe gezielter Operationen, die verschiedene Aspekte der Satzstruktur betreffen.

Das Einfügen und Entfernen von Interpunktionszeichen dient dazu, Störungen zu erzeugen, wie sie beispielsweise durch unklare Satzgrenzen oder fehlerhafte Zeichensetzung entstehen können. Durch das Zusammenführen benachbarter Tokens wird simuliert, dass Wortgrenzen fehlerhaft erkannt oder ausgelassen wurden, während das zufällige Aufteilen einzelner Tokens in zwei Teile das Gegenteil abbildet, also eine übermäßige Segmentierung wie sie etwa durch OCR- oder Tokenisierungsfehler auftreten kann.

Darüber hinaus erzeugen Methoden zum Löschen oder Wiederholen von Tokens vereinfachte Formen von grammatikalischen oder stilistischen Abweichungen, wie sie in nutzergenerierten Texten vorkommen können. Das zufällige Vertauschen benachbarter Tokens bildet schließlich Variationen in der Wortstellung ab.[11]

Ähnlich wie bei den orthografischen Störungen werden auch hier alle Operationen über eine zentrale Steuermethode koordiniert. Diese legt anhand der definierten Störungsintensität fest, welche Tokens verändert werden, und wählt für jedes betroffene Token zufällig eine der verfügbaren syntaktischen Operationen aus.

Bei allen syntaktischen Operationen wird das zugrunde liegende BIO-Labelschema konsistent fortgeführt, sodass die Entitätsgrenzen auch nach strukturellen Veränderungen korrekt erhalten bleiben. Werden zwei Tokens zusammengeführt, übernimmt das neu entstandene Token das Label des ersten Tokens, wodurch die ursprüngliche Entitätsstruktur gewahrt bleibt. Wird ein Token hingegen aufgeteilt, so behält der linke Teil das ursprüngliche Label, während der rechte Teil dasselbe Entitätslabel erhält, jedoch mit dem Präfix „I-“ (Inside), sofern das ursprüngliche Token Teil einer Entität war. Auf diese Weise wird sichergestellt, dass die Störungen keine unzulässigen Veränderungen der Entitätskennzeichnung verursachen.

Eine Übersicht aller implementierten syntaktischen Methoden einschließlich kurzer Beschreibungen und Beispielen ist in Tabelle 5 dargestellt.

[11] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/noise/syntactic.py

Methode	Originaltext	Gestörter Text
Einfügen Interpunktuations-zeichen	The United Nations called for new peace talks in Geneva.	The United , Nations called for new peace talks in Geneva.
Löschen Interpunktuations-zeichen	… from Bank of America, New York, and the United States Treasury met in London .	… from Bank of America New York, and the United States Treasury met in London
Zusammenführen	France and Germany signed the agreement yesterday.	Franceand Germany signed the agreement yesterday.
Aufteilen	Microsoft announced new soft-ware on Monday.	Micro soft announced new soft-ware on Monday.
Löschen	Tony Blair met President Bush in London.	Tony Blair met ~~President~~ Bush in London.
Wiederholen	IBM reported strong results in the first quarter.	IBM IBM reported strong results in the first quarter.
Vertauschen	Google announced a new partner-ship with Apple.	Google announced a new part-nership Apple with.

Tabelle 5: Übersicht implementierte syntaktische Qualitätsminderungsmethoden- Beispiele aus dem CoNLL-2003-Korpus vor und nach Anwendung der syntaktischen Störungsoperationen zur Simulation struktureller Abweichungen in Satzorganisation und Segmentierung.

Semantische Störungen

In der Literatur wurden verschiedene Verfahren zur Erzeugung semantischer Störungen beschrieben, die sich vor allem in ihrer methodischen Grundlage und der Art der Bedeutungsveränderung unterscheiden. Grundsätzlich lassen sich zwei Hauptansätze unterscheiden: wortlistenbasierte Verfahren, die auf Ressourcen wie WordNet (Miller, 1995) oder definierten Gazetteers beruhen, und modellbasierte Verfahren, die auf Embeddings basieren. Wie in Kapitel 2.2 erläutert, verwenden statische Modelle wie GloVe (Pennington et al., 2014) oder Paragram (Wieting et al., 2017) feste Wortrepräsentationen unabhängig vom Kontext, während kontextuelle Sprachmodelle dynamische, kontextabhängige Embeddings über MLM generieren (X. Jin et al., 2023; Lin et al., 2021).

Um die in der Literatur beschriebenen Ansätze möglichst vollständig abzubilden, werden in dieser Arbeit Elemente aller genannten Methoden umgesetzt. Dazu zählen Wortlisten-basierte Synonym- und Antonymersetzungen, semantische Substitutionen mithilfe statischer Embeddings sowie kontextabhängige Ersetzungen unter Verwendung vortrainierter Sprachmodelle.[12]

Für die synonym- und antonymbasierten Ersetzungen wird das WordNet-Lexikon herangezogen. Synonyme werden auf Grundlage der semantischen Distanz zwischen den jeweiligen Synsets ausgewählt, die mithilfe der Wu-Palmer-Ähnlichkeit (WUP-Similarity) berechnet wird (Z. Wu & Palmer, 1994). Diese misst den semantischen Abstand zweier Begriffe anhand der Tiefe ihrer gemeinsamen übergeordneten Konzeptknoten in der WordNet-Hierarchie.

[12] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/noise/semantic.py

Nur solche Alternativen werden berücksichtigt, deren Ähnlichkeitswert unterhalb eines festgelegten Schwellenwerts von 0,7 liegt, um rein triviale Synonyme auszuschließen und eine tatsächliche Bedeutungsvariation zu erzeugen. Findet sich kein geeigneter Ersatz, greift ein Fallback-Mechanismus, der das Wort über ein statisches Embeddingmodell ersetzt.

Für die embeddingbasierten Substitutionen wird das vortrainierte Modell GloVe-Wiki-Gigaword-100 genutzt (Pennington et al., 2014). Aus der Liste der ähnlichsten Wörter werden die zehn am stärksten ähnlichen Begriffe übersprungen, um rein synonyme oder triviale Varianten auszuschließen und eine größere Bedeutungsverschiebung zu erzielen. Anschließend wird ein zufälliger Ersatz aus den verbleibenden Kandidaten gewählt.

Die kontextuellen Ersetzungen basieren auf dem vortrainierten Modell ALBERT-base-v2 (Lan et al., 2020), das maskierte Tokens innerhalb eines Satzes durch kontextuell passende Alternativen ersetzt. Dieses Modell wurde bewusst gewählt, da es nicht in den späteren Experimenten verwendet wird und somit keine Verzerrungen durch Modellüberschneidungen entstehen können. Die Implementierung orientiert sich dabei an der Vorgehensweise des NLPAug-Frameworks, wurde jedoch an die Anforderungen dieser Arbeit angepasst.

Um die Berechnung effizient zu gestalten, werden alle zu ersetzenden Tokens in Batches verarbeitet, wobei für jedes Token ein separater Satz mit Maskierung erzeugt und gemeinsam an das Modell übergeben wird. Die Ergebnisse werden gesammelt und die jeweils fünf ähnlichsten Alternativen verworfen, um redundante oder identische Vorhersagen zu vermeiden.

Auf die Erzeugung vollständiger Paraphrasen wurde verzichtet, da deren Anwendung häufig zu strukturellen Veränderungen führt, die das Rückmapping der Labels erschweren und eine konsistente Evaluation der Robustheit beeinträchtigen können (Srinivasan & Vajjala, 2023).

Die Auswahl der zu verändernden Tokens wird durch eine zentrale Steuermethode vorgenommen, die auf der festgelegten Störungsintensität basiert. Dabei werden insbesondere semantisch bedeutungstragende Wortarten wie Nomen, Verben, Adjektive und Adverbien mit höherer Wahrscheinlichkeit ausgewählt, während Funktionswörter wie Präpositionen oder Konjunktionen seltener betroffen sind. Über die konfigurierbare Entity-Strategie kann festgelegt werden, ob ausschließlich Entitäten, nur der Kontext oder beide verändert werden.

Abschließend wird die ursprüngliche Groß- und Kleinschreibung jedes Tokens beibehalten, um eine möglichst natürliche Textstruktur zu erhalten. Eine Übersicht aller implementierten semantischen Methoden mit Beispielausgaben ist in Tabelle 6 dargestellt.

Methode	Originaltext	Gestörter Text
WordNet-basierte Synonymersetzung	The foreign ministry 's Shen told Reuters Television…	The foreign ministry 's Shen told **Haaretz Video**…
WordNet-basierte Antonymersetzung	German first-time registrations of motor vehicles jumped…	German **unwary** registrations of motor vehicles jumped…
Embeddingbasierte Substitution (GloVe)	The meeting was attended by Tony Blair in London.	The meeting was **operated** by Tony Blair in London.
Kontextuelle Ersetzung (ALBERT)	Talks between France and Germany continued in Brussels.	Talks between France and Germany **collapsed** in Brussels.

Tabelle 6: Übersicht implementierte semantische Qualitätsminderungsmethoden- Beispiele aus dem CoNLL-2003-Korpus vor und nach Anwendung von WordNet-, GloVe- und ALBERT-basierten Substitutionsverfahren, die semantische Variationen erzeugen.

Label-bezogene Störungen

Zur Simulation fehlerhafter Annotationen wurden in dieser Arbeit Label-bezogene Störungen implementiert, die sich an den in der Literatur beschriebenen Fehlerkategorien orientieren. Ziel ist es, typische Annotationsfehler wie unvollständige, überlappende oder falsch klassifizierte Entitäten kontrolliert und reproduzierbar zu erzeugen.

Die Störungsintensität bezieht sich hierbei auf den Anteil der veränderten Entitäten innerhalb eines Datensatzes. Für jede betroffene Entität wird zufällig eine von fünf möglichen Transformationen ausgeführt. Dazu gehören das Verkürzen von Entitätsspannen, bei dem das Ende einer Entität um ein Token reduziert und der entfernte Teil der Klasse O zugeordnet wird, sowie das Erweitern von Entitäten, bei dem angrenzende O-Tokens in die bestehende Spanne aufgenommen werden, um Überannotationen zu simulieren. Durch das Ersetzen einer gesamten Entität durch die Klasse O werden dagegen fehlende Annotationen („missing mentions“) abgebildet. Zusätzlich kann die ursprüngliche Entitätsklasse zufällig durch eine andere ersetzt werden, um Klassifikationsfehler nachzubilden. Eine Sonderrolle nimmt das Erzeugen neuer Entitäten aus O-Tokens ein, da hierbei keine bestehenden Annotationen verändert, sondern neue künstliche Entitäten eingefügt werden, um falsch positive Labels zu simulieren.[13]

Wird eine neue Entität erzeugt, bleibt dafür im Gegenzug eine ursprünglich ausgewählte Entität unverändert. Dadurch wird verhindert, dass die Gesamtzahl der Entitäten durch die künstlich hinzugefügten Labels überproportional zunimmt. Würde stattdessen jeder Vorgang der Entitätserzeugung zusätzlich zu den übrigen Transformationen ausgeführt, entstünde ein Ungleichgewicht, da Nicht-Entitäten in der Regel in deutlich höherer Zahl vorhanden sind.

[13] https://github.com/denis-trtnr/ner-quality-impact/blob/main/src/noise/label_noise.py

Die Auswahl der zu verändernden Entitäten erfolgt proportional zur festgelegten Störungsintensität. Falls eine gewählte Operation nicht anwendbar ist, etwa weil eine Erweiterung am Satzende nicht möglich ist, wird bis zu drei Mal eine alternative Transformation versucht, um die geplante Störungsrate einzuhalten. Alle Änderungen erfolgen unter Wahrung des BIO-Schemas, sodass die strukturelle Integrität der Annotationen erhalten bleibt.

In Tabelle 7 sind die Methoden sowie zugehörige Beispiele dargestellt.

Methode	Originaltext	Gestörter Text
Entität verkürzen	President (O) George (B-PER) Bush (I-PER) met (O) reporters (O) at (O) the (O) White (B-LOC) House (I-LOC) . (O)	President (O) George (B-PER) Bush (**O**) met (O) reporters (O) at (O) the (O) White (B-LOC) House (I-LOC) . (O)
Entität erweitern	Talks (O) in (O) Paris (B-LOC) ended (O) Friday (O) morning (O) ...	Talks (O) in (O) Paris (B-LOC) ended (**I-LOC**) Friday (O) morning (O) …
Entität entfernen	IBM (B-ORG) announced (O) plans (O) to (O) expand (O) in (O) Germany (B-LOC) . (O)	IBM (**O**) announced (O) plans (O) to (O) expand (O) in (O) Germany (B-LOC) . (O)
Entitätsklasse vertauschen	Arsenal (B-ORG) beat (O) Chelsea (B-ORG) 2-1 (O) at (O) Highbury (B-LOC)	Arsenal (**B-LOC**) beat (O) Chelsea (B-ORG) 2-1 (O) at (O) Highbury (B-LOC)
Neue Entität erzeugen	.The (O) meeting (O) took (O) place (O) in (O) Brussels (B-LOC) . (O)	The (O) meeting (**B-LOC**) took (O) place (O) in (O) Brussels (B-LOC) . (O)

Tabelle 7: Übersicht implementierte Label-bezogene Qualitätsminderungsmethoden- Dargestellt sind exemplarische Token-Sequenzen aus dem CoNLL-2003-Datensatz mit zugehörigen BIO-Labels vor und nach Anwendung der jeweiligen Transformation.

6 Evaluation

In diesem Kapitel werden die zuvor beschriebenen Störungsmethoden empirisch ausgewertet, um deren Einfluss auf die Robustheit der untersuchten NER-Modelle zu analysieren. Die Experimente folgen dem in Kapitel 5 beschriebenen Versuchsaufbau und betrachten Störungsintensitäten von 10 %, 20 % und 30 %. Im Fokus steht die Veränderung der Micro-F1-Scores im Vergleich zur störungsfreien Baseline.

Zunächst werden in Kapitel 6.1 die Baseline-Ergebnisse ohne Störungen vorgestellt, die als Referenzpunkt für die weiteren Analysen dienen. Anschließend untersucht Kapitel 6.2 den Einfluss von Störungen im Testdatensatz, während Kapitel 6.3 und 6.4 kombinierte beziehungsweise ausschließlich trainingsbezogene Störungsszenarien betrachten. Den Abschluss bildet Kapitel 6.5, das die Ergebnisse mit den in der SLR berichteten Befunden vergleicht.

6.1 Baseline

Als Ausgangspunkt für die Robustheitsanalyse dienen die Baseline-Experimente, in denen die Modelle ohne jegliche Störungen evaluiert wurden. Alle in Kapitel 5.2 beschriebenen Modelle wurden dabei mit den in Kapitel 5.4 detailliert erläuterten Trainingsparametern auf dem CoNLL-2003-Datensatz feinjustiert.

Die erzielten Micro-F1-Scores, dargestellt in Tabelle 8, geben den Mittelwert über mehrere Trainingsläufe und Lernraten hinweg wieder. Alle Modelle erreichen ein hohes Leistungsniveau, wobei RoBERTa mit 92,9 % den höchsten und CANINE mit 89,4 % den niedrigsten Wert erzielt. Die Standardabweichung gibt an, wie stark die erzielten Ergebnisse über die verschiedenen Trainingsläufe hinweg schwanken, und dient somit als Maß für die Stabilität beziehungsweise Reproduzierbarkeit der Modellleistung.

Modell	Micro-F1-Score (%)	Standardabweichung σ
BERT	91,8	± 0,3
RoBERTa	92,9	± 0,2
DeBERTa	92,7	± 0,3
DistilBERT	90,3	± 0,4
CANINE	89,4	± 0,5
XLNet	91,8	± 0,3

Tabelle 8: Baseline Ergebnisse - Vergleich der auf dem CoNLL-2003-Datensatz trainierten Modelle hinsichtlich ihrer Ausgangsleistung vor der Einführung von Datenstörungen. Evaluierung erfolgte mittels Micro-F1 Score.

Besonders interessant für die generelle Analyse sind CANINE und DistilBERT, da sie sich hinsichtlich ihrer Architektur deutlich von den anderen Modellen unterscheiden: Während CANINE vollständig auf Zeichenebene operiert, basiert DistilBERT auf einer komprimierten, distillierten Variante von BERT und zielt somit auf Effizienz bei reduzierter Modellgröße ab. Beide Modelle erzielen in der Baseline leicht niedrigere Werte, bleiben jedoch insgesamt gut mit den übrigen Modellen vergleichbar.

In der Literatur werden für einzelne Modelle teils höhere Werte berichtet, was in der Regel auf gezielte Hyperparameter-Optimierungen oder zusätzliche Vorverarbeitungsschritte zurückzuführen ist. Da der Fokus dieser Arbeit auf der Robustheitsanalyse liegt, wurde bewusst auf einen umfangreichen Hyperparameter-Sweep verzichtet. Stattdessen kamen ausschließlich die in Kapitel 5.4 beschriebenen standardisierten Trainingsschritte zum Einsatz, um konsistente und reproduzierbare Vergleichswerte zu gewährleisten.

6.2 Störungen im Testdatensatz

In diesem Abschnitt wird untersucht, wie empfindlich die Modelle auf Störungen im Testdatensatz reagieren, wenn sie auf unveränderten Trainingsdaten trainiert wurden. Dieses Szenario entspricht der typischen Anwendungssituation, in der ein Modell mit sauberen Daten entwickelt und anschließend auf potenziell verrauschten oder fehlerhaften Eingaben im Praxiseinsatz getestet wird. Aufgrund des besseren Leseflusses wurden die Standardabweichungen der F1-Scores in den Anhang 2 ausgelagert, im Text werden jedoch zentrale Beobachtungen dazu erläutert. Abbildung 8 zeigt den mittleren F1-Score über alle Modelle hinweg in Abhängigkeit vom Anteil der veränderten Tokens.

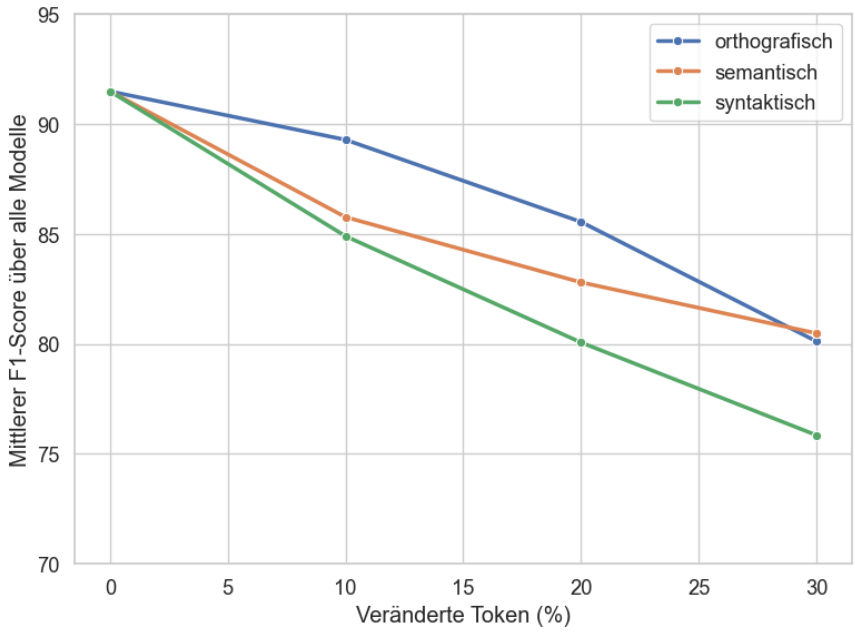


Abbildung 8: Mittlere F1-Score Veränderung auf Testdaten- Veranschaulicht den Leistungsabfall über alle Modelle hinweg bei zunehmendem Anteil veränderter Token. Kategorisierung der Störungen wurden in 4.3.1 durchgeführt.

Betrachtet man zunächst den generellen Einfluss der Störungsintensität, so lässt sich ein erwartungsgemäß negativer Trend feststellen. Mit steigendem Anteil veränderter Tokens sinkt der mittlere F1-Score kontinuierlich. Auffällig ist hierbei die unterschiedliche Sensitivität der Modelle gegenüber den verschiedenen Störungskategorien. Während orthografische Veränderungen (blaue Linie) im Durchschnitt den geringsten Leistungsabfall verursachen, führen syntaktische Störungen (grüne Linie) bereits bei niedrigen Intensitäten zu den stärksten Einbußen. So fällt der mittlere F1-Score bei einer syntaktischen Störungsrate von 30 % auf unter 76 %, wohingegen er bei orthografischen Fehlern gleicher Intensität noch knapp über 80 % liegt. Diese Instabilität gegenüber syntaktischen Störungen äußert sich auch in der höchsten Volatilität der Ergebnisse über alle Modelle hinweg, die durchschnittliche Standardabweichung liegt bei ± 1,5 bei 30% Noise, während sie bei orthografischen Störungen im selben Bereich lediglich ± 0,9 beträgt (Vgl. Anhang 2).

Semantische Störungen (orange Linie) bewegen sich im Mittelfeld dieser beiden Extreme, zeigen jedoch einen interessanten Verlauf: Ihr Leistungsabfall verlangsamt sich bei höheren Störungsintensitäten leicht, sodass sich die Kurven für semantische und orthografische Störungen bei 30 % annähern und fast schneiden. Dies deutet darauf hin, dass die Modelle ab einem gewissen Grad an Rauschen gleichermaßen stark durch falsche Wortbedeutungen wie durch Schreibfehler beeinträchtigt werden, während sie generell am stärksten von einer korrekten übergeordneten Satzstruktur abhängig bleiben.

Der Verlauf der Leistungsdegradation ist dabei nicht linear. Syntaktische Störungen zeigen oft bereits bei 10 % Störungsanteil den stärksten initialen Abfall. Orthografische Störungen verlaufen demgegenüber zunächst flacher und weisen erst zwischen 20 % und 30 % einen beschleunigten Abfall auf. Hier scheint ein Kipppunkt zu existieren, ab dem die Menge fehlerhafter Tokens die kontextuelle Kompensationsfähigkeit der Modelle überfordert. Die detaillierten F1-Scores in Tabelle 9 bestätigen den in Abbildung 8 beobachteten generellen Trend, wonach syntaktische Störungen für die Mehrheit der Modelle die größte Herausforderung darstellen, während orthografische Veränderungen oft am besten kompensiert werden können. Die Betrachtung der Einzelwerte verdeutlicht jedoch, dass dieser Durchschnittstrend nicht universell gilt, da spezifische Architekturmerkmale einiger Modelle zu deutlichen Abweichungen in bestimmten Störungskategorien führen.

Art	Störung	BERT	RoBERTa	DeBERTa	DistilBERT	CANINE	XLNet
Baseline	0%	91,8	**92,9**	92,7	90,3	89,4	91,8
Orthografisch	10%	89,7	**91,1**	90,7	86,0	88,6	89,6
	20%	85,9	**88,0**	86,9	81,3	86,5	86,3
	30%	79,8	**82,6**	82,2	76,1	**82,6**	80,0

Semantisch	10%	86,1	**88,0**	87,7	83,2	83,4	86,2
	20%	83,3	**85,4**	84,8	78,5	80,9	83,9
	30%	81,3	83,6	**83,7**	74,9	78,1	81,3
Syntaktisch	10%	84,9	86,7	**86,9**	81,8	82,7	86,4
	20%	79,9	82,1	**82,7**	76,6	77,8	81,3
	30%	76,1	77,7	**78,8**	72,2	72,6	77,7

Tabelle 9: Ergebnisse Datenqualitätsminderungen Testdatensatz- Detaillierte gemittelte Micro-F1-Scores der Modelle bei unterschiedlichen Arten und Intensitäten von Datenstörungen auf dem CoNLL-2003-Testdatensatz. Aufgrund des besseren Leseflusses wurde die Darstellung der Standardabweichungen in Anhang 2 ausgelagert.

Auf den ersten Blick kristallisiert sich eine leistungsstarke Gruppe aus RoBERTa, DeBERTa und XLNet heraus, die nicht nur mit den höchsten Baseline-Werten starten, sondern auch über die verschiedenen Störungsarten hinweg ein vergleichsweise hohes Niveau halten. Selbst bei moderaten Störungen von 10 % liegen ihre F1-Scores in allen Kategorien noch deutlich über der 85 %-Marke, was auf eine robuste Grundarchitektur und effektive Pretraining-Strategien hindeutet. RoBERTa und DeBERTa zeichnen sich zudem durch vergleichsweise geringe Standardabweichungen von durchschnittlich 0,8 auf und liegen damit unter dem Durchschnitt aller Modelle ($\sigma \approx 1{,}2$).

Bei der detaillierten Betrachtung der **orthografischen** Störungen zeigt sich eine interessante Verschiebung der Leistungsfähigkeit, die spezifische Architekturmerkmale offenbart. Das Modell CANINE weist trotz der niedrigsten Baseline von 89,4 % eine vergleichsweise hohe Stabilität auf und erreicht bei 30 % Störungsanteil mit 82,6 % ein ähnliches Niveau wie das in absoluten Zahlen stärkste Modell RoBERTa mit 82,7 %. Die hohe Konsistenz dieser überlegenen Leistung wird durch die sehr geringe Standardabweichung von $\sigma = \pm 0{,}6$ für CANINE bei 30% Störung belegt, was deutlich unter dem Durchschnitt aller Modelle liegt ($\sigma = 1{,}1$). Das Verhalten lässt sich vermutlich damit begründen, dass CANINE im Gegensatz zu den anderen Subword-basierten Modellen, Eingaben direkt auf Zeichenebene verarbeitet. Es ist anzunehmen, dass lokale Schreibfehler die interne Repräsentation des Gesamtkontexts bei diesem Ansatz weniger stark beeinträchtigen als bei Subword-basierten Modellen, die bei Tippfehlern oft mit fehlerhaft segmentierten Token-Sequenzen konfrontiert werden.

RoBERTa und DeBERTa bilden mit CANINE zusammen Spitzengruppe in dieser Kategorie. Ihre Fähigkeit, das hohe Ausgangsniveau auch unter Rauschen weitgehend zu halten, dürfte maßgeblich auf robustere interne Repräsentationen zurückzuführen sein, die durch umfangreicheres Pretraining und optimierte Trainingsziele entstanden sind. Diese Eigenschaften scheinen eine effektivere Kompensation fehlender oder fehlerhafter Informationen aus dem

Kontext zu ermöglichen. Während BERT und XLNet sich im Mittelfeld positionieren, bildet DistilBERT eine deutliche Ausnahme. Es weist mit einem Endwert von 76,1 % die mit Abstand geringste Toleranz gegenüber orthografischen Fehlern auf. Dieser signifikante Leistungseinbruch lässt vermuten, dass die durch Destillation reduzierte Parameteranzahl die Fähigkeit stark limitiert, durch verrauschte Tokens entstandene Informationslücken aus dem verbleibenden Kontext zu rekonstruieren.

Im Bereich der **semantischen** Störungen zeigt sich ein homogeneres Bild an der Leistungsspitze, wobei RoBERTa und DeBERTa ihre führenden Positionen behaupten. Beide Modelle weisen selbst bei einer hohen Störungsrate von 30 % bemerkenswert robuste F1-Scores von 83,6 % beziehungsweise 83,7 % auf. Theoretisch hätte vermutet werden können, dass DeBERTa in dieser Kategorie einen deutlicheren Vorsprung erzielt, da dessen Disentangled-Attention-Mechanismus für eine präzisere Erfassung kontextueller Beziehungen entwickelt wurde. Diese Architektur sollte prinzipiell Vorteile bieten, wenn es darum geht, die korrekte Bedeutung einer Entität aus dem verbleibenden Satzkontext abzuleiten, selbst wenn das Kernwort semantisch verändert wurde. Die Ergebnisse legen jedoch nahe, dass RoBERTa durch sein umfangreiches Pretraining eine vergleichbar robuste semantische Repräsentation aufgebaut hat, die diesen theoretischen Architekturvorteil in diesem spezifischen Szenario ausgleicht.

Ein deutlicher Kontrast zur vorherigen Kategorie zeigt sich bei CANINE. Der modellarchitektonische Vorteil der Zeichenverarbeitung kommt bei semantischen Fehlern nicht mehr zum Tragen, da das Erkennen inhaltlich falscher Wörter ein Verständnis auf höherer Abstraktionsebene erfordert. Dies führt zu einem deutlicheren Leistungsabfall auf 78,1 % bei maximaler Störung. DistilBERT bildet erneut das Schlusslicht und fällt auf 74,9 % zurück, was die Annahme erhärtet, dass eine reduzierte Modellkapazität die Möglichkeiten zur kontextuellen Fehlerkompensation stark einschränkt.

Syntaktische Störungen stellen wie Abbildung 8 bereits aufzeigte, die größte Herausforderung für alle Modelle dar. In diesem Szenario erzielt DeBERTa mit 78,8 % bei maximaler Störungsintensität den höchsten Wert, was vermutlich auf die Verarbeitung relativer Positionen durch den Disentangled-Attention-Mechanismus zurückzuführen ist. XLNet zeigt trotz einer niedrigeren Baseline bei 30 % Störung mit 77,7 % ein vergleichbares Ergebnis wie RoBERTa. Diese Resilienz könnte durch das Pretraining mittels Permutation-Language-Modeling begründet sein, welches das Modell zwingt, Zusammenhänge unabhängig von einer linearen Lesereihenfolge zu erlernen.

Für CANINE zeigt sich bereits ab 10 % (F1 = 82,7 %), dass die Verarbeitung auf Zeichenebene bei globalen Strukturproblemen keinen Vorteil bietet. Dieser Trend setzt sich bis zu einem Endwert von 72,6 % fort.

DistilBERT verzeichnet ebenfalls einen kontinuierlichen Abfall über alle Stufen hinweg und erreicht bei maximaler Störung 72,2 %

Um die Modelle unabhängig von ihrer absoluten Ausgangsleistung vergleichen zu können, visualisiert Abbildung 8 den durchschnittlichen prozentualen Leistungsabfall über alle drei Störungsintensitäten hinweg. Diese Metrik isoliert die intrinsische Stabilität der Architekturen, indem sie anzeigt, wie stark ein Modell relativ zu seinem eigenen Optimum durch Datenqualitätsminderungen beeinträchtigt wird.

Es muss jedoch berücksichtigt werden, dass diese Durchschnittsbildung extreme Leistungseinbrüche bei hohen Störungsintensitäten maskieren kann, falls ein Modell bei geringerem Rauschen noch sehr gute Werte liefert. Ein Beispiel hierfür ist der orthografische Bereich, wo viele Modelle bei 10 % Störung noch verhältnismäßig stabil sind, was den drastischen Abfall bei 30 % im Durchschnittswert etwas abmildert.

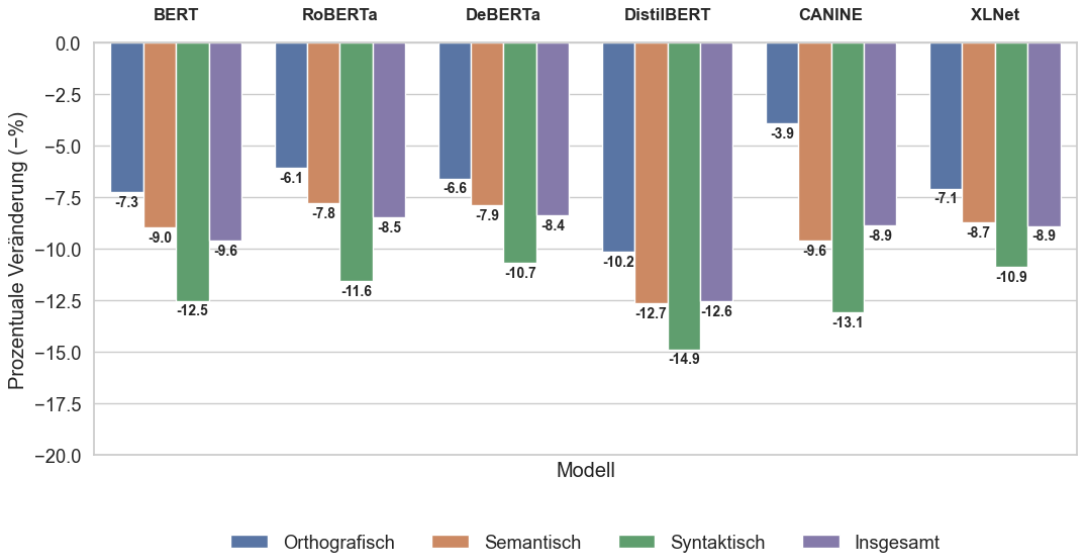


Abbildung 9: Durchschnittliche Prozentuale Veränderung je Modell-Darstellung des mittleren prozentualen Leistungsabfalls (Micro-F1) der Modelle über alle Störungsarten und -intensitäten hinweg zur Beurteilung ihrer relativen Robustheit gegenüber Datenqualitätsminderungen.

Unter Berücksichtigung dieser methodischen Einschränkung bestätigt die Visualisierung die Sonderrolle von CANINE im Bereich der orthografischen Störungen. Mit einem durchschnittlichen Abfall von lediglich 3,3 % erweist es sich in dieser Kategorie als mit Abstand stabilstes Modell. Über alle Störungskategorien hinweg betrachtet bestätigen sich jedoch RoBERTa und DeBERTa als die robustesten Gesamtarchitekturen. Dicht darauf folgt XLNet, das mit einem durchschnittlichen Abfall von 8,9 % ebenfalls eine hohe relative Stabilität beweist.

BERT ordnet sich mit einem Verlust von 9,6 % im Mittelfeld ein. Im Gegensatz dazu verzeichnet DistilBERT mit einem durchschnittlichen Gesamtverlust von 12,6 % die deutlichste relative Instabilität und weist zugleich mit σ ≈ 1,5 die höchste mittlere Standardabweichung auf.

Kontextabhängigkeit

Um die Abhängigkeit der Modelle von intrinsischen Entitätsinformationen im Vergleich zu Kontextmerkmalen zu differenzieren, wurde der in Kapitel 5.5 beschriebene Entitätsschutz evaluiert. Bei diesem Ansatz werden ausschließlich Nicht-Entitäten durch die Störungsoperationen verändert. Die Ergebnisse für orthografische Störungen unter Entitätsschutz, dargestellt in Abbildung 10 (rechts), zeigen eine signifikante Leistungsstabilisierung. Im Vergleich zum ungeschützten Szenario (links) verläuft die Verlustkurve wesentlich flacher, wobei die leistungsstarken Modelle selbst bei 30 % Kontextstörung F1-Scores von über 87 % halten. Gleichzeitig sinkt auch die Streuung der Ergebnisse deutlich. Die durchschnittliche Standardabweichung reduziert sich von etwa ± 0,8 auf ± 0,5, was auf eine konsistentere Modellreaktion hinweist.

Dies lässt den Schluss zu, dass die Modelle stark auf die unveränderte Schreibweise der Entität selbst angewiesen sind und weniger robuste Kontextrepräsentationen nutzen als angenommen.

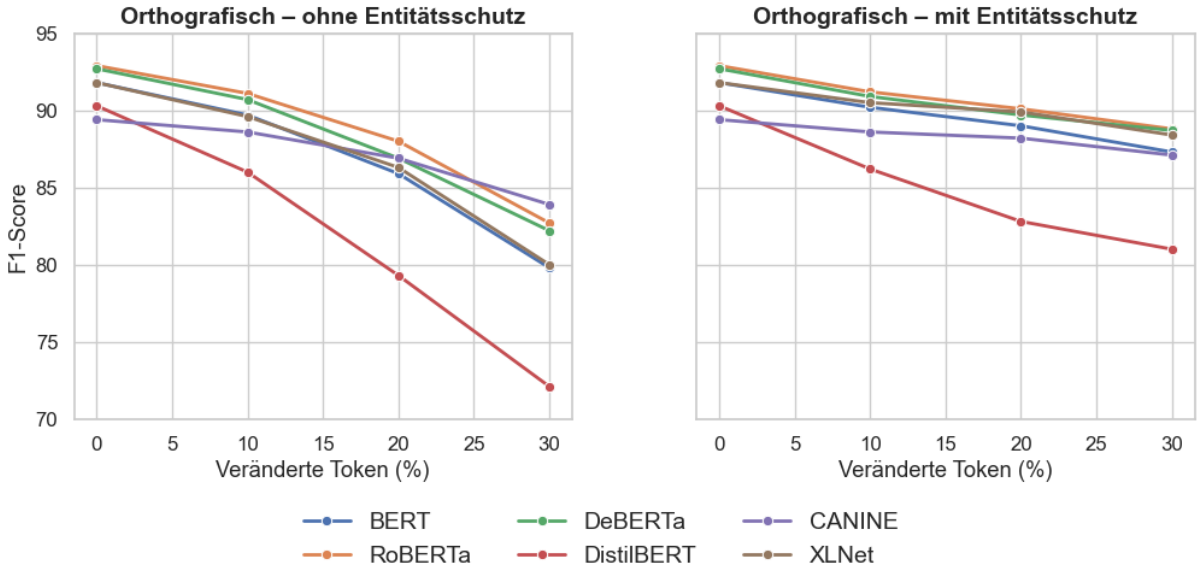


Abbildung 10: Orthografische Leistung mit Entitätsschutz auf Testdatensatz - Vergleich der mittleren Micro-F1-Scores bei orthografischen Störungen mit und ohne Entitätsschutz, um den Einfluss des Kontexts zu messen.

Ein vergleichbarer, wenn auch leicht abgeschwächter Stabilisierungseffekt zeigt sich bei semantischen Störungen in Abbildung 11.

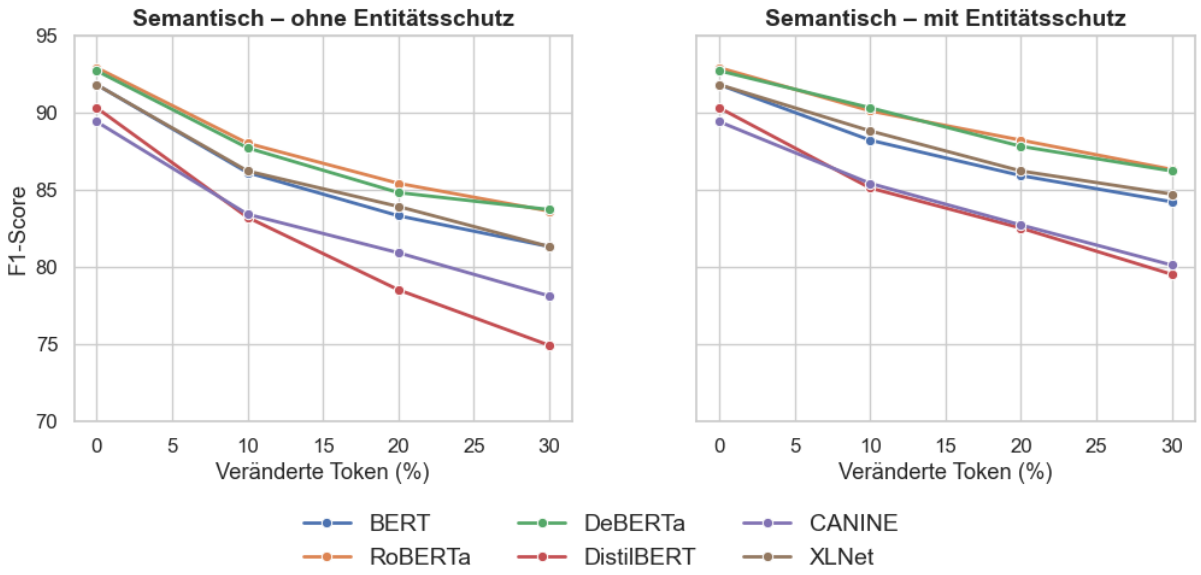


Abbildung 11: Semantische Leistung mit Entitätsschutz auf Testdatensatz - Vergleich der mittleren Micro-F1-Scores bei semantischen Störungen mit und ohne Entitätsschutz, um den Einfluss des Kontexts zu messen.

Auch hier führt der Schutz der Entitäten zu einem deutlich flacheren Verlauf der Leistungsminderung sowie einer geringeren Standardabweichung als im ungeschützten Szenario. Dies legt nahe, dass eine korrekte Identifikation oft maßgeblich durch die Entität selbst ausgelöst wird, während der Kontext primär zur Auflösung von Mehrdeutigkeiten dient. Dennoch ist der Leistungsrückgang bei DistilBERT und CANINE auch hier sichtbar stärker als bei den anderen Modellen.

6.3 Störungen im Test- und Trainingsdatensatz

In diesem Abschnitt wird untersucht, inwieweit eine gezielte Exposition gegenüber Störungen während des Trainings die Robustheit der Modelle im Umgang mit verrauschten Testdaten verbessern kann. Damit wird überprüft, ob sich die in Abschnitt 6.2 beobachteten Leistungseinbußen durch ein angepasstes Training teilweise kompensieren lassen. Tabelle 10 zeigt die vollständigen F1-Scores der sechs Modelle über alle Störungsarten und -intensitäten hinweg. Die Zeilen mit dem Zusatz (S) stellen dabei die Ergebnisse unter Entitätenschutz dar, bei dem ausschließlich Nicht-Entitäten modifiziert wurden.

Art	Störung	BERT	RoBERTa	DeBERTa	DistilBERT	CANINE	XLNet
Baseline	0%	91,8	**92,9**	92,7	90,3	89,4	91,8
Orthografisch	10%	90,1	91,5	**91,6**	87,8	88,7	90,7
	20%	88,7	**90,1**	90,0	83,1	87,9	89,2
	30%	86,4	**89,0**	**89,0**	81,6	86,9	86,6
Orthografisch (S)	10%	91,0	**91,9**	91,8	89,4	89,2	91,3
	20%	90,6	91,7	**91,8**	88,2	88,9	91,0
	30%	89,8	91,5	**91,7**	86,4	88,2	90,5
Semantisch	10%	89,6	90,3	**91,0**	87,7	87,6	89,9
	20%	86,7	88,3	**89,1**	84,6	84,5	86,9
	30%	85,3	87,5	**88,4**	81,9	82,2	85,2
Semantisch (S)	10%	91,3	**92,0**	91,6	89,1	88,6	91,3
	20%	90,7	**91,2**	**91,2**	88,0	88,3	91,0
	30%	90,1	90,7	**91,0**	87,3	88,1	90,5
Syntaktisch	10%	88,4	90,0	**90,5**	86,6	85.8	89,0
	20%	86,3	88,6	**89,2**	83,2	82,5	87,9
	30%	84,1	86,0	**87,7**	81,1	81,2	86,4

Tabelle 10: Ergebnisse Datenqualitätsminderungen Trainings- und Testdatensatz- Detaillierte gemittelte Micro-F1-Scores der Modelle bei unterschiedlichen Arten und Intensitäten von Datenstörungen auf dem CoNLL-2003-Datensatz. Störungen wurden dabei im Trainings-, Validierungs- sowie Testdatensatz vorgenommen. Aufgrund des besseren Leseflusses wurde die Darstellung der Standardabweichungen in Anhang 3 ausgelagert.

Ein erster Blick auf die Werte offenbart eine signifikante allgemeine Leistungssteigerung gegenüber dem reinen Testszenario. Die Rangfolge der Spitzenmodelle bleibt dabei weitgehend stabil: RoBERTa und DeBERTa erweisen sich auch unter diesen Bedingungen weiterhin als die leistungsstärksten Architekturen. Besonders beeindruckend ist ihre Performance bei orthografischen Störungen, wo DeBERTa bereits bei 10 % Noise mit 91,6 % wieder sehr nah an seine ursprüngliche Baseline von 92,7 % herankommt. Auch im syntaktischen und semantischen Bereich erreichen beide Modelle bei 10 % wieder Werte um 90 %.

Ein interessantes Phänomen zeigt sich bei der Betrachtung der Verlustkurven über die Störungsintensitäten. Während in Kapitel 6.2 oft ein steiler initialer Abfall zu beobachten war, verläuft die Degradation nun wesentlich flacher und linearer.

Das robuste Training scheint die Modelle also nicht nur punktuell bei einer bestimmten Störungsrate zu verbessern, sondern stabilisiert ihr Verhalten über das gesamte Spektrum hinweg. Der Kipppunkt, an dem die Leistung drastisch einbricht, wird entweder zu höheren Störungsintensitäten verschoben oder ganz eliminiert. Diese Tendenz wird auch in den Standardabweichungen sichtbar, die im Durchschnitt über alle Modelle hinweg von etwa $\sigma \approx 1{,}2$ auf $\sigma \approx 0{,}8$ sinken, was auf eine deutlich geringere Streuung der Ergebnisse hinweist. An den relativen Abständen der Standardabweichungen zwischen den Modellen selbst hat sich jedoch nichts geändert (Vgl. Anhang 3).

Zusätzlich zeigen experimentelle Läufe mit aktiviertem Entitätsschutz (S), bei denen nur Kontexte gestört wurden, erwartungsgemäß die höchsten F1-Scores. Bei 10 % orthografischer Störung mit Schutz erreichen große Modelle nahezu wieder ihr Baseline-Niveau (z. B. RoBERTa 91,9 % vs. Baseline 92,9 %). Dies bestätigt die Erkenntnis aus Kapitel 6.2, dass intakte Entitätsinformationen ein starker Anker für die Modelle sind. Wenn Modelle lernen können den verrauschten Kontext zu ignorieren und sich auf die ungestörten Entitäten zu fokussieren, sind kaum noch nennenswerte Leistungseinbußen gegenüber der Baseline messbar. Methodisch wäre für diese spezifischen Szenarien eine Kreuzvalidierung mit einem ungeschützten Testdatensatz interessant gewesen, um die Generalisierungsfähigkeit weitergehend zu prüfen. Aufgrund des begrenzten Umfangs dieser Arbeit wurde jedoch auf diesen zusätzlichen Untersuchungsschritt verzichtet.

Analyse des Leistungszugewinns

Zur Quantifizierung des spezifischen Nutzens des Trainings konzentriert sich die folgende Analyse auf den direkten Vergleich zwischen Modellen mit und ohne Störungen im Training bei einer maximalen Störungsintensität von 30 %. Diese bewusste Eingrenzung auf das extremste untersuchte Szenario dient dazu die Belastungsgrenzen der Modelle und die Unterschiede zwischen ihnen deutlich herauszuarbeiten.

Die Abbildungen 12 bis 14 visualisieren diesen Effekt für die jeweiligen Störungskategorien. Sie zeigen die Differenz zwischen dem F1-Wert bei Standardtraining (blauer Balken) und der angepassten Leistung nach angepasstem Training (grüner Balken). Der graue Balken dient dabei jeweils als Referenzwert für die ursprüngliche Leistungsfähigkeit ohne jegliche Störungen.

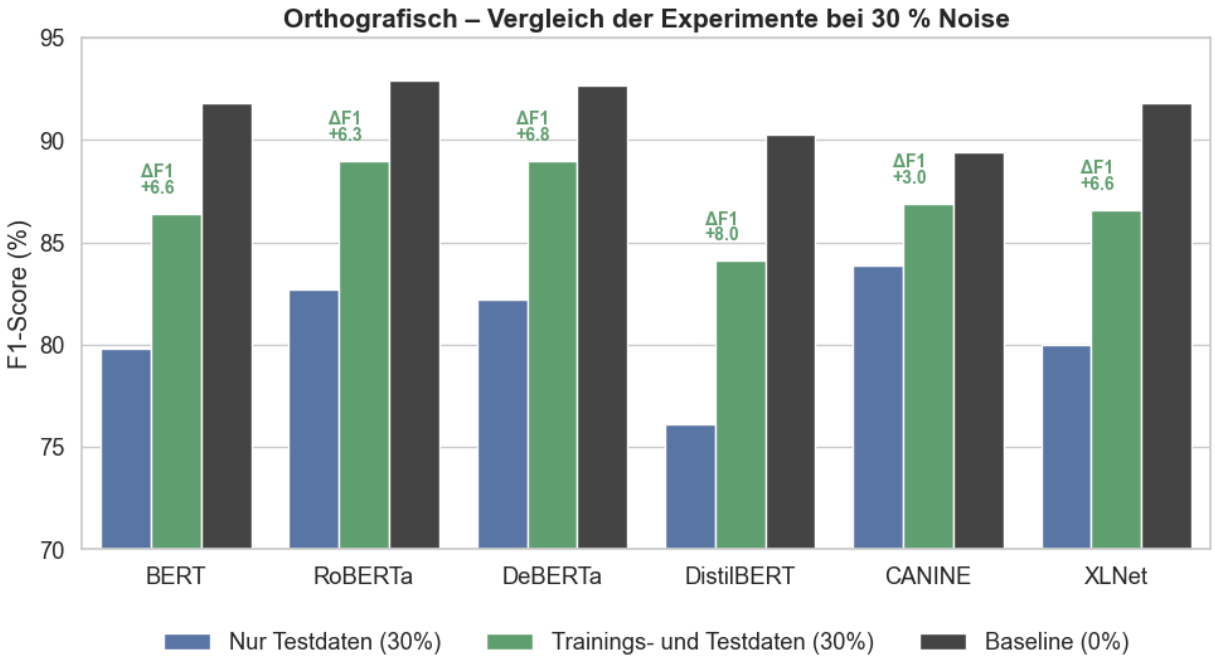


Abbildung 12: Modellleistung mit und ohne orthografische Störungen in Trainingsdaten- Gegenüberstellung der Micro-F1-Scores bei 30 % veränderten Tokens für Modelle mit nur gestörten Testdaten und solchen mit zusätzlich gestörten Trainingsdaten, jeweils im Vergleich zur Baseline.

Bei der detaillierten Analyse der **orthografischen** Störungen in Abbildung 12 zeigt sich durch das Training eine deutliche Leistungssteigerung über alle Modelle hinweg.

Auffällig ist hierbei die unterschiedliche Ausprägung dieses Zugewinns in Abhängigkeit von der Modellarchitektur. DistilBERT, das initial am stärksten unter den Schreibfehlern litt und auf unter 76 % abfiel, verzeichnet mit einem Plus von 8,0 Prozentpunkten den größten relativen Leistungszuwachs. Dies lässt vermuten, dass die begrenzte Modellkapazität, die im unvorbereiteten Zustand ein Nachteil war, durch das gezielte Training effizient genutzt werden kann, um sich spezifisch an die Rauschverteilung anzupassen. Auch andere Modelle profitieren erheblich vom Training: BERT (+6,6), RoBERTa (+6,3), DeBERTA (+6,8), XLNet (+6,6).

Im Gegensatz dazu fällt der Zugewinn bei CANINE mit 3,0 Prozentpunkten vergleichsweise gering aus. Dieser scheinbar kleine Effekt ist jedoch konsistent mit der zuvor festgestellten hohen Grundrobustheit des Modells. Da CANINE aufgrund seiner charakterbasierten Verarbeitung bereits ohne spezifisches Training sehr widerstandsfähig gegen orthografische Fehler ist, fällt das verbleibende Optimierungspotenzial naturgemäß geringer aus.

Im Schnitt gelang es den Modellen in dieser Kategorie, mehr als die Hälfte des ursprünglich durch die Störungen verursachten Leistungsabfalls zurückzugewinnen.

Abbildung 13 zeigt, dass auch im Bereich der **semantischen** Störungen das robuste Training zu konsistenten Leistungssteigerungen über alle untersuchten Modelle hinweg führt.

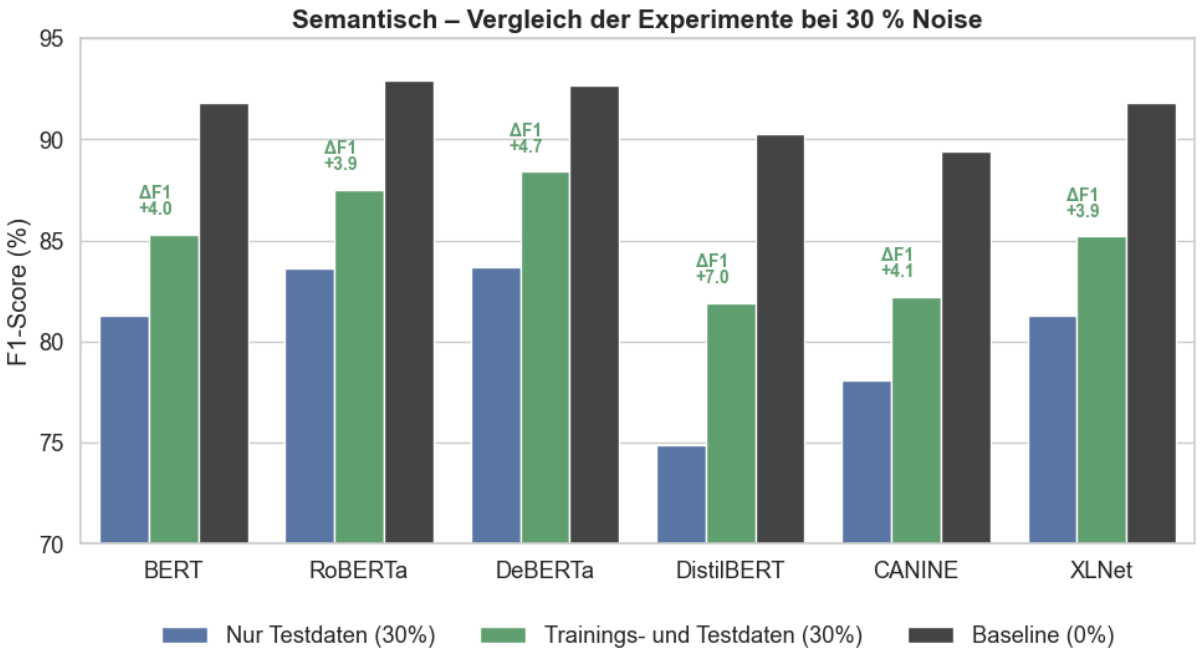


Abbildung 13: Modellleistung mit und ohne semantische Störungen in Trainingsdaten- Gegenüberstellung der Micro-F1-Scores bei 30 % veränderten Tokens für Modelle mit nur gestörten Testdaten und solchen mit zusätzlich gestörten Trainingsdaten, jeweils im Vergleich zur Baseline.

DistilBERT profitiert erneut am stärksten und verzeichnet einen Zuwachs von 7,0 Prozentpunkten, was darauf hindeutet, dass das Modell lernt, sich weniger auf spezifische, nun potenziell fehlerhafte Schlüsselwörter zu verlassen und stattdessen robustere Kontextrepräsentationen nutzt.

Ein interessantes Detail offenbart der Vergleich zwischen DeBERTa und RoBERTa, die sich in den vorherigen Experimenten oft sehr ähnlich verhielten. Hier kann DeBERTa mit einem Zugewinn von 4,7 Prozentpunkten einen sichtbareren Vorteil gegenüber RoBERTa (+3,9 Prozentpunkte) erzielen. Dies legt die Vermutung nahe, dass DeBERTa mit dem Disentangled-Attention-Mechanismus stärker vom spezialisierten Training profitieren kann. Es scheint effizienter darin zu sein, trotz Rauschens semantisch robustere Repräsentationen zu erlernen, während RoBERTa, dessen Stärke primär auf Skalierung und Modellgröße beruht, hier möglicherweise früher an Sättigungsgrenzen stößt.

Im direkten Vergleich zu den orthografischen Experimenten fällt jedoch über alle Architekturen auf, dass der durchschnittliche Grad der Wiederherstellung insgesamt geringer ausfällt. Während bei Schreibfehlern oft mehr als die Hälfte des ursprünglichen Leistungsverlusts kompensiert werden konnte, bleiben die Zugewinne hier moderater. Dies dürfte auf die unterschiedliche Natur der Störungen zurückzuführen sein.

Orthografische Fehler folgen oft, insbesondere bei der künstlichen Generierung, definierten Mustern, die ein neuronales Netz effektiv erlernen kann. Semantische Störungen hingegen weisen eine deutlich höhere Varianz und Komplexität auf, da die Unvorhersehbarkeit, mit welchem falschen Begriff ein Kontext korrumpiert wird, es den Modellen erschwert, eine ähnlich effektive generelle Kompensationsstrategie zu entwickeln.

Syntaktische Störungen profitierten am stärksten vom angepassten Training. Da diese Kategorie initial die größten Leistungseinbrüche verursachte, war das theoretische Verbesserungspotenzial hier jedoch auch am höchsten. Abbildung 14 visualisiert diese Rückgewinne

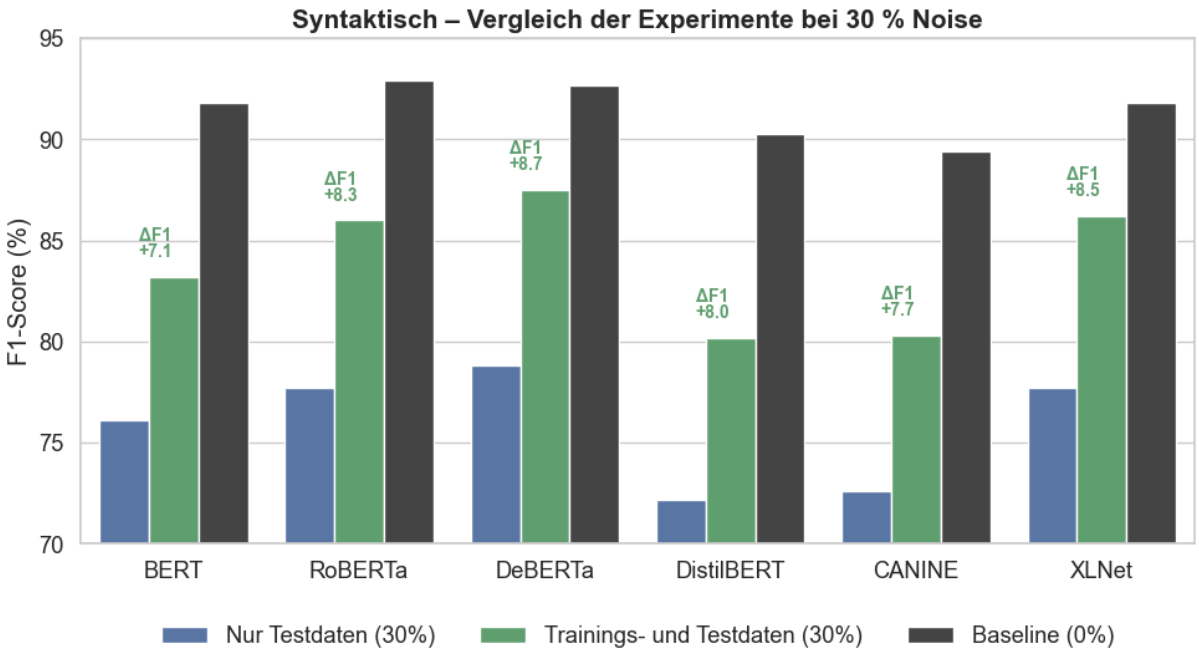


Abbildung 14: Modellleistung mit und ohne syntaktische Störungen in Trainingsdaten- Gegenüberstellung der Micro-F1-Scores bei 30 % veränderten Tokens für Modelle mit nur gestörten Testdaten und solchen mit zusätzlich gestörten Trainingsdaten, jeweils im Vergleich zur Baseline.

Besonders bemerkenswert ist die Leistung von DeBERTa und XLNet in diesem Szenario. Mit Zugewinnen von 8,7 und 8,5 Prozentpunkten erzielen sie nicht nur die höchsten absoluten Zugewinne, sondern demonstrieren auch die stärkste Adaptionsfähigkeit. Dies legt nahe, dass ihre spezifischen Architekturmerkmale ihnen einen entscheidenden Vorteil verschaffen. Der Disentangled-Attention-Mechanismus bei DeBERTa und das auf Permutationen basierende Pretraining von XLNet scheinen diese Modelle nicht nur passiv robuster gegen Änderungen der Wortreihenfolge zu machen, sondern befähigen sie auch dazu, diese nicht-linearen Kontexte aktiv besser zu erlernen. Im Gegensatz zu Modellen mit starren absoluten Positionskodierungen können sie die neuartigen, gestörten Strukturmuster effizienter in ihre internen Repräsentationen integrieren.

Insgesamt deuten die deutlichen Zugewinne darauf hin, dass die Modelle durch das Training effektive Strategien entwickeln, um ihre Abhängigkeit von einer korrekten globalen Grammatik zu reduzieren. Sie scheinen sich stärker auf verbleibende lokale Indikatoren zu fokussieren, wie etwa die Morphologie der Entitäten selbst oder unmittelbare Nachbarwörter, anstatt auf die korrumpierte Satzstruktur zu vertrauen.

Trotz dieser Anpassungsfähigkeit erreichen die absoluten F1-Scores im syntaktischen Bereich nicht ganz das Niveau der orthografischen Experimente nach robustem Training, was unterstreicht, dass eine zerstörte Satzstruktur fundamental schwieriger zu kompensieren bleibt als lokale Schreibfehler.

Zudem wirft diese starke Anpassung an gestörte Grammatik eine wichtige weiterführende Frage auf. Es wäre interessant zu prüfen, ob diese neu erlernten Strategien potenziell schädlich sind, wenn das Modell wieder auf sauberen, grammatikalisch korrekten Texten angewendet wird. Dieser mögliche "Cost of Robustness" könnte bedeuten, dass Modelle durch die Reduzierung ihrer Abhängigkeit von korrekter Syntax verlernen, die feinen Nuancen einer perfekten Grammatik optimal für die Präzision zu nutzen.

6.4 Störungen im Trainingsdatensatz

Ergänzend zu den bisherigen Szenarien untersucht dieser Abschnitt die Auswirkungen verminderter Datenqualität, die sich auf die Trainingsphase beschränkt. Die Modelle wurden hierbei auf gestörten Daten trainiert, die Evaluation erfolgte jedoch anschließend auf dem originalen, fehlerfreien Testdatensatz. Dieses Experiment erfüllt einen doppelten Zweck. Zum einen simuliert es ein Praxisszenario mit qualitativ minderwertigen Trainingsdaten wie sie etwa durch Web-Scraping entstehen können. Zum anderen dient es als empirische Überprüfung der in Kapitel 5.3 erwähnten „Cost of Robustness“. Es wird analysiert, ob die Anpassung an Trainingsrauschen zu einer Verschlechterung der Modellleistung unter Idealbedingungen führt.

Tabelle 11 fasst die Ergebnisse für dieses Szenario zusammen. Auffällig ist zunächst die hohe Resilienz aller Modelle gegenüber reinen Textstörungen in der Trainingsphase. Im Gegensatz zu den drastischen Einbrüchen bei verrauschten Testdaten in Kapitel 6.2 führt selbst eine massive Störung von 30 % im Training kaum zu Leistungsabfällen. Auch die Standardabweichungen, welche zugunsten der besseren Lesbarkeit in Anhang 4 dokumentiert sind, nähern sich wieder den Werten der Baselines an, was auf eine weitgehend stabile Modellanpassung trotz der Trainingsstörungen hinweist.

Art	Störung	BERT	RoBERTa	DeBERTa	DistilBERT	CANINE	XLNet
Baseline	0%	91,8	**92,9**	92,7	90,3	89,4	91,8
Orthografisch	10%	91,5	92,5	**92,6**	89,9	89,3	91,6
	20%	91,3	92,7	**92,8**	89,5	89,0	91,6
	30%	90,9	**92,6**	92,5	88,8	88,8	91,3
Orthografisch (S)	10%	91,6	92,4	**92,6**	90,1	89,3	91,8
	20%	91,6	92,3	**92,4**	89,8	89,1	91,8
	30%	91,5	91,9	**92,2**	89.6	88,9	91,7
Semantisch	10%	90,7	91,7	**92,2**	89,5	88,9	91,2
	20%	90,8	91,8	**92,3**	88,9	89.0	91,2
	30%	90,1	91,6	**92,0**	88,1	88,7	90,8
Semantisch (S)	10%	91,1	91,9	**92,0**	89,9	88,6	91,3
	20%	90,9	**91,8**	**91,8**	89,7	88,4	91,0
	30%	90,4	91,3	**91,6**	89,1	88,2	90,7
Label-bezogen	10%	81,8	**84,7**	83,5	79,9	80,9	83,1
	20%	79,5	**83,0**	81,9	78,2	80,1	82,6
	30%	78,3	**81,3**	80,4	76,9	79,9	80,7
Syntaktisch	10%	90,1	91,7	**91,8**	88,8	88,5	90,1
	20%	89,7	91,2	**91,3**	87,9	87,8	89,4
	30%	89,1	90,5	**91,0**	87,7	87,1	88,7

Tabelle 11: Ergebnisse Datenqualitätsminderungen Trainingsdatensatz- Detaillierte gemittelte Micro-F1-Scores der Modelle bei unterschiedlichen Arten und Intensitäten von Datenstörungen auf dem CoNLL-2003-Datensatz. Störungen wurden dabei im Trainings- sowie Validierungsdatensatz vorgenommen. Aufgrund des besseren Leseflusses wurde die Darstellung der Standardabweichungen in Anhang 4 ausgelagert.

Bei orthografischen Störungen ist der F1-Verlust besonders gering. RoBERTa fällt von 92,9 % auf 92,6 % und selbst das sensitivere DistilBERT verliert nur 1,5 Prozentpunkte und sinkt von 90,3 % auf 88,8 %. Interessanterweise lässt sich bei einigen Modellen ein nicht-linearer Verlauf beobachten. So steigt der F1-Score von RoBERTa zwischen 10 % und 20 % Störungsanteil leicht von 92,5 % auf 92,7 % an. Auch DeBERTa zeigt dieses Phänomen und übertrifft bei 20 % Noise mit 92,8 % sogar minimal seine ursprüngliche Baseline von 92,7 %.

Dies könnte darauf hindeuten, dass ein moderates Maß an orthografischem Rauschen im Training wie eine Art Datenerweiterung wirkt, die das Modell zwingt robustere interne Repräsentationen zu lernen und somit Overfitting auf spezifische Schreibweisen zu verhindern.

Ein ähnliches Bild zeigt sich bei semantischen Störungen, wo die Leistungsabfälle ebenfalls minimal bleiben und die Modelle robust genug erscheinen, um die zugrundeliegenden Entitätskonzepte auch aus inhaltlich leicht verfremdeten Sätzen zu extrahieren. Im Gegensatz dazu verzeichnen syntaktische Störungen bei hohen Intensitäten etwas deutlichere Einbußen. Während die Werte bei 10 % noch stabil sind, fallen sie bei 30 % sichtbar ab. RoBERTa sinkt auf 90,5 % und DeBERTa auf 91,0 %. Dies bestätigt erneut die kritische Rolle der Syntax für NER-Modelle. Wenn die grammatikalische Struktur bereits im Training zu stark zerstört ist, scheint es den Modellen schwerer zu fallen, die korrekten positionsabhängigen Muster zu erlernen, die für eine präzise Extraktion auf sauberen Daten notwendig wären.

Label-bezogene Störungen

Einen fundamental anderen Verlauf zeigt die neu eingeführte Kategorie der label-bezogenen Störungen, deren Ergebnisse in Abbildung 15 visualisiert sind. Diese Störungsart wurde methodisch erst in diesem dritten Experiment betrachtet, da in den vorherigen Szenarien der Fokus auf verrauschten Eingabedaten im Testzeitpunkt lag, wo eine Manipulation der zu validierenden Labels nicht zielführend gewesen wäre.

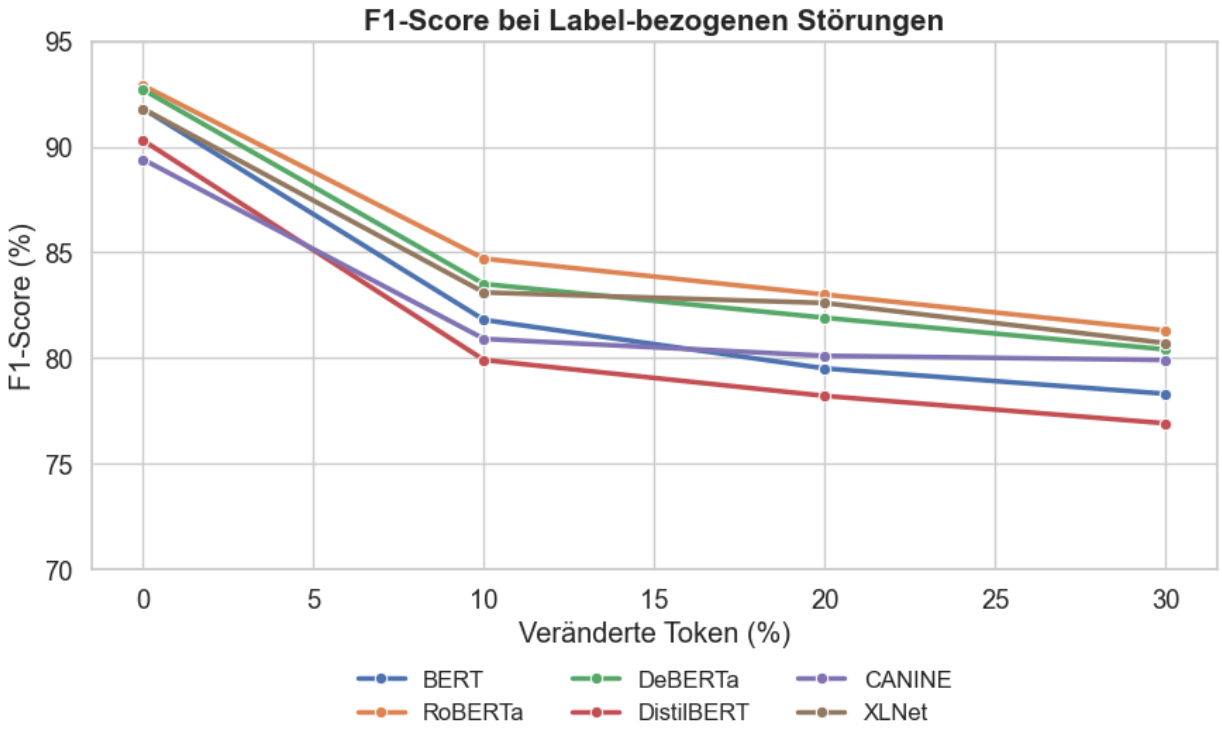


Abbildung 15: Leistungsverlust bei Label-bezogenen Störungen- Vergleich der Micro-F1-Scores bei zunehmender Störungsintensität, um die Auswirkungen der eingeführten Annotationsfehler (z. B. verkürzte, erweiterte oder falsch klassifizierte Entitäten) auf die Modellleistung zu veranschaulichen.

Eine Analyse des Leistungsabfalls offenbart, dass es sich um eine nicht-lineare Degradation handelt. Der initiale Einbruch zwischen 0 % und 10 % Störungsanteil ist übermäßig stark und verursacht bei Modellen wie BERT und DistilBERT Verluste von über 10 Prozentpunkten. Dieser massive Schock deutet darauf hin, dass bereits ein moderater Anteil falscher Ground-Truth-Daten ausreicht, um die feinen Entscheidungsgrenzen des Modells signifikant zu destabilisieren. Interessanterweise zeigt sich im weiteren Verlauf zwischen 10 % und 30 % eine deutliche Glättung der Kurven. Obwohl der Anteil falscher Labels weiter linear zunimmt, verlangsamt sich der weitere Leistungsabfall spürbar.

Dieses Sättigungsverhalten könnte mehrere Ursachen haben. Zum einen könnten interne Regularisierungsmechanismen verhindern, dass sich das Modell vollständig an die widersprüchlichen Trainingssignale anpasst. Zum anderen ist es wahrscheinlich, dass nach dem initialen Verlust seltenerer oder schwierigerer Entitäten ein "robuster Kern" von sehr häufigen und eindeutigen Entitäten verbleibt. Diese tauchen in den Daten so oft auf, dass sie selbst bei 30 % Rauschen noch in der Mehrzahl der Fälle korrekt annotiert sind und somit weiterhin stabil erlernt werden können. Zudem könnte die spezifische Art der künstlichen Störungsgenerierung eine Rolle spielen. Wenn die künstlich erzeugten Fehler bestimmten Mustern folgen, könnten die Modelle lernen, diese spezifischen Fehlertypen als solche zu erkennen und ihren Einfluss zu dämpfen.

Ein weiterer klarer Trend zeigt sich im Zusammenhang mit der Modellkapazität. Das leistungsstarke RoBERTa-Modell erweist sich in diesem Szenario als am widerstandsfähigsten, während das komprimierte DistilBERT die stärksten Einbußen verzeichnet. Dies lässt einen direkten Zusammenhang zwischen Modellgröße und Robustheit gegenüber Annotationsfehlern vermuten. Größere Modelle verfügen über mehr Parameter, die es ihnen möglicherweise erlauben, redundante korrekte Muster trotz widersprüchlicher Signale in den Trainingsdaten robust abzuspeichern. Kleinere Modelle wie DistilBERT besitzen weniger Kapazität für solche Redundanzen und werden daher schneller von den falschen Trainingssignalen negativ beeinflusst.

6.5 Abgleich mit Literatur

Dieser Abschnitt setzt die in den Experimenten erzielten Ergebnisse in den Kontext der in der SLR identifizierten Ergebnisse. Dabei werden die Befunde für jede der vier untersuchten Störungskategorien mit vergleichbaren Studien abgeglichen, um Gemeinsamkeiten und Unterschiede herauszuarbeiten.

Orthografische Störungen

Die Experimente zu orthografischen Störungen zeigten auf dem Testdatensatz einen moderaten Leistungsabfall, wobei der mittlere F1-Score bei 30 % Störungsintensität von über 91 % auf knapp über 80 % sank. Es offenbarten sich deutliche architektonische Unterschiede, da das zeichenbasierte CANINE-Modell mit einem Verlust von nur etwa 6 Prozentpunkten besonders robust war, während Subword-basierte Modelle wie DistilBERT Einbußen von bis zu 18 Prozentpunkten verzeichneten.

Diese Ergebnisse decken sich tendenziell gut mit der Literatur. Bagla und Gupta (2021) berichteten zwar von etwas schwerwiegenderen Einbußen für BERT, bestätigten aber ebenfalls, dass modernere Architekturen wie RoBERTa robuster agieren. Auch Moradi und Samwald (2021) fanden ähnliche Relationen und Verlustraten in vergleichbaren Größenordnungen, wobei RoBERTa auch hier tendenziell stabiler abschnitt. Die hier ermittelten Werte liegen zudem nah an den rund 15 Punkten Verlust, die Simoncini und Spanakis (2021) für BERT meldeten.

Das Training auf verrauschten Daten führte in den durchgeführten Experimenten zu signifikanten Rückgewinnen und kompensierte im Schnitt mehr als die Hälfte des ursprünglichen Leistungsverlusts. Insbesondere schwächere Modelle wie DistilBERT profitierten überproportional stark. Dies korrespondiert mit Befunden von Namysl et al. (2020), deren Noise-Aware Training etwa zwei Drittel der verlorenen Performance wiederherstellen konnte. Auch Simoncini und Spanakis (2021) berichten von einer fast vollständigen Wiederherstellung der Leistung nach adversarialem Training, was die hohe Effektivität dieser Methode zur Robustheitssteigerung unterstreicht.

Semantische Störungen

Die Experimente mit semantischen Störungen führten zu einem mittleren Leistungsabfall auf dem Testdatensatz. Bei einer Störungsintensität von 30 % sanken die F1-Scores auf Werte zwischen 81 % für BERT und knapp 84 % für DeBERTa. Dabei erwiesen sich modernere Architekturen wie DeBERTa und RoBERTa als widerstandsfähiger im Vergleich zum Basis-BERT-Modell.

Die Literatur berichtet teilweise von deutlich extremeren Leistungsabfällen mit Verlustspannen von bis zu 40 Prozentpunkten, die in dieser Arbeit nicht bestätigt werden konnten. Diese Diskrepanz lässt sich vermutlich auf methodische Unterschiede zurückführen. Viele Studien fokussieren sich auf direkte Manipulationen der Entitäten selbst oder nutzen gezielte adversariale Angriffe, die darauf ausgelegt sind maximalen Schaden anzurichten. Die Ergebnisse dieser Arbeit bestätigen jedoch den in der Literatur beobachteten Trend, dass modernere Architekturen wie RoBERTa robuster auf Kontextveränderungen reagieren als ältere Modelle wie BERT.

Zudem deckt sich unsere Beobachtung, dass reine Kontextmanipulationen weniger destruktiv sind als Entitätsveränderungen, mit den grundlegenden Erkenntnissen vergleichbarer Studien.

Das Training mit semantisch gestörten Daten führte auch in dieser Arbeit zu klaren Verbesserungen. Dies deckt sich mit der Forschungsliteratur, wo Methoden der Datenanreicherung oder adversariales Training die Resilienz gegenüber semantischen Angriffen signifikant steigern. So konnten beispielsweise Ying et al. (2022) den durch Angriffe verursachten Leistungsverlust fast vollständig kompensieren und von ursprünglich 32 % auf unter 5 % reduzieren. Auch Jin et al. (2023) berichten von starken Wiederherstellungsraten, bei denen etwa die Hälfte der verlorenen Prozentpunkte zurückgewonnen wurde.

In den hier durchgeführten Experimenten fiel die relative Kompensation etwas geringer aus. Dies dürfte primär auf methodische Unterschiede zurückzuführen sein, da in dieser Arbeit ein Training mit breit gestreutem und zufälligem Rauschen durchgeführt wurde. Spezialisierte Ansätze aus der Literatur können sich hingegen oft gezielter an spezifische Angriffsmuster anpassen und erzielen dadurch höhere Rückgewinne.

Syntaktische Störungen

Syntaktische Störungen erwiesen sich in den Experimenten als die destruktivste Kategorie. Bei einer Störungsintensität von 30 % fielen die F1-Scores im Schnitt auf unter 76 %. DeBERTa zeigte hier eine vergleichsweise höhere Resilienz als andere Modelle und XLNet konnte mit DeBERTa mithalten, was auf die Vorteile ihrer spezifischen Architekturen (Disentangled Attention bzw. Permutation Language Modeling) bei gestörter Wortreihenfolge hindeutet. DistilBERT hingegen reagierte besonders empfindlich auf syntaktische Fehler, was die Bedeutung der Modellkapazität für die Kompensation struktureller Defizite unterstreicht.

In der Literatur werden syntaktische Störungen seltener untersucht und oft mit geringeren Effekten beschrieben. Eine Ausnahme bilden Moradi und Samwald (2021), die F1-Verluste von bis zu 16 Prozentpunkten bei Wortstellungsfehlern meldeten – ein Wert, der den hier beobachteten Größenordnungen nahekommt. Zudem vermuteten sie, dass die spezifische Stärke von XLNet bei Syntaxfehlern auf dessen fortschrittlichere Positionskodierung durch Permutation Language Modeling zurückzuführen ist. Diese Hypothese wird durch die hier gezeigte hohe Resilienz von XLNet sowie dem architektonisch ähnlichen DeBERTa gestützt.

Die Diskrepanz zu anderen Studien könnte darauf zurückzuführen sein, dass die dort verwendeten Störungsquoten niedriger waren oder die implementierten Fehler weniger invasiv in die Satzstruktur eingriffen. Es ist nicht auszuschließen, dass die in dieser Arbeit gewählte Imple-

mentierung syntaktischer Störungen vergleichsweise aggressiv war. Eine Validierung der gestörten Sätze durch unabhängige Personen oder Fachexperten hätte hier zusätzliche Klarheit über den Grad der linguistischen Entstellung bringen können.

Label-bezogene Störungen

Störungen der Labels im Training führten bereits bei 10 % zu massiven Leistungseinbrüchen. BERT verzeichnete beispielsweise einen Verlust von über 10 Prozentpunkten an Modelleistung, was die extreme Sensitivität gegenüber falschen Trainingssignalen verdeutlicht. Auffällig ist jedoch der weitere Verlauf in den eigenen Experimenten, da sich der Leistungsabfall nach diesem initialen Schock schnell abschwächt und in eine Sättigungsphase übergeht.

Dieser starke initiale Verlust deckt sich grundlegend mit der Literatur, die ebenfalls von massiven Einbußen durch Label-Rauschen berichtet. Allerdings gehen die dort verzeichneten Abstürze häufig noch tiefer. So melden Merdjanovska et al. (2024) Verluste von bis zu 31,4 Punkten auf real verrauschten Datensätzen, wenngleich die genauen Rauschintensitäten bei realen Daten oft schwer zu quantifizieren sind.

Ein Erklärungsansatz für diese Diskrepanz liefert Zhu et al. (2022), die zeigten, dass reales Rauschen deutlich schädlicher ist als synthetisches. Die Ursache liegt vermutlich in den ungleichen und komplexen Mustern realer Annotationsfehler. Synthetisches Rauschen hingegen folgt oft gleichförmigeren Verteilungen, die vom Modell ab einem gewissen Grad möglicherweise leichter als Störsignal identifiziert und ignoriert werden können, was den hier beobachteten Sättigungseffekt begünstigt.

Die in dieser Arbeit beobachtete Korrelation zwischen Modellgröße und Robustheit, bei der das größere RoBERTa-Modell stabiler agierte als das kleinere DistilBERT, deckt sich teilweise mit Erkenntnissen aus der Literatur. Sie kann jedoch nicht uneingeschränkt bestätigt werden. Fokam und Beukman (2023) fanden zwar ebenfalls Tendenzen, dass leistungsfähigere Modelle robuster sind, wobei beispielsweise das größere Afro-XLM-R besser abschnitt als mBERT, allerdings zeigte sich dieser Effekt in ihren Untersuchungen nicht durchgängig in gleichem Maße.

7 Fazit

Die vorliegende Arbeit untersuchte den Einfluss von Datenqualitätsproblemen auf die Robustheit Transformer-basierter NER-Modelle. Ziel war es, ein systematisches Verständnis dafür zu entwickeln, welche Arten von Störungen existieren, wie stark diese die Modellleistung beeinträchtigen und inwiefern architektonische Unterschiede die Robustheit beeinflussen. Zur Beantwortung der Forschungsfragen wurde ein hybrider methodischer Ansatz gewählt, bestehend aus einem systematischen Literaturreview und einer umfassenden experimentellen Untersuchung auf Basis des CoNLL-2003-Datensatzes.

Die erste Forschungsfrage nach den auftretenden Arten von Datenstörungen konnte durch das systematische Literaturreview beantwortet werden. Im Zuge der Untersuchung wurden insgesamt 26 verschiedene Datenstörungen identifiziert und den fünf Kategorien orthografische, syntaktische, semantische, Label-bezogene und sonstige Störungen zugeordnet.

Auf Grundlage dieser Ergebnisse wurde ein experimentelles Untersuchungsdesign entwickelt, das die Auswirkungen der identifizierten Störungstypen auf sechs repräsentative Transformer Modelle analysierte: BERT, RoBERTa, DeBERTa, XLNet, DistilBERT und CANINE.

Hinsichtlich der zweiten Forschungsfrage, die den Einfluss unterschiedlicher Störungstypen und Intensitäten auf die Modellleistung untersucht, zeigten die Experimente auf dem Testdatensatz eine deutliche, jedoch nicht lineare Abhängigkeit zwischen Datenqualität und Leistungsfähigkeit. Syntaktische Störungen erwiesen sich als besonders destruktiv. Bei rund zehn Prozent veränderter Token kam es zu den stärksten anfänglichen Leistungseinbrüchen. Bei höheren Anteilen sank die Leistung weiter, allerdings in deutlich geringerem Ausmaß. Beim maximal untersuchten Anteil von 30 Prozent lag der mittlere F1-Wert bei 75,8%, ausgehend von einer Baseline von rund 91,5 Prozent. Orthografische Fehler führten zunächst zu einer langsameren Degradation und zeigten einen klaren Kipppunkt zwischen 20 und 30 Prozent veränderter Tokens, ab dieser Schwelle fiel die Leistung rasch auf etwa 80 Prozent. Semantische Störungen wirkten insgesamt moderater und zeigten einen gleichmäßigeren Verlauf mit einem durchschnittlichen Rückgang von rund neun Prozentpunkten.

In Bezug auf die dritte Forschungsfrage zeigte sich, dass Modelle durch die Exposition gegenüber verrauschten Daten im Training deutlich robuster auf dieselben Teststörungen reagierten. Sie kompensierten häufig mehr als die Hälfte der ursprünglichen Leistungsverluste, wodurch die zuvor abrupten Einbrüche einem flacheren Verlauf wichen. Bei ausschließlicher Störung der Trainingsdaten erwiesen sich die Modelle als resilient gegenüber Textfehlern, wobei im Durchschnitt nur minimale Verluste von 0,5 bis 1 Prozentpunkt gegenüber der Baseline verzeichnet wurden. Dies impliziert, dass die gewonnene Robustheit kaum auf Kosten einer geringeren Präzision auf sauberen Daten erkauft wird.

Im starken Gegensatz dazu führten Label-bezogene Störungen zu einem nichtlinearen Leistungsabfall, der bereits bei zehn Prozent veränderter Tokens über acht Prozentpunkte betrug und erst bei höheren Anteilen in eine Sättigungsphase überging.

Ergänzend zu diesen allgemeinen Beobachtungen kristallisierten sich im Rahmen der vierten Forschungsfrage klare Muster hinsichtlich der verschiedenen Modellarchitekturen heraus. RoBERTa, das größte Modell, und DeBERTa erwiesen sich als die leistungsstärksten und demonstrierten auf Testdaten eine vergleichbar hohe Grundrobustheit. In der Trainingsphase zeigte DeBERTa jedoch eine überlegene Adaptionsfähigkeit an qualitätsgeminderten Daten, was sich auf den Einsatz des Disentangled Attention Mechanismus zurückführen lässt. Das Standard BERT Modell ordnete sich im Mittelfeld ein. Architekturspezifische Vorteile zeigten sich in einzelnen Störungstypen: Das zeichenbasierte CANINE Modell war besonders resistent gegenüber orthografischen Fehlern, während XLNet durch seinen Permutation Language Modeling Ansatz eine überdurchschnittliche Stabilität bei syntaktischen Störungen zeigte. Das kleinere DistilBERT Modell verzeichnete die stärksten relativen Einbußen, was die Bedeutung der Modellkapazität als zentrale Ressource zur Kompensation von Datenrauschen unterstreicht.

7.1 Kritische Reflexion

Bei der Interpretation der gewonnenen Ergebnisse ist zu berücksichtigen, dass die Arbeit bestimmten Limitationen unterliegt.

Zunächst betrifft dies den systematischen Literaturreview. Da im Rahmen der Recherche keine Rückwärtssuche durchgeführt wurde, ist nicht auszuschließen, dass relevante Publikationen, die zwar in der Literatur referenziert, aber nicht direkt über Suchbegriffe auffindbar waren, unberücksichtigt geblieben sind. Dadurch könnte das Spektrum identifizierter Datenstörungen unvollständig sein.

Eine weitere Einschränkung betrifft die Auswahl der Modelle. Obwohl mit BERT, RoBERTa, DeBERTa, XLNet, DistilBERT und CANINE ein breites Spektrum gängiger Transformer-Architekturen abgedeckt wurde, bleibt die Analyse auf diese begrenzte Anzahl von Ansätzen beschränkt. Insbesondere mehrsprachige, domänenspezifisch vortrainierte oder neuere architekturelle Varianten wurden nicht einbezogen.

Auch die Datengrundlage stellt eine Einschränkung dar. Die Experimente basierten ausschließlich auf dem CoNLL-2003-Datensatz, der eine klar strukturierte und redaktionell homogene Textsammlung darstellt. In stärker domänenspezifischen Korpora, etwa aus medizinischen, juristischen oder sozialen Kontexten, könnten andere Fehlertypen dominieren oder vorhandene Störungen eine abweichende Wirkung entfalten.

Darüber hinaus ist die Simulation der Datenstörungen kritisch zu betrachten. Echte Datensätze weisen meist komplexere und kontextabhängige Fehlerstrukturen auf, die sich nicht vollständig durch regelbasierte Transformationen nachbilden lassen. In den Experimenten wurden alle Störungstypen gleichverteilt simuliert, was in der Praxis nicht der tatsächlichen Fehlerverteilung entspricht. Eine empirische Erhebung realer Häufigkeiten und Muster von Datenqualitätsproblemen wäre notwendig, um realistischere Szenarien abzubilden. Dies ist besonders relevant, da die Analyse gezeigt hat, dass unterschiedliche Störungstypen die Modellleistung in sehr unterschiedlichem Ausmaß beeinträchtigen. Zudem lässt der im Vergleich zur Literatur stärkere Leistungsabfall bei syntaktischen Störungen vermuten, dass die Implementierung der Störungsregeln teilweise zu stark in die Satzstruktur eingreift. Eine unabhängige Überprüfung der generierten Störungen durch eine zweite Person hätte zu einer besseren Einschätzung und Feinabstimmung beitragen können.

7.2 Ausblick

Die in dieser Arbeit gewonnenen Erkenntnisse zeigen deutliche architektonische Unterschiede in der Robustheit Transformer-basierter NER-Modelle. Diese Ergebnisse sollten in künftigen Studien auf weitere Datensätze und Domänen übertragen werden, um zu prüfen, inwieweit die identifizierten Muster generalisierbar sind. Besonders relevant ist die Frage, ob die beobachteten Stärken und Schwächen der Modelle auch in stärker domänenspezifischen oder mehrsprachigen Anwendungsfeldern bestehen bleiben.

Für Anwenderinnen und Anwender liefert die Arbeit bereits wichtige Hinweise darauf, welche Modellarchitekturen in bestimmten Szenarien besonders robust reagieren. Dieses Wissen kann genutzt werden, um Modelle gezielter auszuwählen und Fehlerrisiken frühzeitig zu erkennen. Darüber hinaus könnten die identifizierten Anfälligkeiten genutzt werden, um bestehende Architekturen gezielt zu verbessern. Eine Möglichkeit bestünde darin, architektonische Stärken zu kombinieren und Mechanismen wie den Disentangled-Attention-Mechanismus weiterzuentwickeln, die in dieser Arbeit vielversprechende Ansätze zur robusteren Kontextrepräsentation gezeigt hat.

Zudem sollte das Training von Modellen unter Einbeziehung gezielter Datenstörungen weiter ausgebaut werden. Die Experimente haben gezeigt, dass der Preis für erhöhte Robustheit gering ausfällt und dass Modelle, die bereits im Training verrauschten Daten ausgesetzt sind, deutlich stabiler auf Qualitätsminderungen reagieren.

Schließlich sollten auch die eingesetzten Störungsmethoden weiter verfeinert werden, um realistischere Testbedingungen zu schaffen und die Aussagekraft künftiger Evaluierungen zu erhöhen. Eine empirische Erhebung realer Fehlermuster und deren Integration in Störungssimulationen würde eine noch genauere Validierung der Modellrobustheit ermöglichen.

Literaturverzeichnis

Ahmed, A., Huang, D [Degen], Arafat, S. Y. & Hameed, I. (2024). Enriching Urdu NER with BERT Embedding, Data Augmentation, and Hybrid Encoder-CNN Architecture. *ACM Transactions on Asian and Low-Resource Language Information Processing*, *23*(4), 1–38. https://doi.org/10.1145/3648362

Ai, C., Jiang, Y., Huang, S., Xie, P. & Tu, K. (2024). *Learning Robust Named Entity Recognizers From Noisy Data With Retrieval Augmentation*. https://arxiv.org/pdf/2407.18562

Akbik, A., Blythe, D. & Vollgraf, R. (2018). Contextual String Embeddings for Sequence Labeling. *Proceedings of the 27th International Conference on Computational Linguistics*, 1638–1649. https://aclanthology.org/C18-1139/

Al Sharou, K., Li, Z [Zhenhao] & Specia, L. (2021). Towards a Better Understanding of Noise in Natural Language Processing. *Proceedings of the International Conference on Recent Advances in Natural Language Processing (RANLP 2021)*, 53–62. https://aclanthology.org/2021.ranlp-1.7/

Aliakbarzadeh, A., Flek, L. & Karimi, A. (2025, 14. Januar). *Exploring Robustness of Multilingual LLMs on Real-World Noisy Data*. https://arxiv.org/pdf/2501.08322

Araujo, V., Carvallo, A., Aspillaga, C. & Parra, D. (2020). *On Adversarial Examples for Biomedical NLP Tasks*. https://arxiv.org/pdf/2004.11157

Bagla, K., Gupta, S., Kumar, A [Ankit] & Gupta, A. (2023). Noisy Text Data: foible of popular Transformer based NLP models. In *The Third International Conference on Artificial Intelligence and Machine Learning Systems* (S. 1–5). ACM. https://doi.org/10.1145/3639856.3639889

Bagla, K., Kumar, A [Ankit], Gupta, S. & Gupta, A. (2021). *Noisy Text Data: Achilles' Heel of popular transformer based NLP models*. https://arxiv.org/pdf/2110.03353

Batini, C., Cappiello, C., Francalanci, C. & Maurino, A. (2009). Methodologies for data quality assessment and improvement. *ACM Computing Surveys*, *41*(3), 1–52. https://doi.org/10.1145/1541880.1541883

Belinkov, Y. & Bisk, Y. (2017). *Synthetic and Natural Noise Both Break Neural Machine Translation*. https://arxiv.org/pdf/1711.02173

Bengio, Y [Yoshua], Ducharme, R., Vincent, P. & Janvin, C. (2003). A Neural Probabilistic Language Model. *Journal of machine learning research*. https://www.semanticscholar.org/paper/A-Neural-Probabilistic-Language-Model-Bengio-Ducharme/6c2b28f9354f667cd5bd07afc0471d8334430da7

Bernier-Colborne, G. & Langlais, P. (2020). HardEval: Focusing on Challenging Tokens to Assess Robustness of NER. *Proceedings of the Twelfth Language Resources and Evaluation Conference*, 1704–1711. https://aclanthology.org/2020.lrec-1.211/

Bernier-Colborne, G. & Vajjala, S. (2024). *Annotation Errors and NER: A Study with OntoNotes 5.0*. https://arxiv.org/pdf/2406.19172

Bhadauria, D., Sierra-Múnera, A. & Krestel, R. (2024). The Effects of Data Quality on Named Entity Recognition. *Proceedings of the Ninth Workshop on Noisy and User-generated Text (W-NUT 2024)*, 79–88. https://aclanthology.org/2024.wnut-1.8/

Bodapati, S., Yun, H. & Al-Onaizan, Y. Robustness to Capitalization Errors in Named Entity Recognition. *http://noisy-text.github.io*. https://arxiv.org/pdf/1911.05241

Boros, E., Hamdi, A., Linhares Pontes, E., Cabrera-Diego, L. A., Moreno, J. G., Sidere, N. & Doucet, A. (2020). Alleviating Digitization Errors in Named Entity Recognition for Historical Documents. *Proceedings of the 24th Conference on Computational Natural Language Learning*, 431–441. https://doi.org/10.18653/v1/2020.conll-1.35

Cai, E. & O'Connor, B. (2024). The State of Relation Extraction Data Quality: Is Bigger Always Better? *Findings of the Association for Computational Linguistics: ACL 2024*, 7893–7906. https://doi.org/10.18653/v1/2024.findings-acl.470

Chen, S., Neves, L. & Solorio, T. (2023). *Context-aware Adversarial Attack on Named Entity Recognition*. https://arxiv.org/pdf/2309.08999

Chu, Z., Zhang, R [Ruiyi], Yu, T., Jain, R., Morariu, V. I., Gu, J. & Nenkova, A. (2023, 25. Oktober). *Improving a Named Entity Recognizer Trained on Noisy Data with a Few Clean Instances*. https://arxiv.org/pdf/2310.16790

Chu, Z., Zhang, R [Ruiyi], Yu, T., Jain, R., Morariu, V., Gu, J. & Nenkova, A. (2024). Self-Cleaning: Improving a Named Entity Recognizer Trained on Noisy Data with a Few Clean Instances. *Findings of the Association for Computational Linguistics: NAACL 2024*, 196–210. https://doi.org/10.18653/v1/2024.findings-naacl.14

Clark, J. H., Garrette, D., Turc, I. & Wieting, J. (2022). Canine : Pre-training an Efficient Tokenization-Free Encoder for Language Representation. *Transactions of the Association for Computational Linguistics*, *10*, 73–91. https://doi.org/10.1162/tacl_a_00448

Das, S. & Paik, J. (2022). Resilience of Named Entity Recognition Models under Adversarial Attack. *Proceedings of the First Workshop on Dynamic Adversarial Data Collection*, 1–6. https://doi.org/10.18653/v1/2022.dadc-1.1

Derczynski, L., Ritter, A., Clark, S. & Bontcheva, K. (2013). Twitter Part-of-Speech Tagging for All: Overcoming Sparse and Noisy Data. *Proceedings of the International Conference Recent Advances in Natural Language Processing RANLP 2013*, 198–206. https://aclanthology.org/R13-1026/

DeVaney, S. A. (2016). Yin, R.K. (2016). Qualitative Research from Start to Finish, Second Edition. New York: The Guilford Press. ISBN: 978-1-4625-1797-8. 386 pp. *Family and Consumer Sciences Research Journal*, *44*(3), 324–325. https://doi.org/10.1111/fcsr.12144

Devlin, J., Chang, M.-W., Lee, K. & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. https://doi.org/10.18653/v1/N19-1423

Dirkson, A., Verberne, S. & Kraaij, W. (2021). *Breaking BERT: Understanding its Vulnerabilities for Named Entity Recognition through Adversarial Attack*. https://arxiv.org/pdf/2109.11308

Ebrahimi, J., Rao, A., Lowd, D. & Dou, D. (2018). HotFlip: White-Box Adversarial Examples for Text Classification. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, 31–36. https://doi.org/10.18653/v1/P18-2006

Ehrmann, M., Hamdi, A., Pontes, E. L., Romanello, M. & Doucet, A. (2024). Named Entity Recognition and Classification in Historical Documents: A Survey. *ACM Computing Surveys*, *56*(2), 1–47. https://doi.org/10.1145/3604931

Esmaail, N., Omar, N., Mohd, M., Fauzi, F. & Mansur, Z. (2024). Named Entity Recognition in User-Generated Text: A Systematic Literature Review. *IEEE Access*, *12*, 136330–136353. https://doi.org/10.1109/ACCESS.2024.3427714

Fokam, M. & Beukman, M. (2022). *The Impact of Data Corruption on Named Entity Recognition for Low-resourced Languages*. https://arxiv.org/pdf/2208.04568

Gao, J [Ji], Lanchantin, J., Soffa, M. L. & Qi, Y. (2018). Black-Box Generation of Adversarial Text Sequences to Evade Deep Learning Classifiers. In *2018 IEEE Security and Privacy Workshops (SPW)* (S. 50–56). IEEE. https://doi.org/10.1109/SPW.2018.00016

Garg, S. & Ramakrishnan, G. (2020). BAE: BERT-based Adversarial Examples for Text Classification. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 6174–6181. https://doi.org/10.18653/v1/2020.emnlp-main.498

Gartner. (2023). *Hype Cycle for Generative AI, 2023*. https://www.gartner.com/document/4726631

Gaser, M. (2022). *Subword-level Segmentation for Neural Machine Translation of Code-switched Dialectal Egyptian Arabic -English Text*. https://www.researchgate.net/publication/362477674_Subword-level_Segmentation_for_Neural_Machine_Translation_of_Code-switched_Dialectal_Egyptian_Arabic_-English_Text https://doi.org/10.13140/RG.2.2.10302.77123

Georg Heigold, Stalin Varanasi, Günter Neumann & Josef van Genabith (2018). How Robust Are Character-Based Word Embeddings in Tagging and MT Against Wrod Scramlbing or Randdm Nouse? *Proceedings of the 13th Conference of the Association for Machine Translation in the Americas (Volume 1: Research Track)*, 68–80. https://aclanthology.org/W18-1807/

Gong, Y., Liu, G., Xue, Y., Li, R. & Meng, L. (2023). A survey on dataset quality in machine learning. *Information and Software Technology*, *162*, 107268. https://doi.org/10.1016/j.infsof.2023.107268

Goodfellow, I., Bengio, Y [Yoshua] & Courville, A. (2016). *Deep Learning.* MIT Press. http://www.deeplearningbook.org

Goodfellow, I. J., Shlens, J. & Szegedy, C. (2014). *Explaining and Harnessing Adversarial Examples*. https://arxiv.org/pdf/1412.6572

Goyal, S., Doddapaneni, S., Khapra, M. M. & Ravindran, B. (2023). A Survey of Adversarial Defenses and Robustness in NLP. *ACM Computing Surveys*, *55*(14s), 1–39. https://doi.org/10.1145/3593042

Gururangan, S., Marasović, A., Swayamdipta, S., Lo, K., Beltagy, I., Downey, D. & Smith, N. A. (2020). Don’t Stop Pretraining: Adapt Language Models to Domains and Tasks. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 8342–8360. https://doi.org/10.18653/v1/2020.acl-main.740

Hamdi, A., Linhares Pontes, E., Sidere, N., Coustaty, M. & Doucet, A. (2023). In-depth analysis of the impact of OCR errors on named entity recognition and linking. *Natural Language Engineering*, *29*(2), 425–448. https://doi.org/10.1017/S1351324922000110

He, P [Pengcheng], Liu, X [Xiaodong], Gao, J [Jianfeng] & Chen, W. (2020, 5. Juni). *DeBERTa: Decoding-enhanced BERT with Disentangled Attention*. https://arxiv.org/pdf/2006.03654

Hendrycks, D. & Dietterich, T. (2019). *Benchmarking Neural Network Robustness to Common Corruptions and Perturbations*. https://arxiv.org/pdf/1903.12261

Hobbs, J. R., Appelt, D., Bear, J., Israel, D., Kameyalna, M. & Tyson, M. (1993). FASTUS: A System for Extracting Information from Text. *Human Language Technology: Proceedings of a Workshop Held at Plainsboro, New Jersey, March 21-24, 1993*. https://aclanthology.org/H93-1026/

Hochreiter, S. & Schmidhuber, J. (1997). Long short-term memory. *Neural computation*, *9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Huang, X., Chen, Y [Yubo], Wu, S [Shun], Zhao, J., Xie, Y. & Sun, W. (2021). Named Entity Recognition via Noise Aware Training Mechanism with Data Filter. *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, 4791–4803. https://doi.org/10.18653/v1/2021.findings-acl.423

Huang, Z., Xu, W. & Yu, K. (2015). *Bidirectional LSTM-CRF Models for Sequence Tagging*. https://arxiv.org/pdf/1508.01991

HuggingFace. (2025a). *Datasets - Library*. https://huggingface.co/docs/hub/en/datasets

HuggingFace. (2025b). *Token classification*. https://huggingface.co/docs/transformers/main/tasks/token_classification

HuggingFace. (2025c). *Token classification - Hugging Face LLM Course*. https://huggingface.co/learn/llm-course/chapter7/2

HuggingFace. (2025d). *Trainer Klasse*. https://huggingface.co/docs/transformers/main_classes/trainer

Jain, A., Patel, H., Nagalapatti, L., Gupta, N., Mehta, S., Guttula, S., Mujumdar, S., Afzal, S., Sharma Mittal, R. & Munigala, V. (2020). Overview and Importance of Data Quality for Machine Learning Tasks. In R. Gupta, Y. Liu, M. Shah, S. Rajan, J. Tang & B. A. Prakash (Hrsg.), *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (S. 3561–3562). ACM. https://doi.org/10.1145/3394486.3406477

Jehangir, B., Radhakrishnan, S. & Agarwal, R. (2023). A survey on Named Entity Recognition — datasets, tools, and methodologies. *Natural Language Processing Journal*, *3*, 100017. https://doi.org/10.1016/j.nlp.2023.100017

Jia, R., Raghunathan, A., Göksel, K. & Liang, P. (2019). Certified Robustness to Adversarial Word Substitutions. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 4127–4140. https://doi.org/10.18653/v1/D19-1423

Jin, L., Song, L., Xu, K. & Yu, D. (2021). Instance-adaptive training with noise-robust losses against noisy labels. *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 5647–5663. https://doi.org/10.18653/v1/2021.emnlp-main.457

Jin, X [Xiaomeng], Vinzamuri, B., Venkatapathy, S., Ji, H. & Natarajan, P. (2023). Adversarial Robustness for Large Language NER models using Disentanglement and Word Attributions. *Findings of the Association for Computational Linguistics: EMNLP 2023*, 12437–12450. https://doi.org/10.18653/v1/2023.findings-emnlp.830

Jurafsky, D. & Martin, J. (2025). *Speech and Language Processing: An Introduction to Natural Language Processing: Computational Linguistics, and Speech Recognition, with Language Model*.

Kitchenham, B. & Charters, S. (2007). *Guidelines for performing systematic literature reviews in software engineering* (Technical report, EBSE Technical Report EBSE-2007-01). Keele University and University of Duraham. https://docs.edtechhub.org/lib/EDAG684W

Lafferty, J., McCallum, A. & Pereira, F. (2001). Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data. *International Conference on Machine Learning*. https://www.semanticscholar.org/paper/Conditional-Random-Fields%3A-Probabilistic-Models-for-Lafferty-McCallum/f4ba954b0412773d047dc41231c733de0c1f4926

Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K. & Dyer, C. (2016). Neural Architectures for Named Entity Recognition. *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 260–270. https://doi.org/10.18653/v1/N16-1030

Lan, Z., Chen, M., Goodman, S., Gimpel, K., Sharma, P. & Soricut, R. (2020). ALBERT: A Lite BERT for Self-supervised Learning of Language Representations. In *Eighth International Conference on Learning Representations*. https://iclr.cc/virtual_2020/poster_H1eA7AEtvS.html

Lecun, Y., Bottou, L., Bengio, Y [Y.] & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, *86*(11), 2278–2324. https://doi.org/10.1109/5.726791

Lee, J., Yoon, W., Kim, S [Sungdong], Kim, D., Kim, S [Sunkyu], So, C. H. & Kang, J. (2020). BioBERT: a pre-trained biomedical language representation model for biomedical text mining. *Bioinformatics*, *36*(4), 1234–1240. https://doi.org/10.1093/bioinformatics/btz682

Li, D., Zhang, Y [Yizhe], Peng, H., Chen, L., Brockett, C., Sun, M.-T. & Dolan, B. (2021). Contextualized Perturbation for Textual Adversarial Attack. *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 5053–5069. https://doi.org/10.18653/v1/2021.naacl-main.400

Li, J [Jing], Sun, A., Han, J [Jianglei] & Li, C. (2022). A Survey on Deep Learning for Named Entity Recognition. *IEEE Transactions on Knowledge and Data Engineering*, *34*(1), 50–70. https://doi.org/10.1109/TKDE.2020.2981314

Li, L., Ma, R., Guo, Q., Xue, X. & Qiu, X. (2020). BERT-ATTACK: Adversarial Attack Against BERT Using BERT. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 6193–6202. https://doi.org/10.18653/v1/2020.emnlp-main.500

Liang, X., Mao, R., Wu, L., Li, J [Juntao], Zhang, M. & Li, Q. (2024). Enhancing Low-Resource NLP by Consistency Training With Data and Model Perturbations. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, *32*, 189–199. https://doi.org/10.1109/TASLP.2023.3325970

Liang, Bin and Li, Hongcheng, Su, M., Bian, P., Li, X [Xirong] & Shi, W. (2018). Deep text classification can be fooled. In AAAI Press (Hrsg.), *IJCAI'18: Proceedings of the 27th International Joint Conference on Artificial Intelligence* (S. 4208–4215).

Lin, B. Y., Gao, W., Yan, J., Moreno, R. & Ren, X. (2021). *RockNER: A Simple Method to Create Adversarial Examples for Evaluating the Robustness of Named Entity Recognition Models*. https://arxiv.org/pdf/2109.05620

Liu, Y [Yinhan], Ott, M., Goyal, N., Du Jingfei, Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L. & Stoyanov, V. (2019). *RoBERTa: A Robustly Optimized BERT Pretraining Approach*. https://arxiv.org/pdf/1907.11692

Lothritz, C., Ezzini, S., Purschke, C., Bissyandé, T., Klein, J., Olariu, I., Boytsov, A., Lefebvre, C. & Goujon, A. (2023). Comparing Pre-Training Schemes for Luxembourgish BERT Models. *Proceedings of the 19th Conference on Natural Language Processing (KONVENS 2023)*, 17–27. https://aclanthology.org/2023.konvens-main.2/

Ma, E. (2019). *NLPAug - NLP Augmentation Framework*. https://github.com/makcedward/nlpaug

Ma, Z [Zhiyuan], Du, J. & Zhou, S. (2023). Noise-Robust Training with Dynamic Loss and Contrastive Learning for Distantly-Supervised Named Entity Recognition. *Findings of the Association for Computational Linguistics: ACL 2023*, 10119–10128. https://doi.org/10.18653/v1/2023.findings-acl.643

Madry, A., Makelov, A., Schmidt, L., Tsipras, D. & Vladu, A. (2017, 19. Juni). *Towards Deep Learning Models Resistant to Adversarial Attacks*. https://arxiv.org/pdf/1706.06083

Malykh, V. (2019). Robust to Noise Models in Natural Language Processing Tasks. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics: Student Research Workshop*, 10–16. https://doi.org/10.18653/v1/P19-2002

Malykh, V. & Lyalin, V. (2018). Named Entity Recognition in Noisy Domains. In *2018 International Conference on Artificial Intelligence Applications and Innovations (IC-AIAI)* (S. 60–65). IEEE. https://doi.org/10.1109/IC-AIAI.2018.8674438

Manning, C. D. (2022). Human Language Understanding & Reasoning. *Daedalus*, *151*(2), 127–138. https://doi.org/10.1162/daed_a_01905

Mayhew, S., Chaturvedi, S., Tsai, C.-T. & Roth, D. (2019). *Named Entity Recognition with Partially Annotated Training Data*. https://arxiv.org/pdf/1909.09270

McCallum, A., Freitag, D. & Pereira, F. C. (2000). Maximum Entropy Markov Models for Information Extraction and Segmentation. *International Conference on Machine Learning*, 91–598.

Meng, Y., Zhang, Y [Yunyi], Huang, J., Wang, X [Xuan], Zhang, Y [Yu], Ji, H. & Han, J [Jiawei]. (2021). *Distantly-Supervised Named Entity Recognition with Noise-Robust Learning and Language Model Augmented Self-Training*. https://arxiv.org/pdf/2109.05003

Merdjanovska, E., Aynetdinov, A. & Akbik, A. (2024). NoiseBench: Benchmarking the Impact of Real Label Noise on Named Entity Recognition. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 18182–18198. https://doi.org/10.18653/v1/2024.emnlp-main.1011

Mikolov, T., Chen, K., Corrado, G. & Dean, J. (2013). *Efficient Estimation of Word Representations in Vector Space*. https://arxiv.org/pdf/1301.3781

Miller, G. A. (1995). WordNet: a lexical database for English. *Association for Computing Machinery*, *38*(11), 39–41. https://doi.org/10.1145/219717.219748

Moradi, M., Blagec, K. & Samwald, M. (2021). *Deep learning models are not robust against noise in clinical text*. https://arxiv.org/pdf/2108.12242

Moradi, M. & Samwald, M. (2021). Evaluating the Robustness of Neural Language Models to Input Perturbations. *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 1558–1570. https://doi.org/10.18653/v1/2021.emnlp-main.117

Morris, J., Lifland, E., Yoo, J. Y., Grigsby, J., Jin, D. & Qi, Y. (2020). TextAttack: A Framework for Adversarial Attacks, Data Augmentation, and Adversarial Training in NLP. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 119–126. https://doi.org/10.18653/v1/2020.emnlp-demos.16

Nadeau, D. & Sekine, S. (2009). A survey of named entity recognition and classification. *Named Entities*, 3–28. https://doi.org/10.1075/bct.19.03nad

Nakayama, H. (2018). *seqeval: A Python framework for sequence labeling evaluation*. https://github.com/chakki-works/seqeval

Namysl, M., Behnke, S. & Köhler, J. (2020). *NAT: Noise-Aware Training for Robust Neural Sequence Labeling*. https://arxiv.org/pdf/2005.07162

Náplava, J., Popel, M., Straka, M. & Straková, J. (2021). Understanding Model Robustness to User-generated Noisy Texts. *Proceedings of the Seventh Workshop on Noisy User-generated Text (W-NUT 2021)*, 340–350. https://doi.org/10.18653/v1/2021.wnut-1.38

Nguyen, M. & Chen, N. (2023). FiRo: Finite-context Indexing of Restricted Output Space for NLP Models Facing Noisy Input. *Proceedings of the 13th International Joint Conference on Natural Language Processing and the 3rd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, 834–845. https://doi.org/10.18653/v1/2023.ijcnlp-main.54

Pennington, J., Socher, R. & Manning, C. (2014). Glove: Global Vectors for Word Representation. *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 1532–1543. https://doi.org/10.3115/v1/D14-1162

Qiang, Y., Nandi, S., Mehrabi, N., Ver Steeg, G., Kumar, A [Anoop], Rumshisky, A. & Galstyan, A. (2024). *Prompt Perturbation Consistency Learning for Robust Language Models*. https://arxiv.org/pdf/2402.15833

Qiao, H., Zhu, Y., San, M., Chen, Z., Zhao, S., Chen, Y [Yan], Li, Z [Zhangyan] & Shi, S [Shenghui] (2024). A Named Entity Recognition Method for Fields Including Electrical Power Based on Data Enhancement. In *2024 2nd International Conference on Artificial Intelligence and Power Engineering (AIPE)* (S. 11–16). IEEE. https://doi.org/10.1109/AIPE63225.2024.00011

Ramshaw, L. A. & Marcus, M. P. (1999). Text Chunking Using Transformation-Based Learning. In *Natural Language Processing Using Very Large Corpora* (S. 157–176). Springer, Dordrecht. https://doi.org/10.1007/978-94-017-2390-9_10

Ribeiro, M. T., Wu, T [Tongshuang], Guestrin, C. & Singh, S. (2020). Beyond Accuracy: Behavioral Testing of NLP Models with CheckList. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 4902–4912. https://doi.org/10.18653/v1/2020.acl-main.442

Rogers, A., Kovaleva, O. & Rumshisky, A. (2020). A Primer in BERTology: What We Know About How BERT Works. *Transactions of the Association for Computational Linguistics*, *8*, 842–866. https://doi.org/10.1162/tacl_a_00349

Sajun, A. R., Zualkernan, I. A. & Sankalpa, D. (2024). A Historical Survey of Advances in Transformer Architectures. *Applied Sciences*. https://www.semanticscholar.org/paper/A-Historical-Survey-of-Advances-in-Transformer-Sajun-Zualkernan/0dcbf11176db2a55d43b19c1765f1759e13f368b

Sanh, V., Debut, L., Chaumond, J. & Wolf, T. (2019). *DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter*. https://arxiv.org/pdf/1910.01108

Shi, S [Shenghui], Li, Z [Zhangyan], Yin, L., Chai, Z., Fan, K., Jiang, D., Zheng, L. & Huang, D [Dongqi] (2024). Research and Data Analysis on Relationship Extraction Methods Based on Multi-Domain Texts. In *2024 9th International Conference on Big Data Analytics (ICBDA)* (S. 197–202). IEEE. https://doi.org/10.1109/ICBDA61153.2024.10607254

Si, S., Cai, Z., Zeng, S., Feng, G., Lin, J. & Chang, B. (2023). *SANTA: Separate Strategies for Inaccurate and Incomplete Annotation Noise in Distantly-Supervised Named Entity Recognition*. https://arxiv.org/pdf/2305.04076

Simoncini, W. & Spanakis, G. (2021). SeqAttack: On Adversarial Attacks for Named Entity Recognition. In H. Adel & S. Shi (Hrsg.), *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (S. 308–318). Association for Computational Linguistics. https://doi.org/10.18653/v1/2021.emnlp-demo.35

Sohn, H. & Park, B. (2022). Robust and Informative Text Augmentation (RITA) via Constrained Worst-Case Transformations for Low-Resource Named Entity Recognition. In A. Zhang & H. Rangwala (Hrsg.), *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (S. 1616–1624). ACM. https://doi.org/10.1145/3534678.3539349

Srinivasan, A. & Vajjala, S. (2023). *A Multilingual Evaluation of NER Robustness to Adversarial Inputs*. https://arxiv.org/pdf/2305.18933

Szymański, P., Augustyniak, L., Morzy, M., Szymczak, A., Surdyk, K. & Żelasko, P. (2023). Why Aren't We NER Yet? Artifacts of ASR Errors in Named Entity Recognition in

Spontaneous Speech Transcripts. *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 1746–1761. https://doi.org/10.18653/v1/2023.acl-long.98

Takahashi, K., Yamamoto, K., Kuchiba, A. & Koyama, T. (2022). Confidence interval for micro-averaged F1 and macro-averaged F1 scores. *Applied Intelligence*, *52*(5), 4961–4972. https://doi.org/10.1007/s10489-021-02635-5

Tang, X., Xia, D., Li, Y., Xu, T. & Xiong, N. N. (2024). A Survey of Low-Resource Named Entity Recognition. In (S. 246–260). Springer, Singapore. https://doi.org/10.1007/978-981-99-7161-9_19

Tian, J., Zhou, K., Wang, M., Zhang, Y [Yu], Yao, B., Liu, X [Xiaohu] & Guo, C. (2023). UseClean: learning from complex noisy labels in named entity recognition. *Proceedings of the 2023 CLASP Conference on Learning with Small Data (LSD)*, 120–130. https://aclanthology.org/2023.clasp-1.14/

Tjong Kim Sang, E. & Meulder, F. de (2003). Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition. *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003*, 142–147. https://aclanthology.org/W03-0419/

Torralba, A. & Efros, A. A. (2011). Unbiased look at dataset bias. In *CVPR 2011* (S. 1521–1528). IEEE. https://doi.org/10.1109/CVPR.2011.5995347

Tsai, R. T.-H., Wu, S.-H., Chou, W.-C., Lin, Y.-C., He, D., Hsiang, J., Sung, T.-Y. & Hsu, W.-L. (2006). Various criteria in the evaluation of biomedical named entity recognition. *BMC Bioinformatics*, *7*(1), 92. https://doi.org/10.1186/1471-2105-7-92

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł. & Polosukhin, I. (2017). Attention is All you Need. *Advances in Neural Information Processing Systems*, *30*.

vom Brocke, J., Simons, A., Riemer, K., Niehaves, B., Plattfaut, R. & Cleven, A. (2015). Standing on the Shoulders of Giants: Challenges and Recommendations of Literature Search in Information Systems Research. *Communications of the Association for Information Systems*, *37*(1). https://doi.org/10.17705/1CAIS.03709

Wacholder, N., Ravin, Y. & Choi, M. (1997). Disambiguation of proper names in text. *Fifth Conference on Applied Natural Language Processing*, 202–208. https://doi.org/10.3115/974557.974587

Wang, B., Xu, C [Chejian], Wang, S., Gan, Z., Cheng, Y., Gao, J [Jianfeng], Awadallah, A. & Li, B. (2021). Adversarial GLUE: A Multi-Task Benchmark for Robustness Evaluation

of Language Models. *ArXiv*. https://www.semanticscholar.org/paper/Adversarial-GLUE%3A-A-Multi-Task-Benchmark-for-of-Wang-Xu/8436897e713c2242d6291df9a6a33c1544d4dd39

Wang, H [Hongtao] & Li, A. (2024). Are Deep Neural Networks Robust to Named Entities? An Adversarial Attack and Defense Perspective. In *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (S. 12556–12560). IEEE. https://doi.org/10.1109/ICASSP48485.2024.10448165

Wang, R. Y. & Strong, D. M. (1996). Beyond Accuracy: What Data Quality Means to Data Consumers. *Journal of Management Information Systems*, *12*(4), 5–33. https://doi.org/10.1080/07421222.1996.11518099

Wang, R. & Henao, R. (2021). Unsupervised Paraphrasing Consistency Training for Low Resource Named Entity Recognition. *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 5303–5308. https://doi.org/10.18653/v1/2021.emnlp-main.430

Wang, X [Xuezhi], Wang, H [Haohan] & Yang, D. (2022). Measure and Improve Robustness in NLP Models: A Survey. *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, 4569–4586. https://doi.org/10.18653/v1/2022.naacl-main.339

Wang, Y., Lyu, L. & Anand, A. (2022). BERT Rankers are Brittle. In F. Crestani, G. Pasi & E. Gaussier (Hrsg.), *Proceedings of the 2022 ACM SIGIR International Conference on Theory of Information Retrieval* (S. 115–120). ACM. https://doi.org/10.1145/3539813.3545122

Wei, J. & Zou, K. (2019). EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 6381–6387. https://doi.org/10.18653/v1/D19-1670

Wieting, J., Mallinson, J. & Gimpel, K. (2017). Learning Paraphrastic Sentence Embeddings from Back-Translated Bitext. *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, 274–285. https://doi.org/10.18653/v1/D17-1026

Wilde, T. & Hess, T. (2007). Forschungsmethoden der Wirtschaftsinformatik. *WIRTSCHAFTSINFORMATIK*, *49*(4), 280–287. https://doi.org/10.1007/s11576-007-0064-z

Wolf, T., Debut, L., Sanh, V., Chaumond, J., Delangue, C., Moi, A., Cistac, P., Rault, T., Louf, R., Funtowicz, M., Davison, J., Shleifer, S., Platen, P. von, Ma, C., Jernite, Y., Plu, J., Xu, C [Canwen], Le Scao, T., Gugger, S., . . . Rush, A. (2020). Transformers:

State-of-the-Art Natural Language Processing. In Q. Liu & D. Schlangen (Hrsg.), *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations* (S. 38–45). Association for Computational Linguistics. https://doi.org/10.18653/v1/2020.emnlp-demos.6

Wu, J., Zhang, R [Richong], Mao, Y. & Huai, J. (2022). Dealing With Hierarchical Types and Label Noise in Fine-Grained Entity Typing. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, *30*, 1305–1318. https://doi.org/10.1109/TASLP.2022.3155281

Wu, S [Sihao], Wu, X., Xie, R. & Zhan, W. (2024). Chinese NER Based on Adversarial Training and Interactive Attention. In *Proceedings of the 2024 16th International Conference on Machine Learning and Computing* (S. 557–561). ACM. https://doi.org/10.1145/3651671.3651672

Wu, T [Tingting], Ding, X., Tang, M., Zhang, H., Qin, B. & Liu, T. (2022). STGN: an Implicit Regularization Method for Learning with Noisy Labels in Natural Language Processing. *Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing*, 7587–7598. https://doi.org/10.18653/v1/2022.emnlp-main.515

Wu, Z. & Palmer, M. (1994). Verbs semantics and lexical selection. In J. Pustejovsky (Hrsg.), *Proceedings of the 32nd annual meeting on Association for Computational Linguistics* - (S. 133–138). Association for Computational Linguistics. https://doi.org/10.3115/981732.981751

Yadav, V. & Bethard, S. (2018). A Survey on Recent Advances in Named Entity Recognition from Deep Learning models. *Proceedings of the 27th International Conference on Computational Linguistics*, 2145–2158. https://aclanthology.org/C18-1182/

Yan, J., Xiao, Y., Mukherjee, S., Lin, B. Y., Jia, R. & Ren, X. (2021). *On the Robustness of Reading Comprehension Models to Entity Renaming*. https://arxiv.org/pdf/2110.08555

Yang, Y [Yifei], Wu, H. & Zhao, H. (2023). *Attack Named Entity Recognition by Entity Boundary Interference*. https://arxiv.org/pdf/2305.05253

Yang, Z [Zhilin], Dai, Z., Yang, Y [Yiming], Carbonell, J., Salakhutdinov, R. & Le, Q. V. (2019). XLNet: Generalized Autoregressive Pretraining for Language Understanding. *Neural Information Processing Systems*. https://www.semanticscholar.org/paper/XLNet%3A-Generalized-Autoregressive-Pretraining-for-Yang-Dai/e0c6abdbdecf04ffac65c440da77fb9d66bb474c

Ying, Z., Zhang, J., Xie, R., Wen, G., Xiao, F., Liu, X [Xueyang] & Zhang, S. (2022). 3Rs: Data Augmentation Techniques Using Document Contexts For Low-Resource Chinese Named Entity Recognition. In *2022 International Joint Conference on Neural Networks (IJCNN)* (S. 1–8). IEEE. https://doi.org/10.1109/IJCNN55064.2022.9892341

Yu, Y., Yang, Z [Zhengdong], Cheng, F. & Chu, C. (2025). Semantic-Retention Attack for Continual Named Entity Recognition. *IEEE Transactions on Audio, Speech and Language Processing*, *33*, 2591–2605. https://doi.org/10.1109/TASLPRO.2025.3578765

Yuan, X., He, P [Pan], Zhu, Q. & Li, X [Xiaolin] (2019). Adversarial Examples: Attacks and Defenses for Deep Learning. *IEEE transactions on neural networks and learning systems*, *30*(9), 2805–2824. https://doi.org/10.1109/TNNLS.2018.2886017

Zeng, G., Qi, F., Zhou, Q., Zhang, T., Ma, Z [Zixian], Hou, B., Zang, Y., Liu, Z. & Sun, M. (2020). *OpenAttack: An Open-source Textual Adversarial Attack Toolkit*. https://arxiv.org/pdf/2009.09191 https://doi.org/10.18653/v1/2021.acl-demo.43

Zhang, D [Duzhen], Li, H., Cong, W., Xu, R., Dong, J. & Chen, X. (2023). Task Relation Distillation and Prototypical Pseudo Label for Incremental Named Entity Recognition. In I. Frommholz, F. Hopfgartner, M. Lee, M. Oakes, M. Lalmas, M. Zhang & R. Santos (Hrsg.), *Proceedings of the 32nd ACM International Conference on Information and Knowledge Management* (S. 3319–3329). ACM. https://doi.org/10.1145/3583780.3615075

Zhu, D., Hedderich, M. A., Zhai, F., Adelani, D. I. & Klakow, D. (2022). *Is BERT Robust to Label Noise? A Study on Learning with Noisy Labels in Text Classification*. https://arxiv.org/pdf/2204.09371

Zhu, J., Shi, A., Li, Z [Zixuan], Bai, L., Jin, X [Xiaolong], Guo, J. & Cheng, X. (2025). *Towards Robust Universal Information Extraction: Benchmark, Evaluation, and Solution*. https://arxiv.org/pdf/2503.03201

Zhu, Z., Wang, L., Zhao, P., Du, C., Zhang, W., Dong, H., Qiao, B., Lin, Q., Rajmohan, S. & Zhang, D [Dongmei] (2023). Robust Positive-Unlabeled Learning via Noise Negative Sample Self-correction. In A. Singh, Y. Sun, L. Akoglu, D. Gunopulos, X. Yan, R. Kumar, F. Ozcan & J. Ye (Hrsg.), *Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining* (S. 3663–3673). ACM. https://doi.org/10.1145/3580305.3599491

Anhang

Anhang 1: Identifizierte Paper Systematic Literature Review.....97

Anhang 2: Auswertungstabelle Qualitätsminderungen Testdatensatz 121

Anhang 3: Auswertungstabelle Qualitätsminderungen Trainings- und Testdatensatz.....122

Anhang 4: Auswertungstabelle Qualitätsminderungen Trainingsdatensatz.....123

Anhang 1: Identifizierte Paper Systematic Literature Review

Titel	Link	Re-le-vant	Kein NLP/Noise Bezug	Keine Trans-former	Un-klare Noise	Fal-scher Zeit-raum	Zu we-nig Zita-tionen	Duppli-kat
The Effects of Data Quality on Named Entity Recognition	https://aclanthology.org/2024.wnut-1.8/	x						
Dual Adversarial Neural Transfer for Low-Resource Named Entity Recognition	https://aclanthology.org/P19-1336/	-		x				
Why Aren't We NER Yet? Artifacts of ASR Errors in Named Entity Recognition in Spontaneous Speech Transcripts	https://aclanthology.org/2023.acl-long.98/	x						
SeqAttack: On Adversarial Attacks for Named Entity Recognition	https://aclanthology.org/2021.emnlp-demo.35/	x						
Self-Cleaning: Improving a Named Entity Recognizer Trained on Noisy Data with a Few Clean Instances	https://aclanthology.org/2024.findings-naacl.14/	x						
Adversarial Transfer Learning for Chinese Named Entity Recognition with Self-Attention Mechanism	https://aclanthology.org/D18-1017/	-	x					
UseClean: learning from complex noisy labels in named entity recognition	https://aclanthology.org/2023.clasp-1.14/	x						
Named Entity Recognition via Noise Aware Training Mechanism with Data Filter	https://aclanthology.org/2021.findings-acl.423/	x						
A Robust Risk Minimization based Named Entity Recognition System	https://aclanthology.org/W03-0434/	-	x					
Improving Mention Detection Robustness to Noisy Input	https://aclanthology.org/D10-1033/	-		x				
TextAttack: A Framework for Adversarial Attacks, Data Augmentation, and Adversarial Training in NLP	https://aclanthology.org/2020.emnlp-demos.16/	x						
The State of Relation Extraction Data Quality: Is Bigger Always Better?	https://aclanthology.org/2024.findings-acl.470/	x						
Extract-Select: A Span Selection Framework for Nested Named Entity Recognition with Generative Adversarial Training	https://aclanthology.org/2022.findings-acl.9/	-			x			
Alleviating Digitization Errors in Named Entity Recognition for Historical Documents	https://aclanthology.org/2020.conll-1.35/	x						
Resilience of Named Entity Recognition Models under Adversarial Attack	https://aclanthology.org/2022.dadc-1.1/	x						
HardEval: Focusing on Challenging Tokens to Assess Robustness of NER	https://aclanthology.org/2020.lrec-1.211/	x						

Robust Named Entity Extraction from Large Spoken Archives	https://aclanthology.org/H05-1062/	-			x			
Curation of Benchmark Templates for Measuring Gender Bias in Named Entity Recognition Models	https://aclanthology.org/2024.lrec-main.378/	-					x	
Noise-Robust Training with Dynamic Loss and Contrastive Learning for Distantly-Supervised Named Entity Recognition	https://aclanthology.org/2023.findings-acl.643/	-			x			
Multi-Domain Named Entity Recognition with Genre-Aware and Agnostic Inference	https://aclanthology.org/2020.acl-main.750/	-	x					
Adversarial Robustness for Large Language NER models using Disentanglement and Word Attributions	https://aclanthology.org/2023.findings-emnlp.830/	x						
Piggyback: Using Search Engines for Robust Cross-Domain Named Entity Recognition	https://aclanthology.org/P11-1097/	-				x		
Design Challenges and Misconceptions in Named Entity Recognition	https://aclanthology.org/W09-1119/	-				x		
TransAdv: A Translation-based Adversarial Learning Framework for Zero-Resource Cross-Lingual Named Entity Recognition	https://aclanthology.org/2022.findings-emnlp.52/	-			x			
Towards Building More Robust NER datasets: An Empirical Study on NER Dataset Bias from a Dataset Difficulty View	https://aclanthology.org/2023.emnlp-main.281/	-	x				x	
Named Entity Recognition through Classifier Combination	https://aclanthology.org/W03-0425/	-				x		
Detecting intersectionality in NER models: A data-driven approach	https://aclanthology.org/2023.latechclfl-1.13/	-	x		x			
Enhance Robustness of Sequence Labelling with Masked Adversarial Training	https://aclanthology.org/2020.findings-emnlp.28/	-	x					
Arabic Named Entity Recognition: Using Features Extracted from Noisy Data	https://aclanthology.org/P10-2052/	-				x		
The Impact of De-identification on Downstream Named Entity Recognition in Clinical Text	https://aclanthology.org/2020.louhi-1.1/	-	x					
Enhancing Relation Extraction via Adversarial Multi-task Learning	https://aclanthology.org/2022.lrec-1.666/	-			x			
Creating Ontology-annotated Corpora from Wikipedia for Medical Named-entity Recognition	https://aclanthology.org/2024.bionlp-1.47/	-	x					
SeqVAT: Virtual Adversarial Training for Semi-Supervised Sequence Labeling	https://aclanthology.org/2020.acl-main.777/	-		x				
An Open Corpus for Named Entity Recognition in Historic Newspapers	https://aclanthology.org/L16-1689/	-	x					
Domain Adaption of Named Entity Recognition to Support Credit Risk Assessment	https://aclanthology.org/U15-1010/	-	x					
SKD-NER: Continual Named Entity Recognition via Span-based Knowledge Distillation with Reinforcement Learning	https://aclanthology.org/2023.emnlp-main.413/	-	x					

Dual-Task Learning for AI-Generated Medical Text Detection and Named Entity Recognition	https://aclanthology.org/2024.icnlsp-1.18/	-					x	
SmartSpanNER: Making SpanNER Robust in Low Resource Scenarios	https://aclanthology.org/2023.findings-emnlp.535/	-					x	
Named Entity Recognition in Historic Legal Text: A Transformer and State Machine Ensemble Method	https://aclanthology.org/2021.nllp-1.18/	-			x			
UDAA: An Unsupervised Domain Adaptation Adversarial Learning Framework for Zero-Resource Cross-Domain Named Entity Recognition	https://aclanthology.org/2024.ccl-1.87/	-	x		x			
An evaluation of Named Entity Recognition tools for detecting person names in philosophical text	https://aclanthology.org/2025.nlp4dh-1.36/	-	x					
Enhancing Distantly Supervised Named Entity Recognition with Strong Label Guided Lottery Training	https://aclanthology.org/2024.lrec-main.524/	-			x			
Empirical Study on the Performance Stability of Named Entity Recognition Model across Domains	https://aclanthology.org/W06-1660/	-				x		
Exploiting Feature Hierarchy for Transfer Learning in Named Entity Recognition	https://aclanthology.org/P08-1029/	-				x		
Robust to Noise Models in Natural Language Processing Tasks	https://aclanthology.org/P19-2002/	x						
Few-Shot Class-Incremental Learning for Named Entity Recognition	https://aclanthology.org/2022.acl-long.43/	-	x					
When Generative Adversarial Networks Meet Sequence Labeling Challenges	https://aclanthology.org/2024.emnlp-main.593/	-	x					
Building A German Clinical Named Entity Recognition System without In-domain Training Data	https://aclanthology.org/2024.clinicalnlp-1.7/	-	x					
RockNER: A Simple Method to Create Adversarial Examples for Evaluating the Robustness of Named Entity Recognition Models	https://aclanthology.org/2021.emnlp-main.302/	x						x
NoiseBench: Benchmarking the Impact of Real Label Noise on Named Entity Recognition	https://aclanthology.org/2024.emnlp-main.1011	x						x
EconBERTa: Towards Robust Extraction of Named Entities in Economics	https://aclanthology.org/2023.findings-emnlp.774/	-			x			
Bangor University at WojoodNER 2024: Advancing Arabic Named Entity Recognition with CAMeLBERT-Mix	https://aclanthology.org/2024.arabicnlp-1.105/	-	x					
[DOPPELT] Attack Named Entity Recognition by Entity Boundary Interference	https://aclanthology.org/2024.lrec-main.153/	x						x
Evaluating the Robustness of Neural Language Models to Input Perturbations	https://aclanthology.org/2021.emnlp-main.117/	x						

Instance-adaptive training with noise-robust losses against noisy labels	https://aclanthology.org/2021.emnlp-main.457/	x						
BERT-ATTACK: Adversarial Attack Against BERT Using BERT	https://aclanthology.org/2020.emnlp-main.500/	x						
Hybrid Knowledge Engineering Leveraging a Robust ML Framework to Produce an Assassination Dataset	https://aclanthology.org/2022.case-1.15/	-	x					
Robust Backed-off Estimation of Out-of-Vocabulary Embeddings	https://aclanthology.org/2020.findings-emnlp.434/	-	x					
A Meta-dataset of German Medical Corpora: Harmonization of Annotations and Cross-corpus NER Evaluation	https://aclanthology.org/2023.clinicalnlp-1.23/	-					x	
STGN: an Implicit Regularization Method for Learning with Noisy Labels in Natural Language Processing	https://aclanthology.org/2022.emnlp-main.515/	x						
Detecting intersectionality in NER models: A data-driven approach	https://aclanthology.org/2023.latechclfl-1.13/	-	x					
Robust MT Evaluation with Sentence-level Multilingual Augmentation	https://aclanthology.org/2022.wmt-1.43/	-	x					
BAE: BERT-based Adversarial Examples for Text Classification	https://aclanthology.org/2020.emnlp-main.498/	x						
Bridging the Gap: Efficient Cross-Lingual NER in Low-Resource Financial Domain	https://aclanthology.org/2025.finnlp-1.5/	-					x	
Towards Robust Linguistic Analysis using OntoNotes	https://aclanthology.org/W13-3516/	-	x					
NormNet: Normalize Noun Phrases for More Robust NLP	https://aclanthology.org/2023.findings-acl.136/	-			x			
PCBERT: Parent and Child BERT for Chinese Few-shot NER	https://aclanthology.org/2022.coling-1.192/	-			x			
Contextualized Perturbation for Textual Adversarial Attack	https://aclanthology.org/2021.naacl-main.400/	x						
Focused training sets to reduce noise in NER feature models	https://aclanthology.org/N13-1042/	-			x			
Noise-robust Cross-modal Interactive Learning with Text2Image Mask for Multi-modal Neural Machine Translation	https://aclanthology.org/2022.coling-1.452/	-	x					
HBUT at #SMM4H 2024 Task2: Cross-lingual Few-shot Medical Entity Extraction using a Large Language Model	https://aclanthology.org/2024.smm4h-1.13/	-	x					
Addressing NER Annotation Noises with Uncertainty-Guided Tree-Structured CRFs	https://aclanthology.org/2023.emnlp-main.872/	-			x			
How GermaParl Evolves: Improving Data Quality by Reproducible Corpus Preparation and User Involvement	https://aclanthology.org/2022.parlaclarin-1.2/	-	x					

Dynamic Gazetteer Integration in Multilingual Models for Cross-Lingual and Cross-Domain Named Entity Recognition	https://aclanthology.org/2022.naacl-main.200/	-	x					
CrowNER at ROCLING 2023 MultiNER-Health Task: Enhancing NER Task with GPT Paraphrase Augmentation on Sparsely Labeled Data	https://aclanthology.org/2023.rocling-1.43/	-					x	
HacRED: A Large-Scale Relation Extraction Dataset Toward Hard Cases in Practical Applications	https://aclanthology.org/2021.findings-acl.249/	-			x			
Entity Embellishment Mitigation in LLMs Output with Noisy Synthetic Dataset for Alignment	https://aclanthology.org/2024.unlp-1.15/	-	x					
Turning silver into gold: error-focused corpus reannotation with active learning	https://aclanthology.org/R19-1088/	-			x			
Comparing Pre-Training Schemes for Luxembourgish BERT Models	https://aclanthology.org/2023.konvens-main.2/	x						
FairFlow: Mitigating Dataset Biases through Undecided Learning for Natural Language Understanding	https://aclanthology.org/2024.emnlp-main.1225/	-	x					
AESOP: Paraphrase Generation with Adaptive Syntactic Control	https://aclanthology.org/2021.emnlp-main.420	-	x					
Comparing Annotated Datasets for Named Entity Recognition in English Literature	https://aclanthology.org/2022.lrec-1.404/	-	x					
Enhancing Multimodal Named Entity Recognition through Adaptive Mixup Image Augmentation	https://aclanthology.org/2025.coling-main.122/	-	x					
Leveraging Information Redundancy of Real-World Data through Distant Supervision	https://aclanthology.org/2024.lrec-main.905/	-					x	
Investigating Loss Functions and Optimization Methods for Discriminative Learning of Label Sequences	https://aclanthology.org/W03-1019/	-			x			
Embracing Non-Traditional Linguistic Resources for Low-resource Language Name Tagging	https://aclanthology.org/I17-1037/	-	x					
AFET: Automatic Fine-Grained Entity Typing by Hierarchical Partial-Label	https://aclanthology.org/D16-1144.pdf	-			x			
SpecNFS: A Challenge Dataset Towards Extracting Formal Models from Natural Language Specifications	https://aclanthology.org/2022.lrec-1.233/	-	x					
FiRo: Finite-context Indexing of Restricted Output Space for NLP Models Facing Noisy Input	https://aclanthology.org/2023.ijcnlp-main.54/	x						
Clinical Text Anonymization, its Influence on Downstream NLP Tasks and the Risk of Re-Identification	https://aclanthology.org/2023.eacl-srw.11/	-	x					
Handling Missing Entities in Zero-Shot Named Entity Recognition: Integrated Recall and Retrieval Augmentation	https://aclanthology.org/2025.naacl-long.540/	-					x	

A Joint Framework for Ancient Chinese WS and POS Tagging Based on Adversarial Ensemble Learning	https://aclanthology.org/2022.lt4hala-1.27/	-					x	
Towards a Better Understanding of Noise in Natural Language Processing	https://aclanthology.org/2021.ranlp-1.7/	x						
Unsupervised Paraphrasing Consistency Training for Low Resource Named Entity Recognition	https://aclanthology.org/2021.emnlp-main.430/	-						
Are Text Classifiers Xenophobic? A Country-Oriented Bias Detection Method with Least Confounding Variables	https://aclanthology.org/2024.lrec-main.134/	-	x					
Legal Named Entity Recognition with Multi-Task Domain Adaptation	https://aclanthology.org/2022.nllp-1.29/	-	x					
TextFusion: Privacy-Preserving Pre-trained Model Inference via Token Fusion	https://aclanthology.org/2022.emnlp-main.572/	-	x					
GENDEX: Generative Data Augmentation Strategy Leveraging External Data for Abstractive Dialogue Summarization	https://aclanthology.org/2024.findings-acl.188/	-			x			
Infrrd.ai at SemEval-2022 Task 11: A system for named entity recognition using data augmentation, transformer-based sequence labeling model, and EnsembleCRF	https://aclanthology.org/2022.semeval-1.206/	-	x					
HotFlip: White-Box Adversarial Examples for Text Classification	https://aclanthology.org/P18-2006/	x						
NoiseBench: Benchmarking the Impact of Real Label Noise on Named Entity Recognition	https://arxiv.org/abs/2405.07609	x						
The Impact of Data Corruption on Named Entity Recognition for Low-resourced Languages	https://arxiv.org/abs/2208.04568	x						
Distantly-Supervised Named Entity Recognition with Noise-Robust Learning and Language Model Augmented Self-Training	https://arxiv.org/abs/2109.05003	x						
Distant Supervision and Noisy Label Learning for Low Resource Named Entity Recognition: A Study on Hausa and Yorùbá	https://arxiv.org/abs/2003.08370	-			x			
Improving a Named Entity Recognizer Trained on Noisy Data with a Few Clean Instances	https://arxiv.org/abs/2310.16790	x						
Learning Robust Named Entity Recognizers From Noisy Data With Retrieval Augmentation	https://arxiv.org/abs/2407.18562	x						
OpenAttack: An Open-source Textual Adversarial Attack Toolkit	https://arxiv.org/abs/2009.09191	x						
RockNER: A Simple Method to Create Adversarial Examples for Evaluating the Robustness of Named Entity Recognition Models	https://arxiv.org/abs/2109.05620	x						
Robust Encodings: A Framework for Combating Adversarial Typos	https://arxiv.org/abs/2005.01229	-			x			

Robustness to Capitalization Errors in Named Entity Recognition	https://arxiv.org/abs/1911.05241	x						
Noisy-Labeled NER with Confidence Estimation	https://arxiv.org/abs/2104.04318	-	x					
CleanCoNLL: A Nearly Noise-Free Named Entity Recognition Dataset	https://arxiv.org/abs/2310.16225	-	x					
Named Entity Recognition with Small Strongly Labeled and Large Weakly Labeled Data	https://arxiv.org/abs/2106.08977	-			x			
NAT: Noise-Aware Training for Robust Neural Sequence Labeling	https://arxiv.org/abs/2005.07162	x						
NERetrieve: Dataset for Next Generation Named Entity Recognition and Retrieval	https://arxiv.org/abs/2310.14282	-		x				
Learning from Noisy Labels for Entity-Centric Information Extraction	https://arxiv.org/abs/2104.08656	-			x			
Robust Named Entity Recognition in Idiosyncratic Domains	https://arxiv.org/abs/1608.06757	-				x		
CrossWeigh: Training Named Entity Tagger from Imperfect Annotations	https://arxiv.org/abs/1909.01441	-			x			
Robust Lexical Features for Improved Neural Network Named-Entity Recognition	https://arxiv.org/abs/1806.03489	-	x					
Breaking BERT: Understanding its Vulnerabilities for Named Entity Recognition through Adversarial Attack	https://arxiv.org/abs/2109.11308	x						
Named Entity Recognition without Labelled Data: A Weak Supervision Approach	https://arxiv.org/abs/2004.14723	-	x		x			
Data Augmentation for Cross-Domain Named Entity Recognition	https://arxiv.org/abs/2109.01758	-	x					
ACLM: A Selective-Denoising based Generative Data Augmentation Approach for Low-Resource Complex NER	https://arxiv.org/abs/2306.00928	-			x			
Understanding Model Robustness to User-generated Noisy Texts	https://arxiv.org/abs/2110.07428	x						
AdvPicker: Effectively Leveraging Unlabeled Data via Adversarial Discriminator for Cross-Lingual NER	https://arxiv.org/abs/2106.02300	-	x					
Towards Robust Named Entity Recognition for Historic German	https://arxiv.org/abs/1906.07592	-	x					
Entity-Switched Datasets: An Approach to Auditing the In-Domain Robustness of Named Entity Recognition Models	https://arxiv.org/abs/2004.04123	-			x			
A Multilingual Evaluation of NER Robustness to Adversarial Inputs	https://arxiv.org/abs/2305.18933	x						
Improving Distantly-Supervised Named Entity Recognition with Self-Collaborative Denoising Learning	https://arxiv.org/abs/2110.04429	-			x			

SwellShark: A Generative Model for Biomedical Named Entity Recognition without Labeled Data	https://arxiv.org/abs/1704.06360	-		x				
Adversarial Learning with Contextual Embeddings for Zero-resource Cross-lingual Classification and NER	https://arxiv.org/abs/1909.00153	-			x			
NLNDE: Enhancing Neural Sequence Taggers with Attention and Noisy Channel for Robust Pharmacological Entity Detection	https://arxiv.org/abs/2007.01022	-	x					
Context-aware Adversarial Attack on Named Entity Recognition	https://arxiv.org/abs/2309.08999	x						
Robust Self-Augmentation for Named Entity Recognition with Meta Reweighting	https://arxiv.org/abs/2204.11406	-			x			
Deep learning models are not robust against noise in clinical text	https://arxiv.org/abs/2108.12242	x					x	
MELM: Data Augmentation with Masked Entity Language Modeling for Low-Resource NER	https://arxiv.org/abs/2108.13655	-	x					
Are Data Augmentation Methods in Named Entity Recognition Applicable for Uncertainty Estimation?	https://arxiv.org/abs/2407.02062	-			x			
Leveraging Expert Guided Adversarial Augmentation For Improving Generalization in Named Entity Recognition	https://arxiv.org/abs/2203.10693	-			x			
Improving Pseudo Labels with Global-Local Denoising Framework for Cross-lingual Named Entity Recognition	https://arxiv.org/abs/2406.01213	-	x					
Is BERT Robust to Label Noise? A Study on Learning with Noisy Labels in Text Classification	https://arxiv.org/abs/2204.09371	x						
Noise Robust Named Entity Understanding for Voice Assistants	https://arxiv.org/abs/2005.14408	-				x		
MultiCoNER: A Large-scale Multilingual dataset for Complex Named Entity Recognition	https://arxiv.org/abs/2208.14536	-	x					
Exploring Robustness of Multilingual LLMs on Real-World Noisy Data	https://arxiv.org/abs/2501.08322	x						
SCANNER: Knowledge-Enhanced Approach for Robust Multi-modal Named Entity Recognition of Unseen Entities	https://arxiv.org/abs/2404.01914	-		x	x			
Towards Robust Universal Information Extraction: Benchmark, Evaluation, and Solution	https://arxiv.org/abs/2503.03201	x						
Comprehensive Overview of Named Entity Recognition: Models, Domain-Specific Applications and Challenges	https://arxiv.org/abs/2309.14084	-	x					
Annotation Errors and NER: A Study with OntoNotes 5.0	https://arxiv.org/abs/2406.19172	x						

GPT-NER: Named Entity Recognition via Large Language Models	https://arxiv.org/abs/2304.10428	-		x				
On the Robustness of Reading Comprehension Models to Entity Renaming	https://arxiv.org/abs/2110.08555	x						
On Adversarial Examples for Biomedical NLP Tasks	https://arxiv.org/abs/2004.11157	x						
SeqScore: Addressing Barriers to Reproducible Named Entity Recognition Evaluation	https://arxiv.org/abs/2107.14154	-			x			
BanglaCoNER: Towards Robust Bangla Complex Named Entity Recognition	https://arxiv.org/abs/2303.09306	-					x	
What do we Really Know about State of the Art NER?	https://arxiv.org/abs/2205.00034	-	x					
Distantly-Supervised Joint Extraction with Noise-Robust Learning	https://arxiv.org/abs/2310.04994	-			x			
Attack Named Entity Recognition by Entity Boundary Interference	https://arxiv.org/abs/2305.05253	x						
Named Entity Recognition with Partially Annotated Training Data	https://arxiv.org/abs/1909.09270	x						
Handling Noisy Labels for Robustly Learning from Self-Training Data for Low-Resource Sequence Labeling	https://arxiv.org/abs/1903.12008	-	x					
H-COAL: Human Correction of AI-Generated Labels for Biomedical Named Entity Recognition	https://arxiv.org/abs/2311.11981	-					x	
E-NER: Evidential Deep Learning for Trustworthy Named Entity Recognition	https://arxiv.org/abs/2305.17854	-	x					
AutoTriggER: Label-Efficient and Robust Named Entity Recognition with Auxiliary Trigger Extraction	https://arxiv.org/abs/2109.04726	-					x	
De-biasing Distantly Supervised Named Entity Recognition via Causal Intervention	https://arxiv.org/abs/2106.09233	-	x					
MProto: Multi-Prototype Network with Denoised Optimal Transport for Distantly Supervised Named Entity Recognition	https://arxiv.org/abs/2310.08298	-	x					
Less than One-shot: Named Entity Recognition via Extremely Weak Supervision	https://arxiv.org/abs/2311.02861	-	x					
kNN-NER: Named Entity Recognition with Nearest Neighbor Search	https://arxiv.org/abs/2203.17103	-		x				
SANTA: Separate Strategies for Inaccurate and Incomplete Annotation Noise in Distantly-Supervised Named Entity Recognition	https://arxiv.org/abs/2305.04076	x						
FAME: Feature-Based Adversarial Meta-Embeddings for Robust Input Representations	https://arxiv.org/abs/2010.12305	-					x	
DynClean: Training Dynamics-based Label Cleaning for Distantly-Supervised Named Entity Recognition	https://arxiv.org/abs/2504.04616	-					x	

ConNER: Consistency Training for Cross-lingual Named Entity Recognition	https://arxiv.org/abs/2211.09394	-	x					
Robust Logistic Regression using Shift Parameters (Long Version)	https://arxiv.org/abs/1305.4987	-		x				
Noisy Text Data: Achilles' Heel of popular transformer based NLP models	https://arxiv.org/abs/2110.03353	x						
Named Entity Recognition Under Domain Shift via Metric Learning for Life Sciences	https://arxiv.org/abs/2401.10472	-	x				x	
NER-BERT: A Pre-trained Model for Low-Resource Entity Taggin	https://arxiv.org/abs/2112.00405	-	x					
Template-Based Named Entity Recognition Using BART	https://arxiv.org/abs/2106.01760	-	x					
ScispaCy: Fast and Robust Models for Biomedical Natural Language Processing	https://arxiv.org/abs/1902.07669	-	x					
Better Feature Integration for Named Entity Recognition	https://arxiv.org/abs/2104.05316	-	x					
Cross-Lingual Transfer Robustness to Lower-Resource Languages on Adversarial Datasets	https://arxiv.org/abs/2403.20056	-	x					
CoLaDa: A Collaborative Label Denoising Framework for Cross-lingual Named Entity Recognition	https://arxiv.org/abs/2305.14913	-			x			
Crowdsourcing Learning as Domain Adaptation: A Case Study on Named Entity Recognition	https://arxiv.org/abs/2105.14980	-	x					
Biomedical Language Models are Robust to Sub-optimal Tokenization	https://arxiv.org/abs/2306.17649	-	x					
FewTopNER: Integrating Few-Shot Learning with Topic Modeling and Named Entity Recognition in a Multilingual Framework	https://arxiv.org/abs/2502.02391	-	x				x	
Zero-Resource Cross-Domain Named Entity Recognition	https://arxiv.org/abs/2002.05923	-	x					
Adversarial Domain Adaptation for Machine Reading Comprehension	https://arxiv.org/abs/1908.09209	-				x		
Towards Robust and Generalizable Training: An Empirical Study of Noisy Slot Filling for Input Perturbations	https://arxiv.org/abs/2310.03518	-					x	
Looking Beyond Label Noise: Shifted Label Distribution Matters in Distantly Supervised Relation Extraction	https://arxiv.org/abs/1904.09331	-	x					
Local Additivity Based Data Augmentation for Semi-supervised NER	https://arxiv.org/abs/2010.01677	-	x					
Feature-Dependent Confusion Matrices for Low-Resource NER Labeling with Noisy Labels	https://arxiv.org/abs/1910.06061	-			x			
R2D2: Robust Data-to-Text with Replacement Detection	https://arxiv.org/abs/2205.12467	-	x					
DrBERT: A Robust Pre-trained Model in French for Biomedical and Clinical domains	https://arxiv.org/abs/2304.00958	-	x					

How Good is Your Wikipedia? Auditing Data Quality for Low-resource and Multilingual NLP	https://arxiv.org/abs/2411.05527	-			x			
A Survey on Data Quality Dimensions and Tools for Machine Learning	https://arxiv.org/abs/2406.19614	-		x	x			
Data Augmentation for Robust Character Detection in Fantasy Novels	https://arxiv.org/abs/2302.04555	-	x					
MagNet and "Efficient Defenses Against Adversarial Attacks" are Not Robust to Adversarial Examples	https://arxiv.org/abs/1711.08478	-		x				
TIARA: Multi-grained Retrieval for Robust Question Answering over Large Knowledge Bases	https://arxiv.org/abs/2210.12925	-	x					
Transfer Learning with Label Noise	https://arxiv.org/abs/1707.09724	-		x				
Learning From Crowdsourced Noisy Labels: A Signal Processing Perspective	https://arxiv.org/abs/2407.06902	-					x	
BERTifying the Hidden Markov Model for Multi-Source Weakly Supervised Named Entity Recognition	https://arxiv.org/abs/2105.12848	-	x					
Revisiting Semi-supervised Adversarial Robustness via Noise-aware Online Robust Distillation	https://arxiv.org/abs/2409.12946	-		x				
PerD: Perturbation Sensitivity-based Neural Trojan Detection Framework on NLP Applications	https://arxiv.org/abs/2208.04943	-	x		x			
Prompt Perturbation Consistency Learning for Robust Language Models	https://arxiv.org/abs/2402.15833	x						
Double Perturbation: On the Robustness of Robustness and Counterfactual Bias Evaluation	https://arxiv.org/abs/2104.05232	-	x					
ROSE-NER: Robust Semi-supervised Named Entity Recognition on Insufficient Labeled Data	https://dl.acm.org/doi/abs/10.1145/3502223.3502228	-			x			
Microblog-genre noise and impact on semantic annotation accuracy	https://dl.acm.org/doi/abs/10.1145/2481492.2481495	-				x		
Mining Software Entities in Scientific Literature: Document-level NER for an Extremely Imbalance and Large-scale Task	https://dl.acm.org/doi/abs/10.1145/3459637.3481936	-	x					
Noisy Text Data: foible of popular Transformer based NLP models	https://dl.acm.org/doi/abs/10.1145/3639856.3639889	x						
Domain-Invariant Feature Progressive Distillation with Adversarial Adaptive Augmentation for Low-Resource Cross-Domain NER	https://dl.acm.org/doi/full/10.1145/3570502	-			x			

Chinese NER Based on Adversarial Training and Interactive Attention	https://dl.acm.org/doi/abs/10.1145/3651671.3651672	x						
Adversarial Multi-task Learning for Efficient Chinese Named Entity Recognition	https://dl.acm.org/doi/full/10.1145/3603626	-	x					
Chinese Named Entity Recognition in the Ship News Field Based on Adversarial Transfer Learning	https://dl.acm.org/doi/abs/10.1145/3651671.3651725	-	x				x	
Robust and Informative Text Augmentation (RITA) via Constrained Worst-Case Transformations for Low-Resource Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3534678.3539349	x						
Robust Positive-Unlabeled Learning via Noise Negative Sample Self-correction	https://dl.acm.org/doi/abs/10.1145/3580305.3599491	x						
Token Graph Generation for Robust Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3701716.3715451	-	x					
A Robust Named-Entity Recognition System Using Syllable Bigram Embedding with Eojeol Prefix Information	https://dl.acm.org/doi/abs/10.1145/3132847.3133105	-	x					
GBRAIN: Combating Textual Label Noise by Granular-ball based Robust Training	https://dl.acm.org/doi/abs/10.1145/3652583.3658084	-	x					
Unmasking Label Errors: A need for Robust Cybersecurity Benchmarks	https://dl.acm.org/doi/abs/10.1145/3658644.3691418	-					x	
Toward Scalable Human-in-the-Loop Annotation Error Detection with Label Noise-Aware Training	https://dl.acm.org/doi/abs/10.1145/3736733.3736747	-			x			
Chinese Named Entity Recognition Based on Adversarial Training and Deep Multi-Granularity Dilated Convolutions	https://dl.acm.org/doi/full/10.1145/3709026.3709106	-			x			
TRIDENT -- A Three-Tier Privacy-Preserving Propaganda Detection Model in Mobile Networks using Transformers, Adversarial Learning, and Differential Privacy	https://dl.acm.org/doi/abs/10.1145/3734477.3736148	-					x	
Adversarial Transfer Learning for Biomedical Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3594409.3594423	-	x					
Home Appliance Review Analysis Via Adversarial Reptile	https://dl.acm.org/doi/abs/10.1145/3486622.3493958	-					x	

A Bilingual Legal NER Dataset and Semantics-Aware Cross-Lingual Label Transfer Method for Low-Resource Language	https://dl.acm.org/doi/full/10.1145/3748325	-					x	
MetaNER: Named Entity Recognition with Meta-Learning	https://dl.acm.org/doi/abs/10.1145/3366423.3380127	-	x					
The Eifel algorithm: making TCP robust against spurious retransmissions	https://dl.acm.org/doi/abs/10.1145/505688.505692	-				x		
Deep Adversarial Graph Attention Convolution Network for Text-Based Person Search	https://dl.acm.org/doi/abs/10.1145/3343031.3350991	-		x				
DTR-GAN: dilated temporal relational adversarial network for video summarization	https://dl.acm.org/doi/abs/10.1145/3321408.3322622	-			x			
Robust feature extraction via information theoretic learning	https://dl.acm.org/doi/abs/10.1145/1553374.1553526	-				x		
Robust mechanisms for information elicitation	https://dl.acm.org/doi/abs/10.1145/1160633.1160849	-				x		
Deep text classification can be fooled	https://dl.acm.org/doi/10.5555/3304222.3304355	x						
Reshaping automatic speech transcripts for robust high-level spoken document analysis	https://dl.acm.org/doi/abs/10.1145/1871840.1871849	-		x				
HELO DarkSide: Breaking Free From Katas and Embracing the Adversarial Mindset in Cybersecurity Education	https://dl.acm.org/doi/abs/10.1145/3478431.3499404	-	x					
Improving Adversarial Robustness for Recommendation Model via Cross-Domain Distributional Adversarial Training	https://dl.acm.org/doi/abs/10.1145/3640457.3688116	-					x	
LinkNER: Linking Local Named Entity Recognition Models to Large Language Models using Uncertainty	https://dl.acm.org/doi/abs/10.1145/3589334.3645414	-	x					
UNER: A Unified Prediction Head for Named Entity Recognition in Visually-rich Documents	https://dl.acm.org/doi/abs/10.1145/3664647.3681473	-					x	
Cross-Domain NER under a Divide-and-Transfer Paradigm	https://dl.acm.org/doi/full/10.1145/3655618	-					x	
MACE: high-coverage and robust memory analysis for commodity operating systems	https://dl.acm.org/doi/abs/10.1145/2664243.2664248	-				x		

A Smart Adversarial Attack on Deep Hashing Based Image Retrieval	https://dl.acm.org/doi/abs/10.1145/3460426.3463640	-	x					
Neural Joint Model for Part-of-Speech Tagging and Entity Extraction	https://dl.acm.org/doi/abs/10.1145/3457682.3457718	-		x				
Enriching Urdu NER with BERT Embedding, Data Augmentation, and Hybrid Encoder-CNN Architecture	https://dl.acm.org/doi/full/10.1145/3648362	x						
A Survey of Adversarial Defenses and Robustness in NLP	https://dl.acm.org/doi/full/10.1145/3593042	x						
General Debiasing for Graph-based Collaborative Filtering via Adversarial Graph Dropout	https://dl.acm.org/doi/abs/10.1145/3589334.3645667	-				x		
Maximizing the Capabilities of Tiny Speech Foundation Models in a Privacy Preserving Manner	https://dl.acm.org/doi/abs/10.1145/3636534.3697457	-					x	
Cybersecurity Named Entity Recognition Based on Word-level Enhancement and Multi-task Learning	https://dl.acm.org/doi/abs/10.1145/3613330.3613346	-					x	
Adversarial Personalized Ranking for Recommendation	https://dl.acm.org/doi/abs/10.1145/3209978.3209981	-	x					
Robust checkerboard recognition for efficient nonplanar geometry registration in projector-camera systems	https://dl.acm.org/doi/abs/10.1145/1394622.1394625	-				x		
Adversarial Correctness and Privacy for Probabilistic Data Structures	https://dl.acm.org/doi/abs/10.1145/3548606.3560621	-					x	
Adversarial Evaluation of Robust Neural Sequential Tagging Methods for Thai Language	https://dl.acm.org/doi/abs/10.1145/3383201	-		x				
One Pixel Adversarial Attacks via Sketched Programs	https://dl.acm.org/doi/abs/10.1145/3591301	-					x	
True and Fair: Robust and Unbiased Fake News Detection via Interpretable Machine Learning	https://dl.acm.org/doi/abs/10.1145/3600211.3604760	-	x					
Stance Detection with a Multi-Target Adversarial Attention Network	https://dl.acm.org/doi/full/10.1145/3544490	-	x					
TriG-NER: Triplet-Grid Framework for Discontinuous Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3696410.3714639	-					x	
Robustness of deep autoencoder in intrusion detection under adversarial contamination	https://dl.acm.org/doi/abs/10.1145/3190619.3190637	-	x					

Defending Adversarial Attacks on Cloud-aided Automatic Speech Recognition Systems	https://dl.acm.org/doi/abs/10.1145/3327962.3331456	-			x			
Towards Robust Information Extraction via Binomial Distribution Guided Counterpart Sequence	https://dl.acm.org/doi/abs/10.1145/3637528.3672067	-			x			
Reliable Representations Make A Stronger Defender: Unsupervised Structure Refinement for Robust GNN	https://dl.acm.org/doi/abs/10.1145/3534678.3539484	-		x				
Robust and Noise Resistant Wrapper Induction	https://dl.acm.org/doi/abs/10.1145/2882903.2915214	-			x			
Robust Layout-aware IE for Visually Rich Documents with Pre-trained Language Models	https://dl.acm.org/doi/abs/10.1145/3397271.3401442	-	x					
OmniNER2025: Diverse and Comprehensive Fine-Grained NER Dataset and Benchmark for Chinese	https://dl.acm.org/doi/abs/10.1145/3726302.3730048	-	x					
Boosting Entity Recognition by leveraging Cross-task Domain Models for Weak Supervision	https://dl.acm.org/doi/abs/10.1145/3627673.3680009	-			x			
Automated Testing and Improvement of Named Entity Recognition Systems	https://dl.acm.org/doi/abs/10.1145/3611643.3616295	-					x	
Multi-task Learning for Joint Entity and Relation Extraction on Open-domain	https://dl.acm.org/doi/full/10.1145/3690771.3690790	-					x	
QUEACO: Borrowing Treasures from Weakly-labeled Behavior Data for Query Attribute Value Extraction	https://dl.acm.org/doi/abs/10.1145/3459637.3481946	-			x			
BOND: BERT-Assisted Open-Domain Named Entity Recognition with Distant Supervision	https://dl.acm.org/doi/abs/10.1145/3394486.3403149	-			x			
Label Noise Reduction in Entity Typing by Heterogeneous Partial-Label Embedding	https://dl.acm.org/doi/abs/10.1145/2939672.2939822	-			x			
Mitigating linked data quality issues in knowledge-intense information extraction methods	https://dl.acm.org/doi/abs/10.1145/3102254.3102272	-	x					
Mining and Leveraging Background Knowledge for Improving Named Entity Linking	https://dl.acm.org/doi/abs/10.1145/3227609.3227670	-					x	

Named entity recognition of Chinese electronic medical rec-ords based on adversarial train-ing and feature fusion	https://dl.acm.org/doi/abs/10.1145/3632971.3632983	-					x	
Few-shot Named Entity Recognition: Definition, Taxonomy and Research Directions	https://dl.acm.org/doi/full/10.1145/3609483	-	x					
Named Entity Recognition and Classification in Historical Documents: A Survey	https://dl.acm.org/doi/full/10.1145/3604931	x						
Named Entity Recognition and Relation Extraction: State-of-the-Art	https://dl.acm.org/doi/abs/10.1145/3445965	-	x					
Named entity recognition of Chinese electronic medical rec-ords based on adversarial train-ing and feature fusion	https://dl.acm.org/doi/abs/10.1145/3632971.3632983	-			x			
CycleNER: An Unsupervised Training Approach for Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3485447.3512012	-	x					
Exploring Modular Task Decomposition in Cross-domain Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3477495.3531976	-	x					
A Cyber Threat Entity Recognition Method Based on Robust Feature Representation and Adversarial Training	https://dl.acm.org/doi/abs/10.1145/3633637.3633677	-	x					
Exogenous and Endogenous Data Augmentation for Low-Resource Complex Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3626772.3657754	-					x	
Nested Named Entity Recognition: A Survey	https://dl.acm.org/doi/full/10.1145/3522593	-	x					
DeepTagger: Knowledge Enhanced Named Entity Recognition for Web-Based Ads Queries	https://dl.acm.org/doi/abs/10.1145/3583780.3615467	-	x					
MGICL: Multi-Grained Interaction Contrastive Learning for Multimodal Named Entity Recog-nition	https://dl.acm.org/doi/abs/10.1145/3583780.3614967	-	x					
Dual Contrastive Learning for Cross-Domain Named Entity Recognition	https://dl.acm.org/doi/full/10.1145/3678879	-			x			
A Chinese Cyber Threat Intelligence Named Entity Recognition Method	https://dl.acm.org/doi/full/10.1145/3727648.3727787	-	x					
Representation and Labeling Gap Bridging for Cross-lingual Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3539618.3591757	-					x	
FedINER: Chinese Industrial Named Entity Recognition with Federated Learning	https://dl.acm.org/doi/full/10.1145/3730401	-	x					
Boosted Web Named Entity Recognition via Tri-Training	https://dl.acm.org/doi/abs/10.1145/2963100	-				x		

Fine-Grained Multimodal Named Entity Recognition and Grounding with a Generative Framework	https://dl.acm.org/doi/abs/10.1145/3581783.3612322	-	x					
Task Relation Distillation and Prototypical Pseudo Label for Incremental Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3583780.3615075	x						
Named entity recognition based on semi-supervised ensemble learning with the improved tri-training algorithm	https://dl.acm.org/doi/abs/10.1145/3446999.3447002	-		x				
Entity Pair Recognition using Semantic Enrichment and Adversarial Training for Chinese Drug Knowledge Extraction	https://dl.acm.org/doi/abs/10.1145/3500931.3500939	-	x					
MeDict-GP: An Accurate Entity Recognition Model Combining Medical Domain Knowledge and Globalization Ideas	https://dl.acm.org/doi/abs/10.1145/3594315.3594360	-	x				x	
HEProto: A Hierarchical Enhancing ProtoNet based on Multi-Task Learning for Few-shot Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3583780.3614908	-					x	
Decoupled Hyperbolic Graph Attention Network for Cross-domain Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3539618.3591662	-	x					
A Survey on Deep Learning for Chinese Medical Named Entity Recognition	https://dl.acm.org/doi/abs/10.1145/3594315.3594359	-					x	
Text Analysis for Decision Making under Adversarial Environments	https://dl.acm.org/doi/abs/10.1145/3200947.3201018	-					x	
Wiki-TabNER: Integrating Named Entity Recognition into Wikipedia Tables	https://dl.acm.org/doi/abs/10.1145/3726302.3730344	-					x	
Weighted Vote-Based Classifier Ensemble for Named Entity Recognition: A Genetic Algorithm-Based Approach	https://dl.acm.org/doi/abs/10.1145/1967293.1967296	-	x					
Biological Named Entity Recognition and Role Labeling via Deep Multi-task Learning	https://dl.acm.org/doi/abs/10.1145/3457682.3457751	-					x	
Towards Named-Entity-based Similarity Measures: Challenges and Opportunities	https://dl.acm.org/doi/abs/10.1145/2663712.2666194	-			x			
Data Quality for Machine Learning Tasks	https://dl.acm.org/doi/abs/10.1145/3447548.3470817	-	x					

Adversarial Attacks on Deep-learning Models in Natural Language Processing: A Survey	https://dl.acm.org/doi/abs/10.1145/3374217	-			x			
BERT Rankers are Brittle: A Study using Adversarial Document Perturbations	https://dl.acm.org/doi/abs/10.1145/3539813.3545122	x						
On the Explainability of Natural Language Processing Deep Models	https://dl.acm.org/doi/full/10.1145/3529755	-	x					
Application of NoisyTune on Sentiment Analysis of BERT Model	https://dl.acm.org/doi/abs/10.1145/3650400.3650451	-			x			
Towards Robustness to Label Noise in Text Classification via Noise Modeling	https://dl.acm.org/doi/abs/10.1145/3459637.3482204	-		x				
Enhancing Chinese Medical Named Entity Recognition with Auto-Mined Lexicon	https://ieeexplore.ieee.org/document/9945273	-	x				x	
Named Entity Recognition for Medical Dialogue Based on BERT and Adversarial Training	https://ieeexplore.ieee.org/abstract/document/9904246	-	x					
Exploiting Named Entity Recognition via Pre-trained Language Model and Adversarial Training	https://ieeexplore.ieee.org/document/9574510	-			x			
Power Inspection Text NER: Integrating BERT with Matrix LSTM	https://ieeexplore.ieee.org/document/11009461	-			x			
Chinese Named Entity Recognition Based on Lexicon Information Enhancement and Adaptive Adversarial Training	https://ieeexplore.ieee.org/document/10941950	-	x					
Chinese named entity recognition based on dual-channel dilated convolution neural network	https://ieeexplore.ieee.org/document/10498985	-	x					
A Model for Chinese Named Entity Recognition Based on Global Pointer and Adversarial Learning	https://ieeexplore.ieee.org/document/10168799	-	x					
Adversarial Examples: Attacks and Defenses for Deep Learning	https://ieeexplore.ieee.org/abstract/document/8611298	x						
3Rs: Data Augmentation Techniques Using Document Contexts For Low-Resource Chinese Named Entity Recognition	https://ieeexplore.ieee.org/document/9892341	x						
PGD-GP: A Chinese Named Entity Recognition Model for Constructing Food Safety Standard Knowledge Graph	https://ieeexplore.ieee.org/document/10460123	-	x					
Named Entity Recognition using Negative Sampling and Reinforcement Learning	https://ieeexplore.ieee.org/document/9669602	-			x			
Semantic-Retention Attack for Continual Named Entity Recognition	https://ieeexplore.ieee.org/document/11030305	x						

Resume Parsing Across Multiple Job Domains Using a BERT-Based NER Model	https://ieeexplore.ieee.org/document/10470917	-	x					
Towards DS-NER: Unveiling and Addressing Latent Noise in Distant Annotations	https://ieeexplore.ieee.org/document/10988654	-	x					
Increasing NER Recall with Minimal Precision Loss	https://ieeexplore.ieee.org/document/6657133	-				x		
Research on Named Entity Recognition of Medical Records Combining Confrontation and Attention Mechanism	https://ieeexplore.ieee.org/document/10528525	-	x					
Are Deep Neural Networks Robust to Named Entities? An Adversarial Attack and Defense Perspective	https://ieeexplore.ieee.org/document/10448165	x						
Enhancing Biomedical NER with Adversarial Selective Training	https://ieeexplore.ieee.org/document/10822546	-	x					
DeComa: Dictionary Enhanced Chinese NER Based on Confidence Estimation	https://ieeexplore.ieee.org/document/10097909	x						
Multi-Layout Unstructured Invoice Documents Dataset: A Dataset for Template-Free Invoice Processing and Its Evaluation Using AI Approaches	https://ieeexplore.ieee.org/document/9481217	-	x					
Dealing With Hierarchical Types and Label Noise in Fine-Grained Entity Typing	https://ieeexplore.ieee.org/document/9723572	x						
Review on Big Data Fusion Methods of Quality Inspection for Consumer Goods	https://ieeexplore.ieee.org/document/8421858	-	x					
EFwork: An Efficient Framework for Constructing a Malware Knowledge Graph	https://ieeexplore.ieee.org/document/10538922	-	x					
Comprehensive Architecture for Data Quality Assessment in Industrial IoT	https://ieeexplore.ieee.org/document/10257209	-	x					
In-vivo characterization of a 0.8 – 3 μVRMS input-noise versatile CMOS pre-amplifier	https://ieeexplore.ieee.org/document/7146658	-	x					
GaitReload: A Reloading Framework for Defending Against On-Manifold Adversarial Gait Sequences	https://ieeexplore.ieee.org/document/10025772	-			x			
Effective Few-Shot Named Entity Linking by Meta-Learning	https://ieeexplore.ieee.org/document/9835266	-	x					
Research on Named Entity Recognition of Medical Records Combining Confrontation and Attention Mechanism	https://ieeexplore.ieee.org/document/10528525	-			x			
Increasing NER Recall with Minimal Precision Loss	https://ieeexplore.ieee.org/document/6657133	-	x				x	
Joint Extraction Model of Entity and Relationship Based on Reinforcement Learning	https://ieeexplore.ieee.org/document/9390067	-	x					
Medical Entity Recognition Based on Self-Attention and Adversarial Training	https://ieeexplore.ieee.org/document/10408910	-			x			
Research and Data Analysis on Relationship Extraction Methods Based on Multi-Domain Texts	https://ieeexplore.ieee.org/document/10607254	x						

Text2EL: Exploiting Unstructured Text for Event Log Enrichment	https://ieeexplore.ieee.org/document/10090059	-			x			
Modeling the Type Hierarchy in High-Dimensional Box Space for Fine-Grained Entity Typing	https://ieeexplore.ieee.org/document/10816247	-			x			
KBAA: An adversarial example generation method for KBQA task	https://ieeexplore.ieee.org/document/9331217	-	x					
A Word-Level Adversarial Attack Method Based on Sememes and an Improved Quantum-Behaved Particle Swarm Optimization	https://ieeexplore.ieee.org/document/10155154	-					x	
A System of Data Assets Registration and Catalog Managemen	https://ieeexplore.ieee.org/document/10211143	-			x			
A Method and System for Power Grid Engineering Error Diagnosis Based on Improved Graph Convolutional Networks	https://ieeexplore.ieee.org/document/10373328	-	x					
Exploring Deep Learning Approaches for Real-Time Anonymization and Privacy Preservation in Unstructured Data	https://ieeexplore.ieee.org/document/11081525	-	x				x	
Social Media Data: Challenges, Mitigation Strategies, and Opportunities for Disaster Management	https://ieeexplore.ieee.org/document/10838417	-			x			
Fine-Grained Entity Typing With a Type Taxonomy: A Systematic Review	https://ieeexplore.ieee.org/document/9706297	-			x			
GESgnExt: Gene Expression Signature Extraction and Meta-Analysis on Gene Expression Omnibus	https://ieeexplore.ieee.org/document/8629999	-	x					
An Ontological-Based Model to Data Governance for Big Data	https://ieeexplore.ieee.org/document/9503381	-	x					
Methodology for Automated Master Data Management using Artificial Intelligence	https://ieeexplore.ieee.org/document/9989629	-			x			
Enhancing Low-Resource NLP by Consistency Training With Data and Model Perturbations	https://ieeexplore.ieee.org/document/10288035	x						
An integrated approach for detecting approximate duplicate records	https://ieeexplore.ieee.org/document/5406409	-	x					
Software Entity Recognition with Noise-Robust Learning	https://ieeexplore.ieee.org/abstract/document/10298513	-	x					
Named Entity Recognition in Noisy Domains	https://ieeexplore.ieee.org/abstract/document/8674438	x						
Construction of Machine-Labeled Data for Improving Named Entity Recognition by Transfer Learning	https://ieeexplore.ieee.org/abstract/document/9039649	-	x					
A Survey on Deep Learning for Named Entity Recognition	https://ieeexplore.ieee.org/abstract/document/9039685	-	x		x			

RoSeq: Robust Sequence Labeling	https://ieeex-plore.ieee.org/abstract/document/8709849	-	x					
Noise Reduction Learning Based on XLNet-CRF for Biomedical Named Entity Recognition	https://ieeexplore.ieee.org/abstract/docu-ment/9730067	-			x			
Enhancing Named Entity Recognition in Low-Resource Languages: The Crucial Role of Data Sampling in Malayalam	https://ieeexplore.ieee.org/abstract/docu-ment/10498889	-	x					
A Robust and Domain-Adaptive Approach for Low-Resource Named Entity Recognition	https://ieeexplore.ieee.org/abstract/docu-ment/9194550	-			x			
Pretrained Models with Adversarial Training for Named Entity Recognition in Scientific Text	https://ieeexplore.ieee.org/abstract/docu-ment/9961309	-			x			
A Federated Adversarial Learning Method for Biomedical Named Entity Recognition	https://ieeexplore.ieee.org/abstract/docu-ment/9669728	-	x					
Named entity recognition in the food field based on BERT and Adversarial training	https://ieeexplore.ieee.org/abstract/docu-ment/9601522	-	x					
Enhancing Biomedical NER with Adversarial Selective Training	https://ieeexplore.ieee.org/abstract/docu-ment/10822546	-	x					
Named Entity Recognition for Medical Dialogue Based on BERT and Adversarial Training	https://ieeexplore.ieee.org/abstract/docu-ment/9904246	-	x					
A Named Entity Recognition Method for Fields Including Electrical Power Based on Data Enhancement	https://ieeexplore.ieee.org/abstract/docu-ment/11010196	x						
SNER: Semi-Supervised Named Entity Recognition for Large Volume of Diabetes Data	https://ieeexplore.ieee.org/abstract/docu-ment/10552914	-					x	
Adversarial Named Entity Recognition with POS label embedding	https://ieeexplore.ieee.org/abstract/docu-ment/9207682	-	x					
Textual Adversarial Attacks on Named Entity Recognition in a Hard Label Black Box Setting	https://ieeexplore.ieee.org/abstract/docu-ment/9943674	-		x				
Named Entity Recognition for AI-Driven Medical Text Processing in the Silicon Revolution	https://ieeexplore.ieee.org/abstract/docu-ment/11036807	-					x	

Robust tree-structured Named Entities Recognition from speech	https://ieeexplore.ieee.org/abstract/document/6639319	-	x					
ASNet: An Adversarial Sparse Network for Multi-task Biomedical Named Entity Recognition	https://ieeexplore.ieee.org/abstract/document/9995027	-			x			
Mix of Experts Language Model for Named Entity Recognition	https://ieeexplore.ieee.org/abstract/document/10653372	-	x					
An Empirical Study of Named Entity Recognition for Electronic Health Records	https://ieeexplore.ieee.org/abstract/document/10884296	-			x			
A Comparative Study of Deep Learning based Named Entity Recognition Algorithms for Cybersecurity	https://ieeexplore.ieee.org/abstract/document/9378482	-	x					
Adversarial training for named entity recognition of rail fault text	https://ieeexplore.ieee.org/abstract/document/9565087	-		x				
Transfer Learning in Brain-Computer Interfaces with Adversarial Variational Autoencoders	https://ieeexplore.ieee.org/abstract/document/8716897	-	x					
Pre-Trained or Adversarial Training: A Comparison of NER Methods on Chinese Drug Specifications	https://ieeexplore.ieee.org/abstract/document/10690832	-			x			
A Survey on Arabic Named Entity Recognition: Past, Recent Advances, and Future Trends	https://ieeexplore.ieee.org/abstract/document/10210700	-			x			
Large Language Models and Adversarial Reinforcement Learning to Automate PLCs Programming: A Preliminary Investigation	https://ieeexplore.ieee.org/abstract/document/10284185	-	x					
Majority or Minority: Data Imbalance Learning Method for Named Entity Recognition	https://ieeexplore.ieee.org/abstract/document/10816423	-			x			
Named Entity Recognition in User-Generated Text: A Systematic Literature Review	https://ieeexplore.ieee.org/abstract/document/10597560	x						
Adversarial Learning for Multi-Task Sequence Labeling With Attention Mechanism	https://ieeexplore.ieee.org/abstract/document/9153102	-	x					
Enhancing Nested Named Entity Recognition in Chinese EMRs: A Collaborative Approach	https://ieeexplore.ieee.org/abstract/document/10822099	-	x					

Recent Progress on Named Entity Recognition Based on Pre-trained Language Models	https://ieeexplore.ieee.org/abstract/document/10356429	-	x				x	
Robust, ultra low-cost MMG system with brain-machine-interface applications	https://ieeexplore.ieee.org/abstract/document/6696036	-	x	x		x		
Named Entity Recognition and Relation Extraction with Graph Neural Networks in Semi Structured Documents	https://ieeexplore.ieee.org/abstract/document/9412669	-		x				
Fine-Tuned BERT Based Multilingual Model for Named Entity Recognition in Native Indian Languages	https://ieeexplore.ieee.org/abstract/document/10392937	-			x			
BioALBERT: A Simple and Effective Pre-trained Language Model for Biomedical Named Entity Recognition	https://ieeexplore.ieee.org/abstract/document/9533884	-	x					
MAWSEO: Adversarial Wiki Search Poisoning for Illicit Online Promotion	https://ieeexplore.ieee.org/abstract/document/10646819	-		x				
BuTTER: BidirecTional LSTM for Food Named-Entity Recognition	https://ieeexplore.ieee.org/abstract/document/9378151	-	x					
A robust and efficient method to recover neural events from noisy and corrupted data	https://ieeexplore.ieee.org/abstract/document/6696004	-				x		
Research on Named Entity Recognition for Information Extraction	https://ieeexplore.ieee.org/abstract/document/9425900	-	x					
Enhancing Code-Mixing in Named Entity Recognition: A Comprehensive Survey of Deep Learning Models	https://ieeexplore.ieee.org/abstract/document/10493709	-			x			
Enhancing Named Entity Recognition with a BERT-DQN Hybrid Model	https://ieeexplore.ieee.org/abstract/document/10724323	-	x					
Named Entity Recognition in the Moroccan Dialect	https://ieeexplore.ieee.org/abstract/document/10409973	-					x	
Enhancing Korean Named Entity Recognition With Linguistic Tokenization Strategies	https://ieeexplore.ieee.org/abstract/document/9610031	-	x					
Bag of Tricks for Chinese Named Entity Recognition	https://ieeexplore.ieee.org/abstract/document/9533296	-			x			

Comparing Topic Modeling and Named Entity Recognition Techniques for the Semantic Indexing of a Landscape Architecture Textbook	https://ieeexplore.ieee.org/abstract/document/8735642	-	x					
Transformer-Based Named Entity Recognition in Construction Supply Chain Risk Management in Australia	https://ieeexplore.ieee.org/abstract/document/10472528	-	x					
Optimizing Spatial Contrast of a New Checkerboard Stimulus for Eliciting Robust SSVEPs	https://ieeexplore.ieee.org/abstract/document/8716972	-		x				
Improving Chinese Named Entity Recognition by Large-Scale Syntactic Dependency Graph	https://ieeexplore.ieee.org/abstract/document/9722991	-		x				
Joint Self-Attention and Multi-Embeddings for Chinese Named Entity Recognition	https://ieeexplore.ieee.org/abstract/document/9160451	-	x					
Chinese ASR and NER Improvement Based on Whisper Fine-Tuning	https://ieeexplore.ieee.org/abstract/document/10079686	-			x			
Adaptation of a named entity recognition system for the ESTER 2 evaluation campaign	https://ieeexplore.ieee.org/abstract/document/5313775	-					x	
Transformer-Based Named Entity Recognition for Automated Server Provisioning	https://ieeexplore.ieee.org/abstract/document/11006240	-					x	

Anhang 2: Auswertungstabelle Qualitätsminderungen Testdatensatz

Art	Noise	BERT	RoBERTa	DeBERTa	DistilBERT	CANINE	XLNet
Baseline	0%	91,8 ± 0,3	92,9 ± 0,2	92,7 ± 0,3	90,3 ± 0,4	89,4 ± 0,5	91,8 ± 0,3
Orthografisch	10%	89,7 ± 0,6	91,1 ± 0,5	90,7 ± 0,5	86,0 ± 0,8	88,6 ± 0,4	89,6 ± 0,7
Orthografisch	20%	85,9 ± 0,9	88,0 ± 0,6	86,9 ± 0,7	81,3 ± 1,2	86,5 ± 0,4	86,3 ± 0,8
Orthografisch	30%	79,8 ± 1,2	82,7 ± 0,9	82,2 ± 1,0	76,1 ± 1,6	82,6 ± 0,6	80,0 ± 1,2
Orthografisch (S)	10%	90,2 ± 0,4	91,2 ± 0,3	90,9 ± 0,4	86,2 ± 0,6	88,6 ± 0,4	90,5 ± 0,6
Orthografisch (S)	20%	89,0 ± 0,5	90,1 ± 0,4	89,7 ± 0,5	82,8 ± 0,8	88,2 ± 0,5	89,9 ± 0,6
Orthografisch (S)	30%	87,3 ± 0,7	88,8 ± 0,5	88,7 ± 0,6	81,0 ± 1,0	87,1 ± 0,6	88,4 ± 0,8
Semantisch	10%	86,1 ± 0,8	88,0 ± 0,7	87,7 ± 0,7	83,2 ± 1,0	83,4 ± 0,9	86,2 ± 0,8
Semantisch	20%	83,3 ± 1,0	85,4 ± 0,8	84,8 ± 0,9	78,5 ± 1,2	80,9 ± 1,1	83,9 ± 1,0
Semantisch	30%	81,3 ± 1,2	83,6 ± 1,0	83,7 ± 1,1	74,9 ± 1,5	78,1 ± 1,3	81,3 ± 1,2
Semantisch (S)	10%	88,2 ± 0,6	90,1 ± 0,5	90,3 ± 0,5	85,1 ± 0,8	85,4 ± 0,7	88,8 ± 0,7
Semantisch (S)	20%	85,9 ± 0,7	88,2 ± 0,6	87,8 ± 0,6	82,5 ± 1,0	82,7 ± 0,8	86,2 ± 0,8
Semantisch (S)	30%	84,2 ± 0,9	86,3 ± 0,7	86,2 ± 0,8	79,5 ± 1,1	80,1 ± 0,9	84,7 ± 1,0
Syntaktisch	10%	84,9 ± 1,0	86,7 ± 0,8	86,9 ± 0,9	81,8 ± 1,3	82,7 ± 1,1	86,4 ± 1,0
Syntaktisch	20%	79,9 ± 1,3	82,1 ± 1,0	82,7 ± 1,1	76,6 ± 1,6	77,8 ± 1,3	81,3 ± 1,3
Syntaktisch	30%	76,1 ± 1,5	77,7 ± 1,2	78,8 ± 1,2	72,2 ± 2,2	72,6 ± 1,6	77,7 ± 1,5

Anhang 3: Auswertungstabelle Qualitätsminderungen Trainings- und Testdatensatz

Art	Noise	BERT	RoBERTa	DeBERTa	DistilBERT	CANINE	XLNet
Baseline	0%	91,8 ± 0,3	92,9 ± 0,2	92,7 ± 0,3	90,3 ± 0,4	89,4 ± 0,5	91,8 ± 0,3
Orthografisch	10%	90,1 ± 0,4	91,5 ± 0,3	91,6 ± 0,4	87,8 ± 0,6	88,7 ± 0,5	90,7 ± 0,5
Orthografisch	20%	88,7 ± 0,6	90,1 ± 0,5	90,0 ± 0,5	83,1 ± 0,8	87,9 ± 0,5	89,2 ± 0,6
Orthografisch	30%	86,4 ± 0,8	89,0 ± 0,8	89,0 ± 0,7	81,6 ± 1,2	86,9 ± 0,6	86,6 ± 0,6
Orthografisch (S)	10%	91,0 ± 0,3	91,9 ± 0,3	91,8 ± 0,4	89,4 ± 0,6	89,2 ± 0,4	91,3 ± 0,3
Orthografisch (S)	20%	90,6 ± 0,4	91,7 ± 0,3	91,8 ± 0,4	88,2 ± 0,7	88,9 ± 0,5	91,0 ± 0,5
Orthografisch (S)	30%	89,8 ± 0,5	91,5 ± 0,4	91,7 ± 0,5	86,4 ± 0,7	88,2 ± 0,5	90,5 ± 0,5
Semantisch	10%	89,6 ± 0,6	90,3 ± 0,5	91,0 ± 0,5	87,7 ± 0,8	87,6 ± 0,7	89,9 ± 0,5
Semantisch	20%	86,7 ± 0,8	88,3 ± 0,7	89,1 ± 0,7	84,6 ± 1,0	84,5 ± 0,9	86,9 ± 0,7
Semantisch	30%	85,3 ± 0,9	87,5 ± 0,8	88,4 ± 0,7	81,9 ± 1,1	82,2 ± 1,0	85,2 ± 0,9
Semantisch (S)	10%	91,3 ± 0,4	92,0 ± 0,3	91,6 ± 0,3	89,1 ± 0,5	88,6 ± 0,5	91,3 ± 0,3
Semantisch (S)	20%	90,7 ± 0,5	91,2 ± 0,4	91,2 ± 0,3	88,0 ± 0,5	88,3 ± 0,7	91,0 ± 0,5
Semantisch (S)	30%	90,1 ± 0,7	90,7 ± 0,5	91,0 ± 0,6	87,3 ± 0,8	88,1 ± 0,8	90,5 ± 0,6
Syntaktisch	10%	88,4 ± 0,7	90,0 ± 0,6	90,5 ± 0,6	86,6 ± 0,9	85.8 ± 0,9	89,0 ± 0,8
Syntaktisch	20%	86,3 ± 0,9	88,6 ± 0,8	89,2 ± 0,7	83,2 ± 1,2	82,5 ± 1,1	87,9 ± 1,0
Syntaktisch	30%	84,1 ± 1,1	86,0 ± 0,9	87,7 ± 0,9	81,1 ± 1,5	81,2 ± 1,2	86,4 ± 1,0

Anhang 4: Auswertungstabelle Qualitätsminderungen Trainingsdatensatz

Art	Noise	BERT	RoBERTa	DeBERTa	DistilBERT	CANINE	XLNet
Baseline	0%	91,8 ± 0,3	92,9 ± 0,2	92,7 ± 0,3	90,3 ± 0,4	89,4 ± 0,5	91,8 ± 0,3
Orthografisch	10%	91,5 ± 0,4	92,5 ± 0,3	92,6 ± 0,3	89,9 ± 0,4	89,3 ± 0,4	91,6 ± 0,4
Orthografisch	20%	91,3 ± 0,3	92,7 ± 0,3	92,8 ± 0,4	89,5 ± 0,3	89,0 ± 0,5	91,6 ± 0,3
Orthografisch	30%	90,9 ± 0,4	92,6 ± 0,4	92,5 ± 0,4	88,8 ± 0,4	88,8 ± 0,5	91,3 ± 0,4
Orthografisch (S)	10%	91,6 ± 0,3	92,4 ± 0,2	92,6 ± 0,3	90,1 ± 0,3	89,3 ± 0,5	91,8 ± 0,3
Orthografisch (S)	20%	91,6 ± 0,4	92,3 ± 0,3	92,4 ± 0,4	89,8 ± 0,4	89,1 ± 0,4	91,8 ± 0,3
Orthografisch (S)	30%	91,5 ± 0,4	91,9 ± 0,2	92,2 ± 0,4	89.6 ± 0,4	88,9 ± 0,5	91,7 ± 0,4
Semantisch	10%	90,7 ± 0,4	91,7 ± 0,3	92,2 ± 0,4	89,5 ± 0,5	88,9 ± 0,5	91,2 ± 0,4
Semantisch	20%	90,8 ± 0,4	91,8 ± 0,4	92,3 ± 0,4	88,9 ± 0,4	89.0 ± 0,6	91,2 ± 0,4
Semantisch	30%	90,1 ± 0,3	91,6 ± 0,4	92,0 ± 0,5	88,1 ± 0,5	88,7 ± 0,6	90,8 ± 0,5
Semantisch (S)	10%	91,1 ± 0,3	91,9 ± 0,3	92,0 ± 0,3	89,9 ± 0,4	88,6 ± 0,4	91,3 ± 0,3
Semantisch (S)	20%	90,9 ± 0,4	91,7 ± 0,2	91,8 ± 0,4	89,7 ± 0,5	88,4 ± 0,5	91,0 ± 0,3
Semantisch (S)	30%	90,4 ± 0,4	91,3 ± 0,3	91,6 ± 0,3	89,1 ± 0,4	88,2 ± 0,5	90,7 ± 0,4
Label-bezogen	10%	81,8 ± 1,1	84,7 ± 1,0	83,5 ± 1,1	79,9 ± 1,3	80,9 ± 1,1	83,1 ± 1,2
Label-bezogen	20%	79,5 ± 1,8	83,0 ± 1,5	81,9 ± 1,5	78,2 ± 1,9	80,1 ± 1,6	82,6 ± 1,6
Label-bezogen	30%	78,3 ± 1,9	81,3 ± 1,6	80,4 ± 1,7	76,9 ± 2,1	79,9 ± 1,8	80,7 ± 1,9
Syntaktisch	10%	90,1 ± 0,3	91,7 ± 0,4	91,8 ± 0,3	88,8 ± 0,5	88,5 ± 0,4	90,1 ± 0,4
Syntaktisch	20%	89,7 ± 0,3	91,2 ± 0,3	91,3 ± 0,4	87,9 ± 0,5	87,8 ± 0,5	89,4 ± 0,5
Syntaktisch	30%	89,1 ± 0,5	90,5 ± 0,4	91,0 ± 0,4	87,7 ± 0,6	87,1 ± 0,5	88,7 ± 0,5